Constraint-based learning: Variants of the PC algorithm, hypothesis tests for testing conditional independence, causality, hybrid (constraint based and score+search)

Damián Benasco Sánchez
Thales Camargo
Juan David Cárdenas
Universidad Politécnica de Madrid, Spain

Abstract

Las redes bayesianas son modelos gráficos probabilísticos que permiten representar de forma compacta e interpretable las dependencias condicionales entre un conjunto de variables aleatorias. Cuando la estructura de estos modelos no puede especificarse a partir del conocimiento experto, el aprendizaje estructural a partir de datos permite reconstruirla, y la literatura distingue tres familias de métodos: basados en puntuación y búsqueda, basados en restricciones e híbridos. Este trabajo revisa el estado del arte del aprendizaje basado en restricciones, con el algoritmo PC como eje central. Se examinan sus fundamentos teóricos (condición de Markov causal, fidelidad y d-separación) y las cinco limitaciones que surgen en muestras finitas: ausencia de garantías en alta dimensión, dependencia del orden de las variables, pérdida de potencia al crecer el conjunto de condicionamiento, coste computacional y rigidez de los supuestos. Para cada una se analizan las variantes propuestas, desde CPC, PC-stable y k-PC hasta las versiones paralelas, las extensiones para series temporales, eventos extremos y variables latentes, y las formulaciones diferenciables. A continuación se comparan las pruebas de independencia condicional (correlación parcial, tablas de contingencia, métodos de regresión y contrastes no paramétricos basados en kernel) junto con sus extensiones causales, subrayando que ninguna es universal. Por último, se estudian los enfoques híbridos, que combinan restricciones y optimización por puntuación para mitigar la propagación de errores, y se discuten sus limitaciones. La revisión concluye que el rendimiento depende de la interacción entre potencia estadística, coste y supuestos causales, y que no existe una estrategia dominante. Todo ello sitúa el problema de la inferencia estructural dentro del marco del descubrimiento causal a partir de datos observacionales.

Palabras clave: redes bayesianas, aprendizaje estructural, algoritmo PC, independencia condicional, descubrimiento causal, métodos híbridos.

1 Introducción

Las redes bayesianas son modelos gráficos probabilísticos que representan un conjunto de variables aleatorias y sus dependencias condicionales mediante un grafo acíclico dirigido (DAG) y un conjunto de parámetros de distribución condicional (**??**). En los desarrollos iniciales de este campo, la estructura de la red y sus parámetros se especificaban principalmente a partir del conocimiento experto; sin embargo, esta estrategia presenta limitaciones importantes en sistemas complejos, de alta dimensión o en dominios donde las relaciones subyacentes no se conocen de forma directa (**??**).

Como alternativa, el aprendizaje estructural a partir de datos automatiza la construcción de la topología gráfica y la estimación de parámetros mediante el análisis de bases de datos observacionales o experimentales (**??**). Cuando el grafo se interpreta causalmente, este paradigma de descubrimiento automático permite inferir no solo asociaciones probabilísticas, sino también los mecanismos causales subyacentes, sin imponer una estructura previa definida por expertos (**??**).

Dentro del aprendizaje de estructuras guiado por datos, la literatura distingue tradicionalmente tres familias de métodos: enfoques basados en puntuación y búsqueda, enfoques basados en restricciones y métodos híbridos (**??**). El aprendizaje basado en restricciones, también conocido como *constraint-based learning*, infiere la estructura de la red mediante pruebas estadísticas de hipótesis de independencia condicional entre variables (**??**). Su fundamento teórico se apoya en la condición de Markov causal y la propiedad de fidelidad (faithfulness), que establecen una correspondencia entre las independencias condicionadas observadas en los datos y la d-separación en el DAG (**??**).

Los algoritmos canónicos de esta familia, como el algoritmo PC (Peter-Clark), operan en fases secuenciales y transparentes: primero eliminan aristas entre variables que son condicionalmente independientes dado un conjunto de condicionamiento y, posteriormente, orientan las relaciones que permanecen relevantes según la estructura de independencias observada (**??**). Este enfoque ofrece una mayor interpretabilidad que otras estrategias de aprendizaje estructural, ya que cada decisión de mantener, eliminar u orientar una relación puede rastrearse hasta una prueba estadística concreta (**??**).

No obstante, el aprendizaje basado en restricciones también presenta limitaciones importantes en muestras finitas. La propagación de errores estadísticos puede alterar decisiones tempranas sobre eliminación de aristas (**??**), la potencia de las pruebas de independencia condicional disminuye cuando aumenta el tamaño del conjunto de condicionamiento (**??**) y el resultado puede depender del orden de procesamiento de las variables (**?**). Para solventar estas debilidades surgen los métodos híbridos, que combinan las fortalezas complementarias del aprendizaje basado en restricciones y de los métodos basados en puntuación y búsqueda. En este esquema, la fase de restricción reduce el espacio de soluciones mediante pruebas de independencia condicional y, a continuación, la búsqueda local optimiza una función de puntuación global para refinar la estructura final (**???**).

En este contexto, el presente trabajo se centra en el estado del arte de los métodos *constraint-based* para el aprendizaje de redes bayesianas, con especial atención a las variantes del algoritmo PC, a las pruebas de independencia condicional, a la relación entre independencia y causalidad, y a la evolución hacia enfoques híbridos que integran restricciones y optimización basada en puntuación. El objetivo es revisar la literatura más relevante para situar el problema de inferencia estructural dentro del marco teórico del descubrimiento causal y justificar el interés de combinar estrategias estadísticas y causales en la construcción de modelos probabilísticos a partir de datos observacionales.

2 Estado del arte

El panorama actual del descubrimiento de estructuras en redes bayesianas y modelos gráficos causales ha experimentado una notable evolución, transitando desde la formulación clásica de algoritmos basados en restricciones hacia métodos altamente escalables, flexibles e híbridos. Para comprender de manera sistemática este estado del arte, la presente sección se organiza en tres ejes analíticos interconectados. En primer lugar, se examina la evolución del algoritmo PC y sus variantes, abordando desde sus fundamentos teóricos y modificaciones para garantizar la independencia del orden de entrada y la paralelización, hasta sus extensiones modernas para datos temporales, valores extremos y optimización diferenciable. En segundo lugar, se analizan las pruebas de hipótesis de independencia condicional, comprendidas como el motor estadístico crítico que sustenta las decisiones de poda de aristas y orientación en presencia de variados tipos de datos. Por último, se exploran los paradigmas híbridos, los cuales integran el filtrado local por restricciones con la optimización por puntuación o la resolución lógica de conflictos para mitigar la acumulación de errores en muestras finitas y mejorar la precisión estructural.

2.1 El algoritmo PC: fundamentos, limitaciones y variantes

2.1.1 Fundamentos y limitaciones

El **algoritmo PC**, llamado así por sus autores Peter Spirtes y Clark Glymour (**?**), es el método fundacional del aprendizaje estructural basado en restricciones. Surgió como alternativa eficiente al algoritmo SGS, que contrasta la independencia de cada par de variables condicionando sobre todos los subconjuntos posibles del resto. La idea del PC es limitar los conjuntos de condicionamiento a los vecinos actuales de cada variable en un grafo que se va podando (**?**).

Sea $\mathbf{X} = (X_1, \ldots, X_n)$ un conjunto de variables con distribución conjunta P, y sea $I(X, Y \mid \mathbf{S})$ la independencia condicional de X e Y dado el conjunto $\mathbf{S}$. El PC supone que P es *fiel* a un DAG G, es decir, que las independencias de P son exactamente las d-separaciones de G, y que no existen causas comunes latentes (*suficiencia causal*). Bajo estos supuestos, X e Y no son adyacentes en G si y solo si existe un conjunto $\mathbf{S}$, contenido en los vecinos de X o en los de Y, tal que $I(X, Y \mid \mathbf{S})$ (**??**). El algoritmo explota esta propiedad en dos fases. En la primera (Algoritmo **??**) parte del grafo completo no dirigido y elimina aristas mediante contrastes de orden creciente $\ell = |\mathbf{S}|$, guardando el conjunto separador $\mathbf{S}_{XY}$ de cada arista eliminada.

Algorithm 1 Algoritmo PC: fase de búsqueda del esqueleto

Inicializar G' como un grafo completo no dirigido sobre $\mathbf{X}$
$\ell \leftarrow 0$
repeat
  for cada par adyacente (X, Y) en G' **do**
    if existe $\mathbf{S} \subseteq \mathrm{Adj}_{G'}(X) \setminus \{Y\}$ con $|\mathbf{S}| = \ell$ e $I(X, Y \mid \mathbf{S})$ **then**
      Guardar $\mathbf{S}_{XY} \leftarrow \mathbf{S}$ y eliminar la arista $X - Y$ de G'
    end if
  end for
  $\ell \leftarrow \ell + 1$
until $|\mathrm{Adj}_{G'}(X)| \leq \ell$ para todo $X \in \mathbf{X}$

En la segunda fase, para cada triple no protegido $X - Z - Y$ (con X e Y no adyacentes) se orienta la estructura en v $X \rightarrow Z \leftarrow Y$ si $Z \notin \mathbf{S}_{XY}$. Después, las reglas de **?** propagan orientaciones sin crear ciclos ni nuevas estructuras en v. El resultado no es un DAG único, sino un grafo parcialmente dirigido (CPDAG) que representa la *clase de equivalencia de Markov* de G, es decir, el conjunto de DAG que implican las mismas independencias. Las aristas que quedan sin dirigir no son identificables a partir de datos observacionales. Con un oráculo de independencia perfecto, el PC es correcto y completo, y su coste, exponencial en el número de variables en el peor caso, pasa a ser polinómico cuando el grado del grafo está acotado (**??**).

Estas garantías suponen, sin embargo, un oráculo ideal. En la versión muestral cada decisión es un contraste sujeto a error, y la naturaleza secuencial del algoritmo da lugar a cinco limitaciones que vertebran el resto de la subsección: (i) la falta de garantías cuando el número de variables es comparable o superior al tamaño muestral; (ii) la dependencia del orden de las variables, pues un error temprano modifica los conjuntos de adyacencia sobre los que se plantean los contrastes posteriores; (iii) la pérdida de potencia de los contrastes al crecer $|\mathbf{S}|$, cuyos errores se propagan a la orientación; (iv) el coste de los contrastes en datos de alta dimensión; y (v) la rigidez de los supuestos (datos i.i.d., fidelidad a la d-separación y suficiencia causal), que muchos dominios reales no satisfacen (**??**).

2.1.2 Consistencia en alta dimensión

? respondieron a (i) para datos gaussianos con contrastes de correlación parcial basados en la transformada z de Fisher. Demostraron que el PC muestral estima de forma consistente el esqueleto y el

CPDAG aunque $p = O(n^a)$ para cualquier $a > 0$, siempre que el grafo sea disperso, con grado máximo $q_n = O(n^{1-b})$ y $0 < b \leq 1$, y que el nivel de significación α_n decrezca con n. El coste queda acotado por $O(p^{q_n})$, y en simulaciones el PC alcanzó tasas de descubrimiento verdadero (TDR) superiores a las de búsquedas basadas en BIC, con poca sensibilidad a la elección de α. El resultado exige, no obstante, que las correlaciones parciales no nulas estén acotadas inferiormente por una cota que decrece lentamente con n, una forma de *fidelidad fuerte*. **?** mostraron que, a diferencia de las violaciones de la fidelidad ordinaria, que tienen medida nula, el conjunto de distribuciones que incumplen la fidelidad fuerte tiene medida positiva y crece con el tamaño y la densidad del grafo. Esto explica la fragilidad del PC en muestras finitas incluso cuando sus supuestos asintóticos se cumplen, y motiva las variantes siguientes.

2.1.3 Dependencia del orden

El primer síntoma de esa fragilidad aparece en la orientación. **?** observaron que decidir una estructura en v a partir de un único conjunto separador es especialmente frágil y propusieron el **PC conservador (CPC)**, que solo orienta un triple no protegido si el nodo central aparece en todos sus conjuntos separadores o en ninguno, y lo marca como ambiguo en caso contrario. **?** demostraron después que, en alta dimensión, el problema alcanza también al esqueleto: basta permutar las variables de entrada para obtener esqueletos, estructuras en v y orientaciones muy distintos. Su **PC-stable** congela los conjuntos de adyacencia al inicio de cada nivel ℓ, de modo que las eliminaciones dentro de un nivel no alteran los contrastes de otros pares y el esqueleto deja de depender del orden. Para la orientación combinaron esta idea con CPC (**CPC-stable**) y con una regla de mayoría sobre los conjuntos separadores (**MPC-stable**), y añadieron versiones que registran los conflictos en listas y los representan con aristas bidireccionales (LCPC/LMPC-stable), lo que hace toda la salida independiente del orden. Estas variantes conservan la consistencia en alta dimensión del PC, se extienden a FCI y RFCI, y en datos de expresión génica redujeron la varianza de la distancia de Hamming estructural (SHD) y mejoraron la estimación de efectos causales con IDA. El precio es computacional: al no aprovechar las eliminaciones dentro de cada nivel, PC-stable realiza más contrastes que el PC original, lo que agrava la limitación (iv).

2.1.4 Errores en conjuntos de condicionamiento grandes

Que el resultado no dependa del orden no implica que sea correcto. Cuando $|\mathbf{S}|$ crece, los contrastes pierden potencia y sus errores se trasladan a la orientación. **?** abordaron (iii) para datos discretos desde dos frentes. Por un lado, redujeron el tamaño de los conjuntos de condicionamiento al sustituir los subconjuntos arbitrarios de vecinos por conjuntos de corte mínimos entre X e Y ($CUT_{X,Y}$), calculados con una variante del algoritmo de Ford-Fulkerson. Por otro, reemplazaron el contraste χ^2 por una puntuación bayesiana de Dirichlet (BD), que equilibra mejor los errores de tipo I y II. Completaron el método con una regla que elimina el enlace más débil de los triángulos y un refinamiento voraz final guiado por la puntuación BD, que anticipa los enfoques híbridos. **?** propuso renunciar directamente a los contrastes de orden alto. Definió la **k-equivalencia de Markov**, según la cual dos DAG son equivalentes si implican las mismas independencias con $|\mathbf{S}| \leq k$, la caracterizó mediante *grafos de k-clausura* y diseñó el algoritmo **k-PC**, que aprende esta clase con reglas de orientación inspiradas en FCI. A cambio de una clase de equivalencia menos informativa, k-PC obtuvo en muestras pequeñas mejores F1 en adyacencias y orientaciones que el PC, NOTEARS y LOCI, y en la red *Asia* evitó el grafo excesivamente disperso que producen los contrastes de orden 2 poco fiables.

2.1.5 Escalabilidad computacional

La limitación (iv) se ataca aprovechando que, una vez congeladas las adyacencias como en PC-stable, los contrastes de un mismo nivel son independientes entre sí. **?** paralelizaron la fase de contrastes, que

es con diferencia la más costosa, de dos maneras: con hilos en memoria compartida, agrupando las variables en bloques según diseños de bloques incompletos balanceados (BIB) para reutilizar el cálculo de los estadísticos G^2, y con procesos MPI en memoria distribuida, donde cada proceso gestiona un subconjunto de los casos. **?** mostró en `bnlearn` que el *backtracking*, la optimización clásica que explota la simetría de vecindades y mantas de Markov, degrada la estabilidad a cambio de poca ganancia en velocidad, y propuso un marco paralelo para los algoritmos basados en restricciones que resulta preferible en hardware multinúcleo. **?** desarrollaron **Parallel-PC**, que reparte entre núcleos los contrastes de cada nivel de PC-stable y sincroniza entre niveles, conservando la independencia del orden. En el conjunto DREAM5, con más de 1600 variables, el PC original no terminó en 24 horas, mientras que Parallel-PC lo hizo en menos de seis con ocho núcleos. Estas herramientas se apoyan en implementaciones de referencia como `pcalg` (**?**), que reúne PC, FCI y RFCI, contrastes para datos gaussianos y discretos, conocimiento previo, reglas de orientación conservadoras y la estimación de efectos causales con IDA.

2.1.6 Relajación de supuestos

La limitación (v) ha dado lugar a extensiones que redefinen los datos o el criterio de separación sobre los que opera el PC. Para datos no i.i.d., **?** demostraron que el PC conserva su consistencia en series temporales estacionarias con dependencia de tipo ρ-*mixing* o de mezcla fuerte, incluidos los procesos VARMA y lineales, tanto con correlación parcial como con contrastes HSIC. Propusieron además el **Time-Aware PC (TPC)**, que aprende relaciones entre instantes con retardo y supera al PC y a la causalidad de Granger en datos simulados y en el conjunto hidrológico CauseMe. En la misma línea, PCMCI (**?**) usa una fase de tipo PC para seleccionar condicionantes y un contraste posterior que controla los falsos positivos inducidos por la autocorrelación. Para eventos extremos, **?** estudiaron las redes bayesianas max-lineales, propias de distribuciones de cola pesada, que no son fieles a la d-separación. Probaron que el PC sigue siendo consistente con un oráculo de $*$-separación pese a las independencias adicionales que esta implica, y propusieron **PCstar**, que asume fidelidad a la C-separación ponderada y orienta aristas adicionales en ciertos ciclos, con coste polinómico cuando el grado de entrada está acotado. La relajación de la suficiencia causal mediante FCI y la m-separación se trata en la Sección **??**.

2.1.7 De decisiones discretas a restricciones diferenciables

Todas las variantes anteriores conservan decisiones binarias e irrevocables en cada contraste. **?** propusieron una alternativa con **DAGPA**, que relaja la d-separación a una función diferenciable sobre una matriz de probabilidades de arista mediante una medida de percolación y lógica difusa. Esta función recupera exactamente la d-separación sobre DAG discretos y permite optimizar por gradiente la concordancia entre el grafo y las independencias de los datos, usando los p-valores como etiquetas suaves en lugar de umbrales. El método resultó robusto en muestras pequeñas y superó a las referencias basadas en restricciones y en puntuación sobre el conjunto real de Sachs, lo que lo sitúa en la frontera con los enfoques híbridos de la Sección **??**.

La Tabla **??**, en el Apéndice **??**, resume estas variantes según la limitación que abordan.

2.2 Pruebas de Independencia Condicional y Extensiones para Causalidad

Las pruebas de independencia condicional (IC) constituyen el motor estadístico del aprendizaje estructural basado en restricciones, pues cada decisión de poda y de orientación del esqueleto del grafo se reduce a determinar si dos variables son dependientes o independientes dado un conjunto de condicionamiento (**??**). A diferencia de las funciones de puntuación (score), que evalúan estructuras completas, el contraste IC es una decisión local y contrastable individualmente, lo que explica la interpretabilidad característica de los métodos *constraint-based*, en los que cada arista eliminada o conservada puede rastrearse hasta un conjunto de contrastes estadísticos concreto y sus p-valores (**??**). La Figura **??** resume el criterio de elección entre las familias de contrastes que se describen a continuación.

Formalmente, dada una distribución de probabilidad P sobre un conjunto de variables $\mathbf{X} = (X_1, \ldots, X_n)$, la notación $I(\mathbf{X}, \mathbf{Y} \mid \mathbf{Z})$ denota que los conjuntos $\mathbf{X}$ e $\mathbf{Y}$ son condicionalmente independientes dado $\mathbf{Z}$, esto es, $P(\mathbf{X}, \mathbf{Y} \mid \mathbf{Z}) = P(\mathbf{X} \mid \mathbf{Z})\, P(\mathbf{Y} \mid \mathbf{Z})$. Un contraste de IC procede sobre una muestra finita y confronta la hipótesis nula de independencia condicional $I(\mathbf{X}, \mathbf{Y} \mid \mathbf{Z})$ con la alternativa de dependencia condicional, controlando al nivel α la probabilidad de falso rechazo. La relevancia de estas decisiones radica en su correspondencia con la estructura del grafo, ya que, bajo las condiciones de Markov causal y fidelidad, una distribución es fiel a un DAG G si y solo si, para todo par de conjuntos disjuntos de vértices $\mathbf{X}$, $\mathbf{Y}$ y todo conjunto $\mathbf{Z}$ disjunto de ambos, $I(\mathbf{X}, \mathbf{Y} \mid \mathbf{Z})$ si y solo si $\mathbf{X}$ e $\mathbf{Y}$ están d-separados por $\mathbf{Z}$ (**?**). Expresado matemáticamente:

$$P(X_1, \ldots, X_n) = \prod_{i=1}^{n} P(X_i \mid \mathrm{Pa}(X_i)) \iff \forall\, X, Y, \mathbf{Z} \text{ disjuntos}: \quad I(X, Y \mid \mathbf{Z}) \iff \mathbf{X} \perp_G \mathbf{Y} \mid \mathbf{Z}$$

Los algoritmos explotan esta equivalencia tratando cada resultado de un contraste como un hecho de d-separación, las independencias detectadas eliminan aristas y las dependencias restantes guían la orientación, de modo que la calidad del grafo aprendido queda acotada por la calidad de las decisiones estadísticas (**??**). Los contrastes disponibles se pueden ordenar según la estructura que asumen sobre la dependencia, desde los paramétricos clásicos hasta los no paramétricos, y ninguno es universal, ya que todo contraste restringe implícitamente el tipo de dependencia que puede detectar y paga esa restricción con pérdida de potencia frente al resto de alternativas (**?**). Introduciendo un ejemplo que se desarrollará con más detalle al presentar la correlación parcial. Para $X \sim \mathcal{N}(0, 1)$ e $Y = X^2$ se cumple

$$\mathbb{E}[X^3] = 0 \quad \Longrightarrow \quad \mathrm{corr}(X, Y) = 0 \qquad \text{mientras que} \qquad \neg I(X, Y),$$

de modo que un contraste basado en la correlación parcial no detectaría esta dependencia pese a ser manifiesta.

2.2.1 Correlación parcial

Para datos continuos, el contraste clásico es la **correlación parcial**. Bajo normalidad conjunta, $I(X, Y \mid \mathbf{Z})$ equivale a la anulación de la correlación parcial (**?**). Para cada contraste se toman las observaciones de X, Y y las variables de $\mathbf{Z}$, es decir, $\mathbf{w}_i = (x_i,\, y_i,\, \mathbf{z}_i)$ con $\mathbf{z}_i \in \mathbb{R}^{|\mathbf{Z}|}$, y se calcula su matriz de covarianzas muestral

$$S = \frac{1}{n-1} \sum_{i=1}^{n} \big(\mathbf{w}_i - \bar{\mathbf{w}}\big)\big(\mathbf{w}_i - \bar{\mathbf{w}}\big)^{\top} \;\in\; \mathbb{R}^{(|\mathbf{Z}|+2)\times(|\mathbf{Z}|+2)},$$

cuya inversa, $\hat{K} = S^{-1}$, proporciona la correlación parcial muestral entre X e Y dado $\mathbf{Z}$,

$$\hat{\rho}_{XY\cdot\mathbf{Z}} = \frac{-\hat{K}_{XY}}{\sqrt{\hat{K}_{XX}\,\hat{K}_{YY}}}.$$

El contraste aplica la transformada z de Fisher (**?**) a ese valor muestral,

$$z(r) = \tfrac{1}{2} \ln \frac{1+r}{1-r}, \qquad T = \sqrt{n - |\mathbf{Z}| - 3}\, z(\hat{\rho}_{XY \cdot \mathbf{Z}}),$$

de modo que se rechaza la hipótesis de independencia cuando $|T|$ supera el cuantil $z_{1-\alpha/2}$ de una normal estándar (**?**). Su ventaja principal es el coste, ya que, con la matriz de covarianzas muestral previamente calculada, cada contraste se reduce a invertir el bloque correspondiente, con $O(|\mathbf{Z}|^3)$ operaciones, y sus p-valores son analíticos, sin remuestreo, lo que lo convierte en el contraste habitual para datos continuos en las implementaciones de referencia (**??**), y el que sostiene la consistencia del PC en alta dimensión bajo estructuras poco densas (**??**). Su limitación es simétrica, pues la

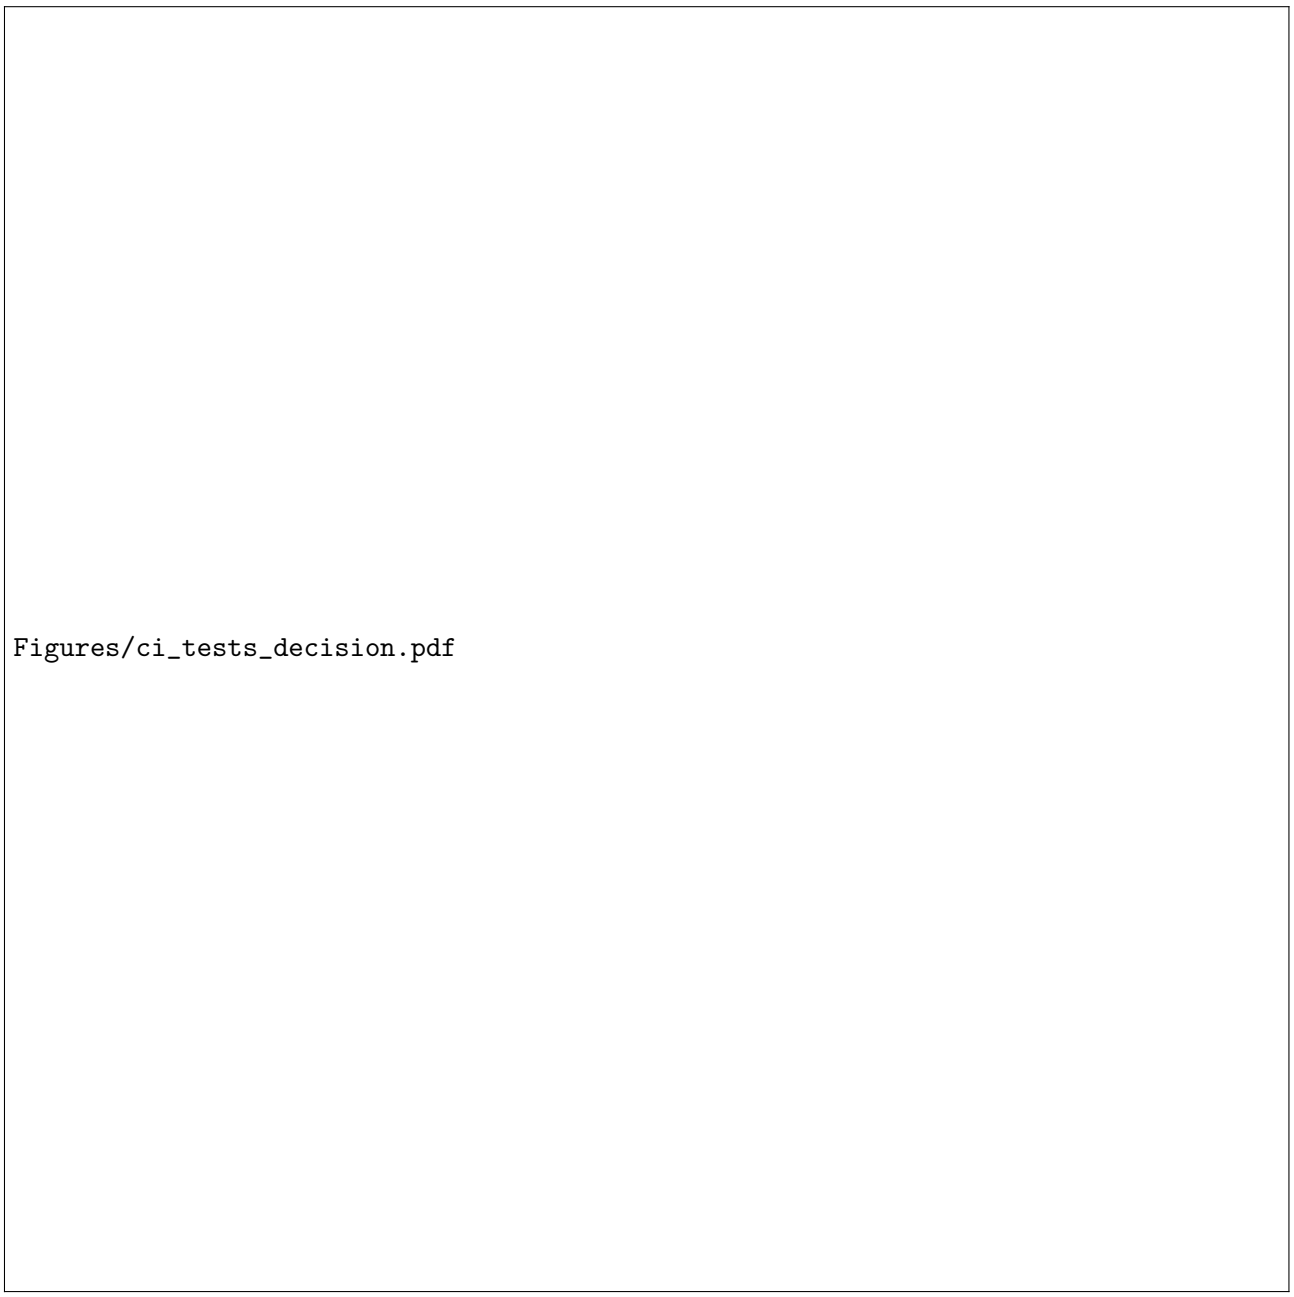


Figura 1: Guía para elegir el contraste de independencia condicional según el tipo de dato, el supuesto sobre la dependencia y el tamaño muestral. La rama *Sí* conduce al contraste recomendado y la rama *No* a su alternativa.

equivalencia entre correlación parcial nula e independencia condicional vale solo bajo normalidad y linealidad, y fuera de ese modelo las variantes de rango únicamente la aproximan (**?**).

Recientes líneas de investigación tratan de dotar de robustez a estos contrastes frente a violaciones parciales del modelo. Cuando la varianza del error no es constante, las versiones ponderadas (WLS) conservan la estructura del contraste y recuperan su calibración (**?**). Cuando la distribución se aleja de la normalidad, los contrastes basados en correlaciones de rango mantienen la consistencia del PC bajo modelos no gaussianos o de cópula gaussiana, con un coste computacional apenas mayor (**?**), y admiten además su extensión a datos mixtos mediante cópulas (**?**). En muestras pequeñas, los esquemas de permutación corrigen la aproximación asintótica del p-valor (**??**).

2.2.2 Tablas de contingencia

Para datos discretos, el contraste clásico es el de **tablas de contingencia**, empleado en los algoritmos de aprendizaje de estructura cuando las variables son categóricas (**?**). Cada celda de la tabla conjunta recoge cuántas observaciones caen en una combinación de valores de X, Y y las variables de $\mathbf{Z}$, y la hipótesis de independencia impone un valor esperado para cada frecuencia. El contraste mide la discrepancia entre los conteos observados y los esperados.

Denotamos por n_{ijk} el número de observaciones de la muestra en las que X toma su valor i, Y su valor j y $\mathbf{Z}$ su k-ésima combinación de valores, y escribimos $n_{i\cdot k}$, $n_{\cdot jk}$ y $n_{\cdot\cdot k}$ para las sumas de n_{ijk} sobre el índice sustituido por el punto. Los esperados bajo independencia se calculan precisamente a partir de esas sumas,

$$E_{ijk} = \frac{n_{i\cdot k}\, n_{\cdot jk}}{n_{\cdot\cdot k}},$$

y los dos estadísticos clásicos son

$$\chi^2 = \sum_{i,j,k} \frac{(n_{ijk} - E_{ijk})^2}{E_{ijk}}, \qquad G^2 = 2 \sum_{i,j,k} n_{ijk} \ln \frac{n_{ijk}}{E_{ijk}}.$$

Ambos se distribuyen asintóticamente como una χ^2_ν con $\nu = (I-1)(J-1)\prod_l K_l$ grados de libertad (**??**), donde K_l es el número de valores de la l-ésima variable de $\mathbf{Z}$, de modo que se rechaza la independencia cuando el estadístico supera el cuantil $\chi^2_{\nu,1-\alpha}$. El estadístico G^2 es la versión discreta del contraste de razón de verosimilitud y es proporcional a la información mutua condicional, $G^2 = 2n\,\hat{\mathrm{I}}(X, Y \mid \mathbf{Z})$, por lo que los contrastes de información mutua (MI) que usan por defecto las implementaciones de referencia pertenecen a esta misma familia (**?**). Para variables ordinales, donde el orden de las categorías es informativo, se incorpora además el contraste de tendencia de Jonckheere–Terpstra en su versión asintótica con corrección por empates, que explota ese orden en lugar de tratar los valores como meras etiquetas (**??**).

Su ventaja es ser el contraste canónico para datos categóricos, con p-valores analíticos y una lectura directa como divergencia entre la tabla observada y la que se esperaría bajo independencia. Cabe destacar que en las simulaciones originales del PC, G^2 condujo al grafo correcto con más frecuencia que χ^2 (**?**). Una de las principales limitaciones es el crecimiento exponencial del número de celdas con respecto a $|\mathbf{Z}|$ y a la cardinalidad de las variables, $I \cdot J \cdot \prod_l K_l$ celdas. Esto hace que los conteos esperados se estimen con pocas observaciones por celda y la aproximación χ^2 deje de ser fiable. Las reglas prácticas exigen un tamaño muestral de al menos cinco veces el número de celdas para estimar con garantías, o asumir dependencia cuando $n < 10\times$ el número de celdas (**?**). El coste de calcular el estadístico es lineal en el número de celdas, pero ese número es justamente el cuello de botella.

Las líneas recientes atacan precisamente esta escasez de datos. **?** propuso una tabla de contingencia suavizada, compatible con cualquier estadístico de tabla, que incorpora *priors* y puede calcularse incluso con bases de datos incompletas, y mostró que mejora la recuperación estructural y reduce la divergencia de KL frente al contraste estándar, incluso con *priors* no informativos y sobre todo con muestras pequeñas o muchas variables. **?** propusieron el estadístico SECMI, una expansión truncada

de la información mutua condicional que mantiene la potencia del contraste cuando $|\mathbf{Z}|$ es grande sin perder el control del error de tipo I. Y en la práctica, la calibración asintótica puede sustituirse por permutaciones o por esquemas semiparamétricos que corrigen el comportamiento en muestra pequeña, tal y como ofrecen las implementaciones de referencia (**??**).

2.2.3 Regresión y métodos de residuos

Otra vía, natural cuando los datos son mixtos, consiste en no modelar la dependencia directamente sino eliminar el efecto de $\mathbf{Z}$ mediante regresión y contrastar la asociación de lo que queda. Se ajustan las regresiones de X y de Y, dadas por las funciones $\hat{m}_X(\mathbf{z}) = \widehat{\mathbb{E}}[X \mid \mathbf{Z} = \mathbf{z}]$ y $\hat{m}_Y(\mathbf{z}) = \widehat{\mathbb{E}}[Y \mid \mathbf{Z} = \mathbf{z}]$, y se toman los residuos $r_i = x_i - \hat{m}_X(\mathbf{z}_i)$ y $s_i = y_i - \hat{m}_Y(\mathbf{z}_i)$. La independencia condicional implica que sus productos $R_i = r_i s_i$ tienen media cero (**?**). La versión general, conocida como medida de covarianza generalizada (GCM), se construye sobre la media muestral $\bar{R}$ de esos productos,

$$T_n = \frac{\sqrt{n}\,\bar{R}}{\hat{\sigma}_R}, \qquad \hat{\sigma}_R^2 = \frac{1}{n}\sum_{i=1}^{n}(R_i - \bar{R})^2,$$

que bajo la hipótesis nula converge a una normal estándar siempre que las regresiones estimen las medias condicionales con el producto de sus errores cuadráticos medios de orden $o(n^{-1})$ (**?**). En el caso lineal y gaussiano este contraste coincide, salvo detalles de normalización, con el de la correlación parcial ya presentado (**?**).

Su ventaja es la flexibilidad, ya que la familia no fija la forma de la dependencia sino la de las medias condicionales, y admite cualquier técnica de regresión, de la lineal y los modelos lineales generalizados para respuestas mixtas a los bosques o los métodos de kernel. Sin embargo, las regresiones no son un elemento neutral en este contraste, ya que el contraste solo puede tener potencia frente a las alternativas que dejan covarianza no nula entre los residuos de las regresiones elegidas, de modo que elegirlas exige conocer el problema que se estudia (**?**). Además, existe un límite teórico más severo. **?** demuestran que, sin restringir la clase nula, ningún contraste que controle uniformemente el nivel de significación alcanza potencia, ni siquiera frente a una única alternativa, y que la potencia solo se recupera restringiendo el problema, como hace la propia GCM al exigir que el producto de los errores cuadráticos medios de sus dos regresiones sea de orden $o(n^{-1})$ (**?**).

? introdujo la medida de covarianza generalizada ponderada (WGCM) que pesa los residuos por la varianza condicional y amplía la clase de alternativas detectables. Esto obliga a ceder algo de potencia en las alternativas que GCM ya cubría bien, y cuando X e Y son categóricos una de sus variantes alcanza potencia frente a todas las alternativas, fuera ya del marco continuo de ese resultado de imposibilidad. Y en el plano de la estimación, los esquemas de validación cruzada del doble machine learning permiten emplear regresiones flexibles sin que su sobreajuste contamine la calibración del contraste (**?**).

2.2.4 Métodos no paramétricos

Los contrastes no paramétricos no fijan ni la forma de la dependencia ni la de las medias condicionales. Los basados en kernel parten de una caracterización de la independencia según la cual dos variables son independientes si y solo si ninguna función de una covaría con ninguna función de la otra, y resume esa condición en una única medida, el criterio HSIC (**?**). Su extensión al caso condicional es el contraste KCI, que elimina el efecto de $\mathbf{Z}$ mediante regresiones no paramétricas y aplica una medida del mismo tipo a lo que queda. Su distribución nula se genera por simulación de Monte Carlo o se aproxima por una gamma de dos parámetros (**?**). De forma alternativa, la información mutua condicional se estima directamente con un estimador de vecinos más cercanos y el contraste se calibra con permutaciones locales (**?**).

Su ventaja es no asumir forma funcional alguna, lo que les permite captar dependencias no lineales, y con densidades no suaves el estimador por vecinos supera en potencia a los métodos de kernel (**?**). Además, los de kernel se propusieron para domar la maldición de la dimensionalidad que vacía las tablas de contingencia cuando $|\mathbf{Z}|$ crece. Por otro lado, el coste de KCI está dominado por la inversión y la descomposición de matrices de kernel grandes y crece al menos cuadráticamente con el tamaño muestral, lo que lo hace inviable en muestras grandes (**?**), y las aproximaciones analíticas de su distribución nula no están bien calibradas por debajo del millar de muestras, aunque las permutaciones mejoran la calibración a costa de potencia (**?**). Las relajaciones RCIT y RCoT aproximan KCI sustituyendo los kernels por características de Fourier aleatorias, pasan a coste lineal en n y devuelven p-valores precisos mucho más rápido que el contraste original, con grafos al menos tan precisos en los algoritmos de descubrimiento (**?**).

La familia sigue creciendo por dos vías, la estadística y la calibración. En la estadística, los contrastes *distribution-free* fijan la distribución nula sin depender de las distribuciones de los datos, y su índice, que se anula si y solo si hay independencia condicional, tiene potencia frente a alternativas fijas y se calcula en tiempo cuadrático (**?**). En la calibración, el contraste de **?** conserva la estadística de kernel y calibra con una permutación aprendida, que transforma el problema en un contraste de dos muestras de kernel entre la muestra permutada y la original, gana una potencia competitiva y estima mejor la distribución nula a medida que crece $|\mathbf{Z}|$.

2.2.5 Extensiones para causalidad

Las garantías recogidas hasta aquí valen para un contraste aislado, pero el producto de un método basado en restricciones es el de una cadena de ellos. Estos métodos eliminan y orientan aristas a partir de una serie de contrastes de independencia (**??**), y en esa cadena ni el nivel de significación ni la potencia miden el error de la búsqueda salvo en muestras muy grandes, pues la probabilidad de rechazar alguna hipótesis verdadera no viene dada por el nivel del contraste, puede superarlo con creces y depende del número de contrastes y de la estructura que el algoritmo recorre (**?**). El efecto se deja ver también degradando la propia propagación, una eliminación errónea de una arista altera los conjuntos de adyacencia que atraviesan los contrastes siguientes, inhibe contrastes que hubieran salvado la arista y arrastra tanto el esqueleto como las estructuras en v (**?**). La única garantía disponible es asintótica, la consistencia del esqueleto exige un nivel α_n que decaiga con el tamaño muestral, y con él el error de la versión muestral se acota exponencialmente (**?**). El resto del apartado desarrolla las dos direcciones en que la independencia condicional se ha hecho causal, la generalización de los criterios de separación y la relajación de los escenarios en los que se aplican.

La primera dirección de avance generaliza los criterios topológicos que vinculan la independencia estadística con el modelo causal subyacente. Cuando el sistema presenta mecanismos no lineales y ciclos, la d-separación clásica resulta teóricamente insuficiente. Para abordarlo, **?** introdujeron los modelos causales estructurales modulares y el criterio de *σ-separación*, justificando el descubrimiento causal bajo retroalimentación. Paralelamente, frente a variables latentes y sesgo de selección, el criterio de *m-separación* sobre grafos ancestrales (MAGs y PAGs) formaliza la inferencia causal relajando el supuesto de suficiencia (**?**). Unificando ambos retos, **?** demostraron recientemente que las reglas lógicas de orientación topológica (como las del FCI) mantienen su corrección e integridad asintótica incluso en sistemas cíclicos.

La segunda dirección flexibiliza los supuestos sobre el origen y la naturaleza de las observaciones. Para resolver la integración de conjuntos de datos heterogéneos, marcos como COmbINE (**?**) extienden los contrastes de independencia condicionando sobre variables indicadoras de contexto. Esto permite unificar experimentos observacionales e intervencionales parcialmente solapados para inferir estructuras globales inidentificables de forma aislada. En el dominio dinámico, **?** formularon pruebas de independencia condicional específicas para trayectorias continuas en Redes Bayesianas de Tiempo Continuo (CTBN), logrando orientar transiciones causales explotando matemáticamente la asimetría

estricta del tiempo físico.

En síntesis, estas extensiones dotan a las pruebas de independencia de semántica causal plena frente a ciclos, latentes y temporalidad. Sin embargo, la vulnerabilidad inherente al encadenamiento de contrastes locales en muestras finitas, donde un solo error estadístico altera irremediablemente los conjuntos de condicionamiento posteriores, permanece intacta. Esta fragilidad estructural para propagar errores constituye la motivación central de los enfoques híbridos explorados a continuación, que buscan reconciliar la alta expresividad causal de las restricciones topológicas con la robustez de la optimización global basada en puntuación.

2.3 Enfoques híbridos de aprendizaje estructural y líneas futuras

Los métodos basados en restricciones (*constraint-based*) presentan limitaciones debido a su dependencia de las pruebas estadísticas de independencia condicional, cuyo número puede crecer considerablemente con la cantidad de variables y la densidad de la red. Asimismo, los errores estadísticos cometidos durante las primeras etapas del aprendizaje pueden propagarse a decisiones posteriores y comprometer la precisión de la estructura resultante. Por otra parte, los métodos basados en puntuaciones (*score-based*) se enfrentan a la elevada complejidad del espacio de búsqueda, lo que suele requerir estrategias heurísticas que no garantizan alcanzar el óptimo global y cuyos resultados pueden depender de la solución inicial. Ante estas limitaciones, los métodos híbridos combinan técnicas de ambos enfoques para aprovechar sus respectivas fortalezas y mejorar potencialmente tanto la eficiencia del aprendizaje estructural como la calidad de las estructuras obtenidas (**?**). Esta integración puede adoptar distintas formas, desde restringir el espacio de búsqueda antes de la optimización hasta combinar información estadística y puntuaciones en diferentes fases del aprendizaje.

2.3.1 Evolución de los métodos híbridos

Una de las principales estrategias híbridas es el enfoque *Restrict/Maximise* (**?**). En este esquema, primero se emplean procedimientos basados en restricciones para obtener información sobre las relaciones entre variables y acotar el espacio de búsqueda. Posteriormente, se aplica un algoritmo *score-based* para buscar una estructura de elevada puntuación dentro del espacio delimitado. Esta combinación puede reducir el número de estructuras que deben evaluarse y, con ello, mejorar la eficiencia computacional del aprendizaje.

Una de las primeras propuestas de este tipo fue el algoritmo *Constraint-Bayesian* (CB), presentado por **?**, que combina PC y K2 (**?**). CB emplea pruebas de independencia condicional para obtener un grafo parcialmente dirigido, a partir del cual determina una ordenación de las variables que posteriormente utiliza K2 para construir la red bayesiana. El método alterna iterativamente ambas fases e incrementa progresivamente el tamaño máximo de los conjuntos condicionantes hasta que la puntuación de la estructura deja de mejorar. Sin embargo, el coste de las pruebas de independencia, la sensibilidad a la ordenación obtenida y la naturaleza voraz de K2 introducen limitaciones tanto en la eficiencia como en la calidad de las estructuras aprendidas.

Posteriormente, **?** propusieron *Sparse Candidate*, orientado a mejorar la escalabilidad mediante la restricción de los posibles padres de cada variable. A diferencia de CB, que limita la búsqueda de K2 a través de una ordenación, *Sparse Candidate* selecciona directamente un conjunto reducido de padres candidatos mediante criterios estadísticos de relevancia y dependencia. A continuación, realiza una búsqueda basada en puntuaciones restringida a esos candidatos, implementada mediante *Hill-Climbing* con lista tabú en el trabajo original. El procedimiento es iterativo: utiliza la estructura aprendida para actualizar los conjuntos de candidatos y refinar la búsqueda. En sus experimentos, los autores observaron reducciones del coste computacional frente a búsquedas no restringidas, con puntuaciones comparables. No obstante, una selección inadecuada puede excluir relaciones relevantes y limitar la calidad de la estructura final.

? propusieron el algoritmo *Max-Min Hill-Climbing* (MMHC), que desarrolla la estrategia de selección de relaciones candidatas mediante pruebas de independencia condicional. En su primera etapa utiliza *Max-Min Parents and Children* (MMPC), un procedimiento que identifica posibles padres e hijos de cada variable para estimar el esqueleto de la red. Posteriormente, una búsqueda *Hill-Climbing* basada en puntuaciones construye un DAG y restringe la incorporación de aristas a las relaciones identificadas previamente. A diferencia de *Sparse Candidate*, MMHC no exige fijar un número máximo común de candidatos ni alternar iterativamente las fases de restricción y optimización, lo que permite adaptar los conjuntos de candidatos a la conectividad local. Los experimentos originales mostraron ventajas en distintas medidas de eficiencia y recuperación estructural frente a *Sparse Candidate*. No obstante, el resultado sigue dependiendo de la calidad de la primera etapa, mientras que la búsqueda heurística no garantiza alcanzar una estructura óptima.

2.3.2 Mejoras en la selección y aplicación de restricciones

Con el objetivo de reducir el impacto de los errores cometidos durante la fase de restricción, **?** propusieron el algoritmo *Hybrid HPC* (H2PC), que sustituye MMPC por *Hybrid Parents and Children* (HPC). Este procedimiento combina técnicas de aprendizaje local para mejorar la identificación de relaciones candidatas, prestando especial atención a la reducción de falsos negativos, que impedirían recuperar determinadas aristas durante la optimización posterior. En los experimentos originales, H2PC mejoró la calidad estructural respecto a MMHC, aunque a costa de un mayor tiempo de ejecución. Estos resultados ponen de manifiesto un compromiso central de los métodos *Restrict/Maximise*: una restricción excesiva puede descartar relaciones verdaderas, mientras que una selección más permisiva amplía las posibilidades de recuperación, pero también el coste de la búsqueda.

Otra línea de investigación ha estudiado los problemas derivados de mantener restricciones rígidas durante la optimización. En este sentido, **?** demostraron que restringir una búsqueda basada en puntuaciones a un esqueleto previamente estimado puede comprometer la consistencia del aprendizaje, incluso cuando se dispone del esqueleto correcto. Para abordar este problema, propusieron *Adaptively Restricted Greedy Equivalence Search* (ARGES), una modificación de GES (**?**) que busca sobre clases de equivalencia de Markov y permite incorporar determinadas aristas inicialmente excluidas según la configuración del grafo durante la búsqueda. Bajo los supuestos establecidos en el artículo, los autores demostraron garantías de consistencia tanto en el escenario clásico como en determinados escenarios de alta dimensionalidad. Así, ARGES muestra que no solo importa la calidad de las restricciones iniciales, sino también la flexibilidad con la que se aplican durante la optimización.

2.3.3 Estrategias alternativas

Además de los métodos *Restrict/Maximise*, existen otras estrategias que combinan procedimientos *constraint-based* y *score-based* sin reducir necesariamente el espacio de búsqueda antes de optimizarlo (**?**). Una posibilidad consiste en utilizar una búsqueda basada en puntuaciones para obtener una estructura inicial y refinarla después mediante pruebas de independencia condicional. Este planteamiento aparece en *Greedy Fast Causal Inference* (GFCI), propuesto por **?** para el descubrimiento causal cuando pueden existir variables latentes. Los procedimientos basados en puntuaciones como GES suelen trabajar bajo el supuesto de suficiencia causal, mientras que algoritmos basados en restricciones como FCI (**?**) o RFCI (**?**) admiten causas comunes no observadas, aunque pueden presentar dificultades de precisión con muestras reducidas. GFCI ejecuta primero *Fast Greedy Search* (FGS), una implementación eficiente de GES, para obtener una estructura inicial representada mediante un CPDAG; después aplica pruebas de independencia condicional y reglas de orientación relacionadas con FCI para refinar las adyacencias y obtener un *Partial Ancestral Graph* (PAG). En los experimentos originales se observaron mejoras en distintas medidas de recuperación y precisión frente a FCI, RFCI y FCI+, aunque con un coste computacional superior al de RFCI. La aportación de GFCI va más

allá de reducir la búsqueda: combina ambos paradigmas para aprender representaciones causales que contemplan posibles variables no observadas.

Durante el aprendizaje estructural, especialmente con un número reducido de observaciones, algunos procedimientos pueden producir redes con componentes desconectadas, entre las que la evidencia no puede propagarse. Esto puede resultar problemático en dominios donde se espera que las variables formen parte de una misma estructura conectada. Para abordar esta situación, **?** propuso *SaiyanH*, que incorpora explícitamente ese supuesto de conectividad. El algoritmo comienza construyendo un grafo no dirigido y conectado mediante medidas estadísticas de asociación entre variables. Posteriormente, orienta sus aristas combinando pruebas de independencia condicional, funciones de puntuación y criterios basados en efectos de intervención. Finalmente, aplica una búsqueda *Hill-Climbing* con memoria tabú, restringida por las independencias identificadas y por la necesidad de conservar la conectividad. Los experimentos mostraron resultados competitivos en diversas medidas de calidad estructural; sin embargo, imponer una estructura conectada puede introducir relaciones espurias cuando ese supuesto no se ajusta al dominio.

2.3.4 Avances recientes

Pese a los avances anteriores, el aprendizaje estructural híbrido sigue afrontando dificultades relacionadas con el coste de identificar relaciones estructurales y con la complejidad de optimizar sobre el espacio de grafos. Investigaciones recientes han explorado mejoras tanto en la eficiencia del aprendizaje del esqueleto como en los procedimientos utilizados para buscar estructuras de alta puntuación.

En esta línea, **?** propusieron el algoritmo ESLH, orientado a reducir el coste de las pruebas de independencia condicional durante el aprendizaje estructural. Para ello, incorpora una estrategia de umbrales dinámicos (DTH) que permite descartar relaciones poco prometedoras y un procedimiento de aprendizaje del esqueleto basado en la eliminación de triángulos (SLTB), diseñado para reducir el número de pruebas necesarias. Posteriormente, emplea una búsqueda *Hill-Climbing* dividida en tres etapas, que aprovecha el esqueleto aprendido sin depender exclusivamente de él para limitar el efecto de posibles errores. En los experimentos originales, ESLH obtuvo mejoras de eficiencia frente a los métodos comparados y mantuvo una precisión estructural competitiva. Esta propuesta ilustra cómo los desarrollos recientes intentan combinar un aprendizaje de restricciones menos costoso con una optimización menos vulnerable a sus errores.

Mientras que ESLH se centra principalmente en mejorar el aprendizaje del esqueleto, otras propuestas han estudiado alternativas a las búsquedas voraces, que pueden quedar atrapadas en óptimos locales. En esta dirección, **?** propusieron *Self-Awakened Particle Swarm Optimization* (SAPSO), que combina restricciones estadísticas basadas en información mutua con una adaptación al aprendizaje estructural de *Particle Swarm Optimization* (PSO) (**?**). El método utiliza un árbol de expansión de peso máximo y medidas de dependencia para orientar la inicialización y restringir el espacio de búsqueda. Después, representa las partículas mediante DAGs y adapta sus actualizaciones al carácter discreto de las modificaciones de aristas, utilizando el criterio BIC (**?**) para evaluar las estructuras. Incorpora, además, un mecanismo *self-awakened* que introduce nuevas soluciones cuando la población se estanca, con el objetivo de mitigar la convergencia prematura. Los experimentos mostraron mejoras en algunas medidas de calidad y eficiencia frente a varios métodos de referencia, aunque su evaluación se limitó a dos redes, lo que dificulta generalizar los resultados.

2.3.5 Limitaciones y desafíos abiertos

La combinación de procedimientos *constraint-based* y *score-based* no garantiza, por sí sola, un rendimiento superior al de los enfoques tradicionales. En este sentido, **?** realizó un estudio comparativo de catorce algoritmos de las tres familias, evaluados sobre cinco estructuras simuladas y distintos tamaños muestrales mediante métricas como MCC, F1 y SHD. En las condiciones estudiadas, ninguna familia dominó sistemáticamente al resto, y métodos híbridos como MMHC y H2PC obtuvieron resultados inferiores a

los de algunos procedimientos basados exclusivamente en restricciones. El rendimiento también varió según la topología, el número de observaciones y la métrica utilizada. Aunque estas conclusiones se limitan al diseño experimental considerado, subrayan la importancia de realizar comparaciones bajo escenarios variados antes de atribuir ventajas generales a una estrategia de aprendizaje.

En conjunto, la literatura revisada identifica varios desafíos aún relevantes. El primero es equilibrar la reducción del espacio de búsqueda con la conservación de relaciones verdaderas, especialmente cuando las pruebas de independencia condicional son poco fiables por la escasez de datos (**??**). También sigue siendo necesario mejorar la escalabilidad y la exploración del espacio de estructuras sin incrementar excesivamente el coste computacional (**??**). A ello se añade la dificultad de mantener garantías de aprendizaje bajo supuestos causales menos restrictivos, por ejemplo, cuando existen variables latentes (**??**). En definitiva, el reto no consiste únicamente en combinar técnicas basadas en restricciones y puntuaciones, sino en determinar cómo integrarlas de manera eficiente y robusta según las características de los datos y los supuestos del problema.

3 Conclusiones y líneas futuras

Propias.

A Resumen de variantes del algoritmo PC

Table 1: Principales variantes y extensiones del algoritmo PC, agrupadas según la limitación que abordan (numeración de la Sección **??**).

Variante	**Aportación principal**	**Garantías / coste**
Algoritmo de partida		
PC **?**	Poda del grafo completo con contrastes de orden creciente; orientación de estructuras en v y reglas de **?**; devuelve un CPDAG.	Correcto y completo con oráculo; polinómico si el grado está acotado.
(i) Garantías en alta dimensión		
PC muestral gaussiano **?**	Correlación parcial con z de Fisher y nivel $\alpha_n \to 0$.	Consistente con $p = O(n^a)$ y grafos dispersos; exige fidelidad fuerte (**?**).
(ii) Dependencia del orden		
CPC **?**	Orienta un triple solo si todos sus conjuntos separadores coinciden; si no, lo marca como ambiguo.	Menos errores de orientación, salida menos informativa.
PC-stable **?**	Congela las adyacencias al inicio de cada nivel ℓ.	Esqueleto independiente del orden; más contrastes.
CPC-, MPC-, LCPC-, LMPC-stable **?**	Orientación conservadora, por mayoría o con listas de conflictos y aristas bidireccionales; extensión a FCI y RFCI.	Salida completa independiente del orden; consistencia en alta dimensión.
(iii) Errores con conjuntos de condicionamiento grandes		
PC con cortes mínimos y BD **?**	Conjuntos de corte mínimos ($CUT_{X,Y}$), contraste bayesiano BD, resolución de triángulos y refinamiento voraz.	Datos discretos; mejora empírica en muestras finitas.
k**-PC** **?**	Solo contrastes con $\lvert\mathbf{S}\rvert \leq k$; aprende la clase de k-equivalencia mediante grafos de k-clausura.	Clase menos fina; más robusto en muestras pequeñas.
(iv) Coste computacional		
PC paralelo (BIB / MPI) **?**	Hilos con diseños de bloques incompletos balanceados y procesos MPI sobre subconjuntos de casos.	Aceleración significativa en datos grandes.
`bnlearn` **paralelo** **?**	Marco paralelo para algoritmos basados en restricciones como alternativa al *backtracking*.	Más estable y rápido en hardware multinúcleo.
Parallel-PC **?**	Reparte entre núcleos los contrastes de cada nivel de PC-stable.	Independiente del orden; DREAM5 de $> 24\,\text{h}$ a $< 6\,\text{h}$.
(v) Relajación de supuestos		
TPC **?**	PC para series temporales con relaciones retardadas y contemporáneas; contrastes de Pearson y HSIC.	Consistente bajo ρ-*mixing* y mezcla fuerte.
PCMCI **?**	Selección de condicionantes de tipo PC seguida de un contraste MCI.	Controla falsos positivos por autocorrelación.
PCstar **?**	Redes max-lineales (eventos extremos); fidelidad a la C-separación.	Orienta aristas adicionales; polinómico con grado de entrada acotado.
Decisiones suaves		
DAGPA **?**	d-separación diferenciable por percolación; optimización por gradiente con p-valores como etiquetas suaves.	Robusto en muestras pequeñas; puente hacia los híbridos.

References

Joaquín Abellán, Manuel Gómez-Olmedo, and Serafín Moral. Some variations on the PC algorithm. In *Proceedings of the Third European Workshop on Probabilistic Graphical Models (PGM 2006)*, pages 1–8, Granada, Spain, 2006.

Carlos Améndola, Benjamin Hollering, and Francesco Nowell. A PC algorithm for max-linear Bayesian networks. *Journal of Computational and Graphical Statistics*, pages 1–12, 2026. doi: 10.1080/10618600.2026.2673046.

T.W. Anderson. *An Introduction to Multivariate Statistical Analysis*. Wiley Series in Probability and Statistics. Wiley, 2003. ISBN 9780471360919.

Pavel Averin, Theodoros Moysiadis, and Ioannis Katakis. Conditional independence tests for constraint-based causal discovery: A survey. *Transactions on Machine Learning Research*, 2026. arXiv:2608.11156.

Kunihiro Baba, Ritei Shibata, and Masaaki Sibuya. Partial correlation and conditional correlation as measures of conditional independence. *Australian & New Zealand Journal of Statistics*, 46(4): 657–664, 2004.

Rahul Biswas and Somabha Mukherjee. Consistent causal inference from time series with PC algorithm and its time-aware extension. *Statistics and Computing*, 34(1):14, 2024. doi: 10.1007/s11222-023-10330-3.

Zhanrui Cai, Runze Li, and Yaowu Zhang. A distribution free conditional independence test with applications to causal discovery. *Journal of Machine Learning Research*, 23(85):1–41, 2022.

Victor Chernozhukov, Denis Chetverikov, Mert Demirer, Esther Duflo, Christian Hansen, Whitney Newey, and James Robins. Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1):C1–C68, 2018. doi: 10.1111/ectj.12097.

David Maxwell Chickering. Optimal structure identification with greedy search. 2002. URL `https://www.jmlr.org/papers/v3/chickering02b.html`.

Diego Colombo and Marloes H. Maathuis. Order-independent constraint-based causal structure learning. *Journal of Machine Learning Research*, 15:3921–3962, 2014.

Diego Colombo, Marloes H. Maathuis, Markus Kalisch, and Thomas S. Richardson. Learning high-dimensional directed acyclic graphs with latent and selection variables. 2012. doi: 10.1214/11-AOS940.

Anthony C. Constantinou. Learning Bayesian networks that enable full propagation of evidence. *IEEE Access*, 8:124845–124856, 2020. doi: 10.1109/ACCESS.2020.3006472.

Gregory F. Cooper and Edward Herskovits. A bayesian method for the induction of probabilistic networks from data. 1992. doi: 10.1007/BF00994110.

Ruifei Cui, Perry Groot, and Tom Heskes. Copula PC algorithm for causal discovery from mixed data. In *Machine Learning and Knowledge Discovery in Databases (ECML PKDD)*, pages 377–392. Springer, 2016.

Denver Dash. Robust independence testing for constraint-based learning of causal structure. In *Proceedings of the 19th Conference on Uncertainty in Artificial Intelligence (UAI)*, pages 167–174. Morgan Kaufmann, 2003.

Gary Doran, Krikamol Muandet, Kun Zhang, and Bernhard Schölkopf. A permutation-based kernel conditional independence test. In *UAI*, pages 132–141, 2014.

Patrick Forré and Joris M. Mooij. Constraint-based causal discovery for non-linear structural causal models with cycles and latent confounders. arXiv preprint, 2018.

Nir Friedman, Iftach Nachman, and Dana Pe'er. Learning Bayesian network structure from massive datasets: The sparse candidate algorithm. In *Proceedings of the Fifteenth Conference on Uncertainty in Artificial Intelligence (UAI)*, pages 206–215. Morgan Kaufmann, 1999.

Maxime Gasse, Alex Aussem, and Haytham Elghazel. A hybrid algorithm for Bayesian network structure learning with application to multi-label learning. *Expert Systems with Applications*, 41 (15):6755–6772, 2014. doi: 10.1016/j.eswa.2014.04.032.

Clark Glymour, Kun Zhang, and Peter Spirtes. Review of causal discovery methods based on graphical models. *Frontiers in Genetics*, 10:524, 2019. doi: 10.3389/fgene.2019.00524.

Arthur Gretton, Olivier Bousquet, Alex Smola, and Bernhard Schölkopf. Measuring statistical dependence with hilbert-schmidt norms. In *International conference on algorithmic learning theory*, pages 63–77. Springer, 2005.

Wiebke Günther, Urmi Ninad, Jonas Wahl, and Jakob Runge. Conditional independence testing with heteroskedastic data and applications to causal discovery. In *Advances in Neural Information Processing Systems*, volume 35, pages 16191–16202, 2022.

Naftali Harris and Mathias Drton. Pc algorithm for gaussian copula graphical models, 2012. URL `https://arxiv.org/abs/1207.0242`.

Harold Hotelling. New light on the correlation coefficient and its transforms. *Journal of the Royal Statistical Society. Series B (Methodological)*, 15(2):193–232, 1953.

Aimable Robert Jonckheere. A distribution-free k-sample test against ordered alternatives. *Biometrika*, 41(1/2):133–145, 1954.

Markus Kalisch and Peter Bühlmann. Estimating high-dimensional directed acyclic graphs with the pc-algorithm. *Journal of Machine Learning Research*, 8:613–636, 2007.

Markus Kalisch, Martin Mächler, Diego Colombo, Marloes H. Maathuis, and Peter Bühlmann. Causal inference using graphical models with the R package pcalg. *Journal of Statistical Software*, 47(11): 1–26, 2012. doi: 10.18637/jss.v047.i11.

Tugay Karadag. Performance evaluation of Bayesian network learning algorithms in structural equation modeling: A simulation study. *Entropy*, 28(9):955, 2026. doi: 10.3390/e28090955.

James Kennedy and Russell Eberhart. Particle swarm optimization. In *Proceedings of the IEEE International Conference on Neural Networks*, 1995. doi: 10.1109/ICNN.1995.488968.

Neville Kenneth Kitson, Anthony C Constantinou, Zhigao Guo, Yang Liu, and Kiattikun Chobtham. A survey of bayesian network structure learning. *Artificial Intelligence Review*, 56(8):8721–8814, 2023.

Murat Kocaoglu. Characterization and learning of causal graphs with small conditioning sets. In *Advances in Neural Information Processing Systems*, volume 36, pages 74140–74179, 2023. doi: 10.52202/075280-3244.

Mariusz Kubkowski, Jan Mielniczuk, and Paweł Teisseyre. How to gain on power: novel conditional independence tests based on short expansion of conditional mutual information. *Journal of Machine Learning Research*, 22(62):1–57, 2021.

Steffen L. Lauritzen. *Graphical Models*. Oxford University Press, Oxford, 1996.

Thuc Duy Le, Tao Hoang, Jiuyong Li, Lin Liu, Huawen Liu, and Shu Hu. A fast PC algorithm for high dimensional causal discovery with multi-core PCs. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, 16(5):1483–1495, 2019. doi: 10.1109/TCBB.2016.2591526. Publicado en línea en 2016.

Pierre Legendre. Comparison of permutation methods for the partial correlation and partial mantel tests. *Journal of statistical computation and simulation*, 67(1):37–73, 2000.

Kun Liu, Peiran Li, Yu Zhang, Jia Ren, Xianyu Wang, and Uzair Aslam Bhatti. Self-awakened particle swarm optimization BN structure learning algorithm based on search space constraint. *Computers, Materials & Continua*, 76(3):3257–3274, 2023. doi: 10.32604/cmc.2023.039430.

Anders L. Madsen, Frank Jensen, Antonio Salmer'on, Helge Langseth, and Thomas D. Nielsen. A parallel algorithm for Bayesian network structure learning from large data sets. *Knowledge-Based Systems*, 117:46–55, 2017.

Christopher Meek. Causal inference and causal explanation with background knowledge. In *Proceedings of the Eleventh Conference on Uncertainty in Artificial Intelligence (UAI)*, pages 403–410, 1995.

Joris M Mooij and Tom Claassen. Constraint-based causal discovery using partial ancestral graphs in the presence of cycles. In *Conference on Uncertainty in Artificial Intelligence*, pages 1159–1168. Pmlr, 2020.

Preetam Nandy, Alain Hauser, and Marloes H. Maathuis. High-dimensional consistency in score-based and hybrid structure learning. *The Annals of Statistics*, 46(6A):3151–3183, 2018. doi: 10.1214/17-AOS1654.

Juan Miguel Ogarrio, Peter Spirtes, and Joe Ramsey. A hybrid causal search algorithm for latent variable models. In *Proceedings of the Eighth International Conference on Probabilistic Graphical Models*, pages 368–379. PMLR, 2016. URL `https://proceedings.mlr.press/v52/ogarrio16.html`.

Judea Pearl. *Causality: Models, Reasoning, and Inference*. Cambridge University Press, New York, 2 edition, 2009.

Joseph Ramsey, Jiji Zhang, and Peter Spirtes. Adjacency-faithfulness and conservative causal inference. In *Proceedings of the Twenty-Second Conference on Uncertainty in Artificial Intelligence (UAI)*, pages 401–408, 2006.

Thomas Richardson and Peter Spirtes. Ancestral graph markov models. *The Annals of Statistics*, 30 (4):962–1030, 2002.

Jakob Runge. Conditional independence testing based on a nearest-neighbor estimator of conditional mutual information. In *International conference on artificial intelligence and statistics*, pages 938–947. Pmlr, 2018.

Jakob Runge, Peer Nowack, Marlene Kretschmer, Seth Flaxman, and Dino Sejdinovic. Detecting and quantifying causal associations in large nonlinear time series datasets. *Science Advances*, 5(11): eaau4996, 2019.

Mauro Scanagatta, Antonio Salmerón, and Fabio Stella. A survey on bayesian network structure learning from data. *Progress in Artificial Intelligence*, 8:425–439, 2019. doi: 10.1007/s13748-019-00194-y.

Cyrill Scheidegger, Julia Hörrmann, and Peter Bühlmann. The weighted generalised covariance measure. *Journal of Machine Learning Research*, 23(273):1–68, 2022.

Gideon Schwarz. Estimating the dimension of a model. 1978. doi: 10.1214/aos/1176344136.

Marco Scutari. Learning Bayesian networks with the bnlearn R package. *Journal of Statistical Software*, 35(3):1–22, 2010. doi: 10.18637/jss.v035.i03.

Marco Scutari. Bayesian network constraint-based structure learning algorithms: Parallel and optimized implementations in the bnlearn R package. *Journal of Statistical Software*, 77(2):1–20, 2017. doi: 10.18637/jss.v077.i02.

Rajen D. Shah and Jonas Peters. The hardness of conditional independence testing and the generalised covariance measure. *The Annals of Statistics*, 48(3):1514–1538, 2020. ISSN 2168-8966. doi: 10.1214/19-aos1857. URL `http://dx.doi.org/10.1214/19-AOS1857`.

Moninder Singh and Marco Valtorta. An algorithm for the construction of Bayesian network structures from data. In *Proceedings of the Ninth Conference on Uncertainty in Artificial Intelligence (UAI)*, pages 259–265. Morgan Kaufmann, 1993. doi: 10.1016/B978-1-4832-1451-1.50036-6.

Peter Spirtes and Clark Glymour. An algorithm for fast recovery of sparse causal graphs. *Social Science Computer Review*, 9(1):62–72, 1991.

Peter Spirtes, Christopher Meek, and Thomas S. Richardson. Causal inference in the presence of latent variables and selection bias. In *Proceedings of the Eleventh Conference on Uncertainty in Artificial Intelligence*, 1995. URL `https://mlanthology.org/uai/1995/spirtes1995uai-causal/`.

Peter Spirtes, Clark Glymour, and Richard Scheines. *Causation, Prediction, and Search*. MIT Press, Cambridge, MA, 2000.

Eric V Strobl, Kun Zhang, and Shyam Visweswaran. Approximate kernel-based conditional independence tests for fast non-parametric causal discovery. *Journal of Causal Inference*, 7(1):20180017, 2019.

Teunis J Terpstra. The asymptotic normality and consistency of Kendall's test against trend, when ties are present in one ranking. *Indagationes Mathematicae*, 14(3):327–333, 1952.

Sofia Triantafillou and Ioannis Tsamardinos. Constraint-based causal discovery from multiple interventions over overlapping variable sets. *The Journal of Machine Learning Research*, 16(1):2147–2205, 2015.

Ioannis Tsamardinos and Giorgos Borboudakis. Permutation testing improves bayesian network learning. In *Joint European conference on machine learning and knowledge discovery in databases*, pages 322–337. Springer, 2010.

Ioannis Tsamardinos, Laura E. Brown, and Constantin F. Aliferis. The max-min hill-climbing Bayesian network structure learning algorithm. *Machine Learning*, 65(1):31–78, 2006.

Caroline Uhler, Garvesh Raskutti, Peter Bühlmann, and Bin Yu. Geometry of the faithfulness assumption in causal inference. *The Annals of Statistics*, 41(2):436–463, 2013.

Simone Villa and Fabio Stella. Learning continuous time bayesian networks in non-stationary domains. *Journal of Artificial Intelligence Research*, 57:1–37, 2016.

Niantai Wang, Haoran Liu, Liyue Zhang, Yanbin Cai, and Qianrui Shi. An efficient skeleton learning approach-based hybrid algorithm for identifying Bayesian network structure. *Engineering Applications of Artificial Intelligence*, 133:108105, 2024. doi: 10.1016/j.engappai.2024.108105.

Kun Zhang, Jonas Peters, Dominik Janzing, and Bernhard Schölkopf. Kernel-based conditional independence test and application in causal discovery. In *Proceedings of the 27th Conference on Uncertainty in Artificial Intelligence (UAI)*, pages 804–813. AUAI Press, 2011.

Jincheng Zhou, Mengbo Wang, Anqi He, Yumeng Zhou, Hessam Olya, Murat Kocaoglu, and Bruno Ribeiro. Differentiable constraint-based causal discovery. In *Advances in Neural Information Processing Systems*, 2025.