Constraint-based learning: Variants of the PC algorithm, hypothesis tests for testing conditional independence, causality, hybrid (constraint based and score+search

Damián Benasco Sánchez
Thales Camargo
Juan David Cárdenas
Universidad Politécnica de Madrid, Spain

Abstract

resumen resumen resumen

1 Introducción

Las redes bayesianas son modelos gráficos probabilísticos que representan un conjunto de variables aleatorias y sus dependencias condicionales mediante un grafo acíclico dirigido (DAG) y un conjunto de parámetros de distribución condicional (Spirtes et al., 2000; Pearl, 2009). En los desarrollos iniciales de este campo, la estructura de la red y sus parámetros se especificaban principalmente a partir del conocimiento experto; sin embargo, esta estrategia presenta limitaciones importantes en sistemas complejos, de alta dimensión o en dominios donde las relaciones subyacentes no se conocen de forma directa (Spirtes et al., 2000; Averin et al., 2026).

Como alternativa, el aprendizaje estructural a partir de datos automatiza la construcción de la topología gráfica y la estimación de parámetros mediante el análisis de bases de datos observacionales o experimentales (Kalisch and B"uhlmann, 2007; Colombo and Maathuis, 2014; Averin et al., 2026). En este paradigma de descubrimiento automático, todas las variables se tratan de forma simétrica para inferir directamente las asociaciones probabilísticas y los mecanismos causales subyacentes sin necesidad de imponer una estructura previa por expertos (Spirtes et al., 2000; Pearl, 2009).

Dentro del aprendizaje de estructuras guiado por datos, la literatura distingue tradicionalmente tres familias de métodos: enfoques basados en puntuación y búsqueda, enfoques basados en restricciones y métodos híbridos (Spirtes et al., 2000; Kalisch and B"uhlmann, 2007). El aprendizaje basado en restricciones, también conocido como *constraint-based learning*, infiere la estructura de la red mediante pruebas estadísticas de hipótesis de independencia condicional entre variables (Averin et al., 2026; Spirtes et al., 2000). Su fundamento teórico se apoya en la condición de Markov causal y la propiedad de fidelidad (faithfulness), que establecen una correspondencia entre las independencias condicionadas observadas en los datos y la d-separación en el DAG (Spirtes et al., 2000; Pearl, 2009).

Los algoritmos canónicos de esta familia, como el algoritmo PC (Peter-Clark), operan en fases secuenciales y transparentes: primero eliminan aristas entre variables que son condicionalmente independientes dado un conjunto de condicionamiento y, posteriormente, orientan las relaciones que permanecen relevantes según la estructura de independencias observada (Spirtes et al., 2000; Kalisch and B"uhlmann, 2007). Este enfoque ofrece una mayor interpretabilidad que otras estrategias de aprendizaje estructural, ya que cada decisión de mantener, eliminar u orientar una relación puede rastrearse hasta una prueba estadística concreta (Averin et al., 2026; Spirtes et al., 2000).

No obstante, el aprendizaje basado en restricciones también presenta limitaciones importantes en muestras finitas. La propagación de errores estadísticos puede alterar decisiones tempranas sobre

eliminación de aristas, la potencia de las pruebas de independencia condicional disminuye cuando aumenta el tamaño del conjunto de condicionamiento y la calidad de la inferencia puede depender del orden de procesamiento de las variables (Kalisch and B"uhlmann, 2007; Colombo and Maathuis, 2014). Estos problemas motivan la aparición de métodos híbridos, que combinan la fase de restricción con una etapa de optimización por puntuación y búsqueda local (Kalisch and B"uhlmann, 2007; Colombo and Maathuis, 2014).

Para solventar estas debilidades, surgen los métodos híbridos, los cuales combinan las fortalezas complementarias del aprendizaje basado en restricciones y de los métodos basados en puntuación y búsqueda (Kalisch and B"uhlmann, 2007; Colombo and Maathuis, 2014). En este esquema, la fase de restricción reduce el espacio de soluciones mediante pruebas de independencia condicional y, a continuación, la búsqueda local optimiza una función de puntuación global para refinar la estructura final (Kalisch and B"uhlmann, 2007; Colombo and Maathuis, 2014).

En este contexto, el presente trabajo se centra en el estado del arte de los métodos *constraint-based* para el aprendizaje de redes bayesianas, con especial atención a las variantes del algoritmo PC, a las pruebas de independencia condicional, a la relación entre independencia y causalidad, y a la evolución hacia enfoques híbridos que integran restricciones y optimización basada en puntuación. El objetivo es revisar la literatura más relevante para situar el problema de inferencia estructural dentro del marco teórico del descubrimiento causal y justificar el interés de combinar estrategias estadísticas y causales en la construcción de modelos probabilísticos a partir de datos observacionales (Spirtes et al., 2000; Pearl, 2009; Averin et al., 2026).

2 Estado del arte

Describir lo que han hecho otros, citando sus trabajos.

Hay diferentes formatos dependiendo del tipo de trabajo: un artículo como Uncu and Türksen (2007), un libro como Hosmer and Lemeshow (2000), un capítulo de libro como Wold (1975) o unas actas de congreso Shakhnarovich et al. (2001).

3 Conclusiones y líneas futuras

Propias.

References

Pavel Averin, Theodoros Moysiadis, and Ioannis Katakis. Conditional independence tests for constraint-based causal discovery: A survey. *arXiv preprint arXiv:2608.11156*, 2026.

Diego Colombo and Marloes H. Maathuis. Order-independent constraint-based causal structure learning. *Journal of Machine Learning Research*, 15:3921–3962, 2014.

David W. Hosmer and Stanley Lemeshow. *Applied Logistic Regression*. John Wiley & Sons, New York, 2 edition, 2000.

Markus Kalisch and Peter B"uhlmann. Estimating high-dimensional directed acyclic graphs with the pc-algorithm. *Journal of Machine Learning Research*, 8:613–636, 2007.

Judea Pearl. *Causality: Models, Reasoning, and Inference*. Cambridge University Press, New York, 2 edition, 2009.

Gregory Shakhnarovich, Ran El-Yaniv, and Yoram Baram. Smoothed bootstrap and statistical data cloning for classifier evaluation. In *Proceedings of the 18th International Conference on Machine Learning (ICML)*, pages 521–528. Morgan Kaufmann, 2001.

Peter Spirtes, Clark Glymour, and Richard Scheines. *Causation, Prediction, and Search*. MIT Press, Cambridge, MA, 2000.

Ozgur Uncu and I. Burhan Türksen. A novel feature selection approach: Combining feature wrappers and filters. *Information Sciences*, 177:449–466, 2007.

Herman Wold. Soft modelling by latent variables: The non-linear iterative partial least squares (NIPALS) approach. In Joseph Gani, editor, *Perspectives in Probability and Statistics*, pages 117–142. Academic Press, 1975.