# Constraint-based learning: Variants of the PC algorithm, hypothesis tests for testing conditional independence, causality, hybrid (constraint based and score+search)

Damián Benasco Sánchez
Thales Camargo
Juan David Cárdenas
Universidad Politécnica de Madrid, Spain

**Abstract**

resumen resumen resumen

## 1 Introducción

Las redes bayesianas son modelos gráficos probabilísticos que representan un conjunto de variables aleatorias y sus dependencias condicionales mediante un grafo acíclico dirigido (DAG) y un conjunto de parámetros de distribución condicional (Spirtes et al., 2000; Pearl, 2009). En los desarrollos iniciales de este campo, la estructura de la red y sus parámetros se especificaban principalmente a partir del conocimiento experto; sin embargo, esta estrategia presenta limitaciones importantes en sistemas complejos, de alta dimensión o en dominios donde las relaciones subyacentes no se conocen de forma directa (Spirtes et al., 2000; Averin et al., 2026).

Como alternativa, el aprendizaje estructural a partir de datos automatiza la construcción de la topología gráfica y la estimación de parámetros mediante el análisis de bases de datos observacionales o experimentales (Kalisch and Bühlmann, 2007; Colombo and Maathuis, 2014; Averin et al., 2026). En este paradigma de descubrimiento automático, todas las variables se tratan de forma simétrica para inferir directamente las asociaciones probabilísticas y los mecanismos causales subyacentes sin necesidad de imponer una estructura previa por expertos (Spirtes et al., 2000; Pearl, 2009).

Dentro del aprendizaje de estructuras guiado por datos, la literatura distingue tradicionalmente tres familias de métodos: enfoques basados en puntuación y búsqueda, enfoques basados en restricciones y métodos híbridos (Villa-Blanco et al., 2023). El aprendizaje basado en restricciones, también conocido como *constraint-based learning*, infiere la estructura de la red mediante pruebas estadísticas de hipótesis de independencia condicional entre variables (Averin et al., 2026; Spirtes et al., 2000). Su fundamento teórico se apoya en la condición de Markov causal y la propiedad de fidelidad (faithfulness), que establecen una correspondencia entre las independencias condicionadas observadas en los datos y la $d$-separación en el DAG (Spirtes et al., 2000; Pearl, 2009).

Los algoritmos canónicos de esta familia, como el algoritmo PC (Peter-Clark), operan en fases secuenciales y transparentes: primero eliminan aristas entre variables que son condicionalmente independientes dado un conjunto de condicionamiento y, posteriormente, orientan las relaciones que permanecen relevantes según la estructura de independencias observada (Spirtes et al., 2000; Kalisch and Bühlmann, 2007). Este enfoque ofrece una mayor interpretabilidad que otras estrategias de aprendizaje estructural, ya que cada decisión de mantener, eliminar u orientar una relación puede rastrearse hasta una prueba estadística concreta (Averin et al., 2026; Spirtes et al., 2000).

No obstante, el aprendizaje basado en restricciones también presenta limitaciones importantes en muestras finitas. La propagación de errores estadísticos puede alterar decisiones tempranas sobre

eliminación de aristas, la potencia de las pruebas de independencia condicional disminuye cuando aumenta el tamaño del conjunto de condicionamiento y la calidad de la inferencia puede depender del orden de procesamiento de las variables (Kalisch and Bühlmann, 2007; Colombo and Maathuis, 2014). Estos problemas motivan la aparición de métodos híbridos, que combinan la fase de restricción con una etapa de optimización por puntuación y búsqueda local (Kalisch and Bühlmann, 2007; Colombo and Maathuis, 2014).

Para solventar estas debilidades, surgen los métodos híbridos, los cuales combinan las fortalezas complementarias del aprendizaje basado en restricciones y de los métodos basados en puntuación y búsqueda (Kalisch and Bühlmann, 2007; Colombo and Maathuis, 2014). En este esquema, la fase de restricción reduce el espacio de soluciones mediante pruebas de independencia condicional y, a continuación, la búsqueda local optimiza una función de puntuación global para refinar la estructura final (Kalisch and Bühlmann, 2007; Colombo and Maathuis, 2014).

En este contexto, el presente trabajo se centra en el estado del arte de los métodos *constraint-based* para el aprendizaje de redes bayesianas, con especial atención a las variantes del algoritmo PC, a las pruebas de independencia condicional, a la relación entre independencia y causalidad, y a la evolución hacia enfoques híbridos que integran restricciones y optimización basada en puntuación. El objetivo es revisar la literatura más relevante para situar el problema de inferencia estructural dentro del marco teórico del descubrimiento causal y justificar el interés de combinar estrategias estadísticas y causales en la construcción de modelos probabilísticos a partir de datos observacionales (Spirtes et al., 2000; Pearl, 2009; Averin et al., 2026).

# 2 Estado del arte

El panorama actual del descubrimiento de estructuras en redes bayesianas y modelos gráficos causales ha experimentado una notable evolución, transitando desde la formulación clásica de algoritmos basados en restricciones hacia métodos altamente escalables, flexibles e híbridos. Para comprender de manera sistemática este estado del arte, la presente sección se organiza en tres ejes analíticos interconectados. En primer lugar, se examina la evolución del algoritmo PC y sus variantes, abordando desde sus fundamentos teóricos y modificaciones para garantizar la independencia del orden de entrada y la paralelización, hasta sus extensiones modernas para datos temporales, valores extremos y optimización diferenciable. En segundo lugar, se analizan las pruebas de hipótesis de independencia condicional, comprendidas como el motor estadístico crítico que sustenta las decisiones de poda de aristas y orientación en presencia de variados tipos de datos. Por último, se exploran los paradigmas híbridos, los cuales integran el filtrado local por restricciones con la optimización por puntuación o la resolución lógica de conflictos para mitigar la acumulación de errores en muestras finitas y mejorar la precisión estructural.

## 2.1 Evolución del Algoritmo PC: Fundamentos, Inestabilidad y Variantes Algorítmicas

El **algoritmo PC** (denominado así por sus creadores Peter Spirtes y Clark Glymour) constituye el método clásico y fundacional dentro del paradigma de aprendizaje de estructuras causales basado en restricciones. Desarrollado como una alternativa computacionalmente eficiente al algoritmo SGS (*Spirtes, Glymour y Scheines*), el algoritmo PC parte de un grafo completo no dirigido y elimina aristas de forma recursiva basándose en decisiones de independencia condicional. Esto produce un grafo no dirigido que luego puede ser parcialmente orientado y extendido para representar el DAG subyacente. El algoritmo PC se ejecuta en el peor de los casos en tiempo exponencial (en función del número de nodos), pero si el DAG subyacente real es disperso, esta complejidad se reduce a un tiempo de ejecución polinomial. (Spirtes et al., 2000; Scanagatta et al., 2019)

En el algoritmo PC, asumimos un conjunto de variables $\mathbf{X} = (X_1, \ldots, X_n)$ con una distribución de probabilidad global $P$ sobre ellas. Los subconjuntos de variables de $\mathbf{X}$ se representan mediante letras mayúsculas en negrita (por ejemplo, $\mathbf{A}, \mathbf{B}, \mathbf{C}$). La notación $I(\mathbf{A}, \mathbf{B} \mid \mathbf{C})$ denota que los conjuntos de variables $\mathbf{A}$ y $\mathbf{B}$ son condicionalmente independientes dado el conjunto $\mathbf{C}$. El algoritmo PC asume la hipótesis de fidelidad (*faithfulness*). Esto significa que existe un grafo acíclico dirigido (DAG), $G$, tal que las relaciones de independencia entre las variables de $\mathbf{X}$ son exactamente aquellas representadas por $G$ mediante el criterio de $d$-separación. En consecuencia, el algoritmo PC se apoya en la posibilidad de comprobar cuándo se verifica $I(\mathbf{A}, \mathbf{B} \mid \mathbf{C})$ en el grafo $G$ y, a partir de esa información, recuperar la estructura subyacente. (Spirtes et al., 2000; Abellán et al., 2006)

La idea central del método consiste en recuperar primero el esqueleto del grafo y, posteriormente, orientar las aristas que permanecen. La etapa de poda se realiza eliminando enlaces entre parejas de nodos cuando existe un subconjunto de sus vecinos que hace que ambas variables sean condicionalmente independientes dados esos vecinos. Este criterio permite reducir progresivamente el grafo completo inicial hasta un grafo no dirigido compatible con las independencias observadas. (Spirtes et al., 2000; Abellán et al., 2006)

**Algorithm 1** Algoritmo PC: fase de búsqueda del esqueleto

```
Inicializar G' como un grafo completo no dirigido sobre X
i ← 0
repeat
    for cada par adyacente (X, Y) en G' do
        if existe S ⊆ Adj_{G'}(X) \ {Y} con |S| = i y I(X, Y | S) then
            Guardar S_XY ← S
            Eliminar la arista X − Y de G'
        end if
    end for
    i ← i + 1
until ∀X ∈ X, |Adj_{G'}(X)| ≤ i
```

En que el conjunto completo de variables del problema se denota por $\mathbf{X}$, mientras que $\mathrm{Adj}_{G'}(X)$ representa el conjunto de vecinos de $X$ en el grafo actual $G'$. La expresión $I(X, Y \mid S)$ indica que $X$ e $Y$ son condicionalmente independientes dado el conjunto $S$. Así, si las independencias observadas son fieles a un DAG, no existe un enlace entre $X$ e $Y$ si y solo si existe un subconjunto $S$ de los vecinos de $X$ tal que se cumple $I(X, Y \mid S)$. Para cada par de variables, $S_{XY}$ contendrá dicho conjunto, si se encuentra. Este conjunto se utilizará en la etapa posterior de orientación.(Spirtes et al., 2000; Abellán et al., 2006)

La etapa de orientación procederá buscando conjuntos de tres variables $\{X, Y, Z\}$ tales que los enlaces $X - Z$ y $Y - Z$ estén en el grafo pero no el enlace $X - Y$. Entonces, si $Z \notin S_{XY}$, orienta los enlaces de $X$ a $Z$ y de $Y$ a $Z$ creando una estructura en v: $X \rightarrow Z \leftarrow Y$. Una vez realizadas estas orientaciones, se intenta orientar el resto de las aristas siguiendo dos principios básicos: no crear ciclos y no crear nuevas estructuras en v. Es posible que la orientación de algunas aristas deba elegirse arbitrariamente. Si el conjunto de independencias es fiel a un grafo y disponemos de un procedimiento perfecto para determinar si $I(X, Y \mid S)$, entonces el algoritmo garantiza producir un grafo equivalente (que representa el mismo conjunto de independencias) al original. (Abellán et al., 2006)

A pesar de su solidez teórica y su completitud asintótica bajo supuestos de fidelidad y suficiencia causal, el algoritmo PC clásico presenta varias limitaciones críticas cuando se aplica a datos reales de tamaño muestral finito (Colombo and Maathuis, 2014). En primer lugar, la versión muestral del algoritmo sufre una fuerte dependencia del orden, donde la secuencia en la que se disponen las variables en el conjunto de datos determina qué pruebas de independencia condicional se ejecutan primero; como resultado, los errores estadísticos tempranos alteran dinámicamente los conjuntos de condicionamiento

disponibles para pares de variables posteriores, lo que conduce a esqueletos estimados, estructuras en $v$ y orientaciones de aristas altamente variables. En segundo lugar, las pruebas estadísticas frecuentistas estándar (como $\chi^2$ o las pruebas $z$ de correlación parcial) toman decisiones categóricas e irrevocables desde el principio, y se vuelven cada vez más propensas a errores de tipo I y tipo II a medida que disminuyen los tamaños de muestra o crece la cardinalidad del conjunto de condicionamiento (Abellán et al., 2006). En tercer lugar, aunque el algoritmo es computacionalmente polinómico para grafos dispersos, el cálculo de numerosas pruebas de independencia condicional en conjuntos de datos de alta dimensión o con muestras masivas crea un cuello de botella computacional dominante. Estos desafíos combinados —inestabilidad del orden, vulnerabilidad estadística en muestras finitas y limitaciones de escalabilidad computacional— motivaron el desarrollo de las variantes algorítmicas especializadas que se discuten a continuación.

Abellán, Gómez-Olmedo y Moral (2006) propusieron cuatro modificaciones clave al algoritmo PC estándar para abordar las limitaciones causadas por errores estadísticos en contextos de muestras finitas. Para minimizar los errores de decisión asociados a conjuntos de condicionamiento grandes, introdujeron la evaluación de la independencia condicional mediante conjuntos de corte de tamaño mínimo ($CUT_{X,Y}$), calculados con un algoritmo de Ford-Fulkerson modificado. Además, sustituyeron las pruebas clásicas de $\chi^2$ por una métrica de puntuación bayesiana de Dirichlet (BD), que ofrece un equilibrio más razonable entre los errores de tipo I y tipo II en distintos tamaños de muestra. Asimismo, incorporaron un paso de refinamiento greedy posterior para optimizar el grafo aprendido según una puntuación BD con el fin de aproximar mejor la distribución conjunta de probabilidad, y un método de resolución de triángulos que evalúa la fuerza de los enlaces para podar el arco más débil en subgrafos totalmente conectados de tres variables.

Kalisch y Bühlmann (2007) establecieron la validez teórica de aplicar el algoritmo PC en escenarios de alta dimensión, donde el número de variables $p$ crece rápidamente en función del tamaño muestral $n$ ($p = O(n^a)$ con $0 < a < \infty$). Demostraron que la versión muestral del algoritmo PC, utilizando la transformación $z$ de Fisher para pruebas de correlación parcial, es asintóticamente consistente para estimar el esqueleto de DAG dispersos bajo distribuciones gaussianas multivariantes. Bajo la suposición de que los vecindarios del grafo son dispersos ($q_n = O(n^{1-b})$ con $0 < b \leq 1$), mostraron que la complejidad computacional en el peor caso queda acotada por $O(p^{q_n})$, lo que hace que el aprendizaje de estructuras sea computacionalmente tratable en redes altas y dispersas. Por último, sus simulaciones empíricas demostraron que el algoritmo PC alcanza tasas de descubrimiento verdaderas (TDR) significativamente mayores que las alternativas basadas en puntuación y mantiene una gran robustez en un amplio rango de niveles de significación $\alpha$.

Kalisch et al. (2012) presentaron el paquete de código abierto para R `pcalg`, diseñado para facilitar el aprendizaje de estructuras causales y la estimación cuantitativa de efectos de intervenciones causales a partir de datos observacionales. El paquete implementa varios algoritmos fundamentales de descubrimiento de estructuras basados en restricciones: el algoritmo PC para escenarios con suficiencia causal, y los algoritmos FCI y RFCI, que contemplan la presencia de factores de confusión latentes y variables de selección. Además de estimar estructuras, `pcalg` incorpora el método IDA y su variante optimizada desde el punto de vista computacional, `idaFast()`, que aplican el cálculo de intervenciones de Pearl a clases de equivalencia de Markov aprendidas para estimar cotas de los efectos causales totales cuando el grafo subyacente no puede identificarse de forma única. Para adaptarse a diversos contextos empíricos, el paquete ofrece funciones modulares para realizar pruebas de independencia condicional con datos gaussianos, discretos y binarios, y permite integrar procedimientos de prueba personalizados y conocimiento previo, como aristas obligatorias o prohibidas. También incluye opciones como reglas conservadoras de orientación para mitigar los conflictos entre aristas inducidos por errores de muestreo. Su utilidad práctica se ha demostrado en aplicaciones de biología y epidemiología de alta dimensionalidad, con miles de variables (Kalisch et al., 2012).

Colombo y Maathuis (2014) abordaron la cuestión crítica de la dependencia del orden en los algoritmos de aprendizaje de estructuras causales basados en restricciones (incluidos PC, FCI, RFCI

y CCD), demostrando que, en escenarios de alta dimensión y muestras finitas, la variación en la secuencia de variables de entrada produce una inestabilidad sustancial en los esqueletos estimados, las estructuras en v y las orientaciones de aristas. Para eliminar la dependencia del orden en la búsqueda del esqueleto, introdujeron el algoritmo **PC-stable**, que registra y congela los conjuntos de adyacencia $a(X_i)$ al inicio de cada nivel de condicionamiento $\ell$, impidiendo que las eliminaciones de aristas dentro del nivel $\ell$ alteren prematuramente los conjuntos de condicionamiento para otros pares de variables. Para la determinación de estructuras en v independientes del orden, desarrollaron **CPC-stable** (Conservative PC) y **MPC-stable** (Majority Rule PC), que evalúan todos los conjuntos separadores para triples no protegidos y clasifican un triple como no ambiguo solo si el nodo intermedio es consistente en su presencia o ausencia en todos los conjuntos separadores (CPC) o en un umbral mayoritario de ellos (MPC). Además, propusieron reglas de orientación basadas en listas (**LCPC-stable** y **LMPC-stable**) que utilizan aristas bidireccionales para resolver conflictos de orientación, logrando salidas gráficas completamente independientes del orden. De manera crucial, demostraron que todas las modificaciones propuestas preservan la corrección, la completitud y la consistencia en alta dimensión del algoritmo PC original bajo condiciones teóricas idénticas, mientras extienden con éxito estos principios de independencia del orden a algoritmos que manejan variables latentes como FCI y RFCI. A través de simulaciones de alta dimensión y análisis de expresión genética, demostraron que las variantes PC-stable producen una varianza significativamente menor de la Distancia de Hamming Estructural (SHD), tasas de descubrimiento verdaderas (TDR) superiores y predicciones de efectos causales mejores cuando se integran con IDA.

Le et al. (2019) abordaron el importante cuello de botella computacional que supone el tiempo de ejecución de los métodos de descubrimiento causal basados en restricciones e independientes del orden, especialmente en aplicaciones biológicas de alta dimensionalidad. Aunque variantes como PC-stable eliminan la dependencia del orden al fijar las consultas de vecindad en cada nivel de condicionamiento, requieren evaluar un número considerablemente mayor de pruebas de independencia condicional, lo que puede producir tiempos de ejecución prohibitivos —superiores a 24 horas— en grandes conjuntos de datos de expresión génica. Para reducir este coste sin sacrificar la independencia del orden ni la precisión estructural, desarrollaron **Parallel-PC**, un marco de paralelización eficiente en memoria para equipos de escritorio multinúcleo y servidores de laboratorio. Como las pruebas de independencia condicional de un mismo nivel son mutuamente independientes mientras las adyacencias del grafo permanecen fijas, Parallel-PC distribuye esas pruebas entre los núcleos disponibles y sincroniza las actualizaciones al pasar de un nivel al siguiente. Además, asigna a un mismo núcleo las pruebas asociadas a una arista candidata, evitando evaluaciones redundantes entre conjuntos de nodos adyacentes. En pruebas de alta dimensionalidad, incluidos los conjuntos de datos del desafío DREAM5, redujo el tiempo de ejecución de más de 24 horas a menos de seis horas en una máquina de ocho núcleos. Su integración en el flujo de trabajo `efficient-IDA` para identificar dianas reguladoras de miARN y ARNm también mejoró la escalabilidad computacional y la precisión de la predicción de efectos causales en redes biológicas complejas (Le et al., 2019).

Kocaoglu (2023) abordó la limitación del algoritmo PC y sus derivados en escenarios con un volumen de datos restringido, en los que las pruebas de independencia condicional pierden potencia estadística a medida que aumenta el tamaño del conjunto condicionante. Para evitar la propagación en cadena de errores estadísticos generados por pruebas de alto orden, el autor introdujo la noción de **$k$-equivalencia de Markov**, según la cual dos grafos acíclicos dirigidos (DAGs) se consideran equivalentes si comparten las mismas restricciones de independencia condicional para conjuntos condicionantes de tamaño limitado a un entero $k$ ($|C| \leq k$). Para representar esta nueva clase de equivalencia, el estudio definió los **grafos de $k$-clausura** (*$k$-closure graphs*) y demostró teóricamente que la $k$-equivalencia entre dos DAGs se reduce a la equivalencia de Markov de sus grafos de $k$-clausura. Sobre esta caracterización, el autor desarrolló el algoritmo **$k$-PC**, que adapta las reglas de orientación del algoritmo FCI para aprender la estructura del grafo $k$-esencial restringiendo las evaluaciones a pruebas de orden como máximo $k$. Experimentos con datos sintéticos y con la red *Asia* demostraron que el

algoritmo $k$-PC presenta una mayor robustez en regímenes de muestra reducida, alcanzando puntuaciones F1 significativamente superiores en la identificación del esqueleto y la orientación de las aristas en comparación con el PC tradicional y métodos de optimización continua como **NOTEARS**.

Biswas y Mukherjee (2024) ampliaron los fundamentos matemáticos del algoritmo PC a escenarios con datos no independientes e idénticamente distribuidos, y establecieron garantías teóricas de consistencia para el descubrimiento causal en series temporales multivariantes. Mientras que las pruebas clásicas de consistencia uniforme del algoritmo PC suponen muestras independientes e idénticamente distribuidas, las series temporales presentan dependencia temporal de forma natural. Los autores demostraron que el algoritmo PC muestral conserva la consistencia puntual y asintótica al estimar DAG contemporáneos bajo procesos estacionarios con dependencia de mezcla $\rho$ y de mezcla fuerte, siempre que las correlaciones decaigan con suficiente rapidez. Establecieron estas garantías para estructuras estacionarias habituales, incluidos los modelos de medias móviles autorregresivas vectoriales (VARMA) y los procesos lineales, utilizando tanto pruebas paramétricas $z$ de correlación parcial de Pearson como pruebas no paramétricas basadas en el criterio de independencia de Hilbert-Schmidt (HSIC). Asimismo, demostraron la consistencia asintótica en alta dimensionalidad del algoritmo **Time-Aware PC (TPC)**, que aprende grafos causales entre instantes y rezagos temporales y luego los transforma en grafos causales resumidos y desplegados. En experimentos con modelos VAR gaussianos lineales y no lineales, redes neuronales de tiempo continuo y datos hidrológicos reales del conjunto CauseMe River Runoff, TPC superó al algoritmo PC clásico y a la causalidad de Granger en la recuperación de conexiones causales entre instantes (Biswas and Mukherjee, 2024).

Las principales variantes y extensiones del algoritmo PC analizadas en esta subsección se resumen en la Tabla 1, incluida en el Apéndice A.

### 2.2 Pruebas de Independencia Condicional y Extensiones para Causalidad

Las pruebas de indepencia condicional (IC) constituyen el motor estadístico del aprendizaje estructural basado en restricciones, pues cada decisión de poda y de orientación del esqueleto del grafo se reduce a determinar si dos variables son dependientes o independientes dado un conjunto de condicionamiento (Spirtes et al., 2000; Averin et al., 2026). A diferencia de las funciones de puntuación (score), que evalúan estructuras completas, el contraste IC es una decisión local y consstrastable individualmente, lo que explica la interpretabilidad característica de los métodos *constraint-based*, en los que cada arista eliminada o conservada puede rastrearse hasta un constraste estadístico conreto y su p-valor (Averin et al., 2026; Spirtes et al., 2000)

Formalmente, dada una distribución de probabilidad $P$ sobre un conjunto de variables $\mathbf{X} = (X_1, \ldots, X_n)$, la notación $I(\mathbf{X}, \mathbf{Y} \mid \mathbf{Z})$ denota que los conjuntos $\mathbf{X}$ e $\mathbf{Y}$ son condicionalmente independientes dado $\mathbf{Z}$, esto es, $P(\mathbf{X}, \mathbf{Y} \mid \mathbf{Z}) = P(\mathbf{X} \mid \mathbf{Z})\, P(\mathbf{Y} \mid \mathbf{Z})$. Un contraste de IC procede sobre una muestra finita y confronta la hipótesis nula de independencia condicional $I(\mathbf{X}, \mathbf{Y} \mid \mathbf{Z})$ con la alternativa de dependencia condicional, controlando al nivel $\alpha$ la probabilidad de falso rechazo. La relevancia de estas decisiones radica en su correspondencia con la estructura el grafo, ya que, bajo las condiciones de Markov causal y fidelidad, una distribución es fiel a un DAG $G$ si y solo si, para todo par de conjuntos disjuntos de vértices $\mathbf{X}$, $\mathbf{Y}$ y todo conjunto $\mathbf{Z}$ disjunto de ambos, $I(\mathbf{X}, \mathbf{Y} \mid \mathbf{Z})$ si y solo si $\mathbf{X}$ e $\mathbf{Y}$ están $d$-separados por $\mathbf{Z}$ (Spirtes et al., 2000). Expresado matemáticamente:

$$P(X_1, \ldots, X_n) = \prod_{i=1}^{n} P(X_i \mid \mathrm{Pa}(X_i)) \iff \forall\, X, Y, \mathbf{Z} \text{ disjuntos}: \quad I(X, Y \mid \mathbf{Z}) \iff \mathbf{X} \perp_G \mathbf{Y} \mid \mathbf{Z}$$

Los algoritmos explotan esta equivalencia tratando cada resultado de un contraste como un hecho de $d$-separación, las independencias detectadas eliminan aristas y las dependencias restantes guían la orientación, de modo que la calidad del grafo aprendido queda acotada por la calidad de las decisiones estadísticas (Spirtes et al., 2000; Pearl, 2009). Los contrastes disponibles se pueden ordenar según la

estructura que asumen sobre la dependencia, desde los paramétricos clásicos hasta los no paramétricos, y ninguno es universal, ya que todo contraste restringe implícitamente el tipo de dependencia que puede detectar y paga esa restricción con pérdida de potencia frente al resto de alternativas (Shah and Peters, 2020). Introduciendo un ejemplo que se desarrollará con más detalle al presentar la correlación parcial. Para $X \sim \mathcal{N}(0,1)$ e $Y = X^2$ se cumple

$$\mathbb{E}[X^3] = 0 \quad \Longrightarrow \quad \operatorname{corr}(X,Y) = 0 \qquad \text{mientras que} \qquad \neg I(X,Y),$$

de modo que un contraste basado en la correlación parcial no detectaría esta dependencia pese a ser manifiesta.

### 2.2.1 Correlación parcial

Para datos continuos, el contraste clásico es la **correlación parcial**. Bajo normalidad conjunta, $I(X,Y \mid \mathbf{Z})$ equivale a la anulación de la correlación parcial (Lauritzen, 1996). Para cada contraste se toman las observaciones de $X$, $Y$ y las variables de $\mathbf{Z}$, es decir, $\mathbf{w}_i = (x_i,\, y_i,\, \mathbf{z}_i)$ con $\mathbf{z}_i \in \mathbb{R}^{|\mathbf{Z}|}$, y se calcula su matriz de covarianzas muestral

$$S = \frac{1}{n-1}\sum_{i=1}^{n}\big(\mathbf{w}_i - \bar{\mathbf{w}}\big)\big(\mathbf{w}_i - \bar{\mathbf{w}}\big)^{\top} \;\in\; \mathbb{R}^{(|\mathbf{Z}|+2)\times(|\mathbf{Z}|+2)},$$

cuya inversa, $\hat{K} = S^{-1}$, proporciona la correlación parcial muestral entre $X$ e $Y$ dado $\mathbf{Z}$,

$$\hat{\rho}_{XY\cdot\mathbf{Z}} = \frac{-\hat{K}_{XY}}{\sqrt{\hat{K}_{XX}\,\hat{K}_{YY}}}.$$

El contraste aplica la transformada $z$ de Fisher (Hotelling, 1953) a ese valor muestral,

$$z(r) = \tfrac{1}{2}\ln\frac{1+r}{1-r}, \qquad T = \sqrt{n - |\mathbf{Z}| - 3}\, z(\hat{\rho}_{XY\cdot\mathbf{Z}}),$$

de modo que se rechaza la hipótesis de independencia cuando $|T|$ supera el cuantil $z_{1-\alpha/2}$ de una normal estándar (Anderson, 2003). Su ventaja principal es el coste, ya que, con la matriz de covarianzas muestral ya calculada, cada contraste se reduce a invertir el bloque correspondiente, con $O(|\mathbf{Z}|^3)$ operaciones, y sus p-valores son analíticos, sin remuestreo, lo que lo convierte en el contraste habitual para datos continuos en las implementaciones de referencia (Kalisch et al., 2012; Scutari, 2010), y el que sostiene la consistencia del PC en alta dimensión bajo esparsidad (Spirtes et al., 2000; Kalisch and Bühlmann, 2007). Su limitación es simétrica, pues la equivalencia entre correlación parcial nula e independencia condicional vale solo bajo normalidad y linealidad, y fuera de ese modelo las variantes de rango únicamente la aproximan (Baba et al., 2004).

Recientes líneas de investigación tratan de dotar de robustez a estos contrastes frente a violaciones parciales del modelo. Cuando la varianza del error no es constante, las versiones ponderadas (WLS) conservan la estructura del contraste y recuperan su calibración (Günther et al., 2022). Cuando la distribución se aleja de la normalidad, los contrastes basados en correlaciones de rango mantienen la consistencia del PC bajo modelos no paranormales o de cópula gaussiana, con un coste computacional apenas mayor (Harris and Drton, 2012), y admiten además su extensión a datos mixtos mediante cópulas (Cui et al., 2016). En muestras pequeñas, los esquemas de permutación corrigen la aproximación asintótica del p-valor (Tsamardinos and Borboudakis, 2010; Legendre, 2000).

### 2.2.2 Tablas de contingencia

Para datos discretos, el contraste clásico es el de **tablas de contingencia**, el que emplean los algoritmos de aprendizaje de estructura cuando las variables son categóricas (Kitson et al., 2023). Cada

celda de la tabla conjunta recoge cuántas observaciones caen en una combinación de valores de $X$, $Y$ y las variables de $\mathbf{Z}$, y la hipótesis de independencia impone un valor esperado para cada frecuencia. El contraste mide la discrepancia entre los conteos observados y los esperados.

Denotamos por $n_{ijk}$ el número de observaciones de la muestra en las que $X$ toma su valor $i$, $Y$ su valor $j$ y $\mathbf{Z}$ su $k$-ésima combinación de valores, y escribimos $n_{i\cdot k}$, $n_{\cdot jk}$ y $n_{\cdot\cdot k}$ para las sumas de $n_{ijk}$ sobre el índice sustituido por el punto. Los esperados bajo independencia se calculan precisamente a partir de esas marginales,

$$E_{ijk} = \frac{n_{i\cdot k}\, n_{\cdot jk}}{n_{\cdot\cdot k}},$$

y los dos estadísticos clásicos son

$$\chi^2 = \sum_{i,j,k} \frac{(n_{ijk} - E_{ijk})^2}{E_{ijk}}, \qquad G^2 = 2\sum_{i,j,k} n_{ijk} \ln \frac{n_{ijk}}{E_{ijk}}.$$

Ambos se distribuyen asintóticamente como una $\chi^2_\nu$ con $\nu = (I-1)(J-1)\prod_l K_l$ grados de libertad (Spirtes et al., 2000; Kitson et al., 2023), donde $K_l$ es el número de valores de la $l$-ésima variable de $\mathbf{Z}$, de modo que se rechaza la independencia cuando el estadístico supera el cuantil $\chi^2_{\nu,1-\alpha}$. El estadístico $G^2$ es la versión discreta del contraste de razón de verosimilitud y es proporcional a la información mutua condicional, $G^2 = 2n\,\hat{\mathrm{I}}(X, Y \mid \mathbf{Z})$, por lo que los contrastes de información mutua (MI) que usan por defecto las implementaciones de referencia pertenecen a esta misma familia (Scutari, 2010). Para variables ordinales, donde el orden de las categorías es informativo, se incorpora además el contraste de tendencia de Jonckheere–Terpstra en su versión asintóctica con corrección por empates, que explota ese orden en lugar de tratar los niveles como meras etiquetas (Jonckheere, 1954; Terpstra, 1952)

Su ventaja es ser el contraste canónico para datos categóricos, con p-valores analíticos y una lectura directa como divergencia entre la tabla observada y la que se esperaría bajo independencia. Cabe destacar que en las simulaciones originales del PC, $G^2$ condujo al grafo correcto con más frecuencia que $X^2$ (Spirtes et al., 2000). Una de las principales limitaciones es el crecimiento exponencial del número de celdas con respecto a $|\mathbf{Z}|$ y a la cardinalidad de las variables, $I \cdot J \cdot \prod_l K_l$ celdas. Esto hace que los conteos esperados se estimen con pocas observaciones por celda y la aproximación $\chi^2$ deje de ser fiable. Las reglas prácticas exigen un mínimo de muestras por celda, del estilo $n \geq 5\times$ el número de celdas para estimar con garantías, o asumir dependencia directamente cuando $n < 10\times$ el número de celdas (Spirtes et al., 2000). El coste de calcular el estadístico es lineal en el número de celdas, pero ese número es justamente el cuello de botella.

Las líneas recientes atacan precisamente esta escasez de datos. Dash (2003) propuso una tabla de contingencia suavizada, compatible con cualquier estadístico de tabla, que incorpora *priors* y puede calcularse incluso con bases de datos incompletas, y mostró que mejora la recuperación estructural y reduce la divergencia de KL frente al contraste estándar, incluso con *priors* no informativos y sobre todo con muestras pequeñas o muchas variables. Kubkowski et al. (2021) propusieron el estadístico SECMI, una expansión truncada de la información mutua condicional que mantiene la potencia del contraste cuando $|\mathbf{Z}|$ es grande sin perder el control del error de tipo I. Y en la práctica, la calibración asintótica puede sustituirse por permutaciones o por esquemas semiparamétricos que corrigen el comportamiento en muestra pequeña, tal y como ofrecen las implementaciones de referencia (Scutari, 2010; Tsamardinos and Borboudakis, 2010).

### 2.2.3 Regresión y métodos de residuos

### 2.2.4 Métodos no paramétricos

## 2.3 Enfoques Híbridos (Constraint-Based y Score-and-Search) y Líneas Futuras

La literatura reciente ha mostrado un creciente interés en enfoques híbridos que combinan la fuerza de los métodos*constraint-based* con las estrategias de*score-and-search*. ...

## 3 Conclusiones y líneas futuras

Propias.

## A Resumen de variantes del algoritmo PC

Table 1: Resumen de las principales variantes y extensiones del algoritmo PC

| Algoritmo | Fuente / Autores | Descripción |
|---|---|---|
| **PC clásico** | Spirtes, Glymour y Scheines (2000) (Spirtes et al., 2000) | Algoritmo fundamental basado en restricciones que estima el esqueleto mediante pruebas recursivas de independencia condicional y orienta aristas según las independencias y las reglas de Meek. |
| **PC de alta dimensión** | Kalisch y Bühlmann (2007) (Kalisch and Bühlmann, 2007) | Adaptación del algoritmo PC con transformación $z$ de Fisher para la correlación parcial, con garantías de consistencia asintótica y viabilidad computacional en escenarios de alta dimensión ($p \gg n$) y grafos dispersos. |
| **PC con conjuntos de corte y pruebas bayesianas** | Abellán, Gómez-Olmedo y Moral (2006) (Abellán et al., 2006) | Utiliza conjuntos de corte mínimos ($CUT_{X,Y}$), calculados mediante una variante de Ford-Fulkerson, y una puntuación bayesiana Dirichlet (BD) para reducir errores en muestras finitas. |
| **PC-stable** | Colombo y Maathuis (2014) (Colombo and Maathuis, 2014) | Elimina la dependencia del orden de las variables en la búsqueda del esqueleto al fijar los conjuntos de adyacencia al inicio de cada nivel de condicionamiento. |
| **CPC-stable** *(Conservative PC)* | Colombo y Maathuis (2014) (Colombo and Maathuis, 2014) | Evalúa los conjuntos separadores de triples no protegidos y considera no ambiguo un triple solo cuando la pertenencia del nodo central es consistente en todos ellos. |
| **MPC-stable** *(Majority Rule PC)* | Colombo y Maathuis (2014) (Colombo and Maathuis, 2014) | Determina la orientación de estructuras en $v$ aplicando una regla de mayoría sobre los conjuntos separadores evaluados para cada triple no protegido. |
| **LCPC-stable / LMPC-stable** | Colombo y Maathuis (2014) (Colombo and Maathuis, 2014) | Emplea listas de candidatos y aristas bidireccionales para resolver conflictos en las reglas de orientación de Meek y obtener resultados independientes del orden. |
| **FCI-stable / RFCI-stable** | Colombo y Maathuis (2014) (Colombo and Maathuis, 2014) | Extiende los principios de independencia del orden a algoritmos que contemplan variables latentes y sesgos de selección, y que producen grafos parcialmente ancestrales (PAG). |
| **Parallel bnlearn** | Scutari (2014) | Distribuye entre varios núcleos la estimación de vecindarios y mantas de Markov para acelerar el aprendizaje de estructuras. |
| **Parallel-PC** | Le et al. (2019) (Le et al., 2019) | Paraleliza las pruebas de independencia condicional de cada nivel del algoritmo PC-stable en procesadores multinúcleo, reduciendo el tiempo de ejecución en datos de alta dimensión. |
| **Parallel PC (BIB / MPI)** | Madsen et al. (2017) | Combina diseños de bloques incompletos balanceados (BIB) para memoria compartida y comunicación MPI para memoria distribuida, con el objetivo de escalar PC a miles de variables. |
| **$k$-PC** | Kocaoglu (2023) (Kocaoglu, 2023) | Aprende clases de equivalencia de Markov para datos limitados, restringiendo las pruebas de independencia condicional a conjuntos de tamaño máximo $k$ y utilizando grafos de $k$-clausura para caracterizarlas. |
| **Time-Aware PC (TPC)** | Biswas y Mukherjee (2024) (Biswas and Mukherjee, 2024) | Extiende PC a series temporales estacionarias no i.i.d. con dependencia temporal ($\rho$-mixing), estimando grafos causales intertemporales y contemporáneos mediante pruebas de Pearson y HSIC. |

## References


Joaquín Abellán, Manuel Gómez-Olmedo, and Serafín Moral. Some variations on the PC algorithm. In *Proceedings of the Third European Workshop on Probabilistic Graphical Models (PGM 2006)*, pages 1–8, Granada, Spain, 2006.

T.W. Anderson. *An Introduction to Multivariate Statistical Analysis*. Wiley Series in Probability and Statistics. Wiley, 2003. ISBN 9780471360919.

Pavel Averin, Theodoros Moysiadis, and Ioannis Katakis. Conditional independence tests for constraint-based causal discovery: A survey. arXiv preprint arXiv:2608.11156, 2026.

Kunihiro Baba, Ritei Shibata, and Masaaki Sibuya. Partial correlation and conditional correlation as measures of conditional independence. *Australian & New Zealand Journal of Statistics*, 46(4): 657–664, 2004.

Rahul Biswas and Somabha Mukherjee. Consistent causal inference from time series with PC algorithm and its time-aware extension. *Statistics and Computing*, 34(14):1–21, 2024. doi: 10.1007/s11222-023-10330-3.

Diego Colombo and Marloes H. Maathuis. Order-independent constraint-based causal structure learning. *Journal of Machine Learning Research*, 15:3921–3962, 2014.

Ruifei Cui, Perry Groot, and Tom Heskes. Copula PC algorithm for causal discovery from mixed data. In *Machine Learning and Knowledge Discovery in Databases (ECML PKDD)*, pages 377–392. Springer, 2016.

Denver Dash. Robust independence testing for constraint-based learning of causal structure. 2003.

Wiebke Günther, Urmi Ninad, Jonas Wahl, and Jakob Runge. Conditional independence testing with heteroskedastic data and applications to causal discovery. *Advances in Neural Information Processing Systems*, 35:16191–16202, 2022.

Naftali Harris and Mathias Drton. Pc algorithm for gaussian copula graphical models, 2012. URL `https://arxiv.org/abs/1207.0242`.

Harold Hotelling. New light on the correlation coefficient and its transforms. *Journal of the Royal Statistical Society. Series B (Methodological)*, 15(2):193–232, 1953.

Aimable Robert Jonckheere. A distribution-free k-sample test against ordered alternatives. *Biometrika*, 41(1/2):133–145, 1954.

Markus Kalisch and Peter Bühlmann. Estimating high-dimensional directed acyclic graphs with the pc-algorithm. *Journal of Machine Learning Research*, 8:613–636, 2007.

Markus Kalisch, Martin Mächler, Diego Colombo, Marloes H. Maathuis, and Peter Bühlmann. Causal inference using graphical models with the R package pcalg. *Journal of Statistical Software*, 47(11): 1–26, 2012. doi: 10.18637/jss.v047.i11.

Neville Kenneth Kitson, Anthony C Constantinou, Zhigao Guo, Yang Liu, and Kiattikun Chobtham. A survey of bayesian network structure learning. *Artificial Intelligence Review*, 56(8):8721–8814, 2023.

Murat Kocaoglu. Characterization and learning of causal graphs with small conditioning sets. In *Advances in Neural Information Processing Systems*, volume 36, pages 74140–74179, 2023. doi: 10.52202/075280-3244.

Mariusz Kubkowski, Jan Mielniczuk, and Paweł Teisseyre. How to gain on power: novel conditional independence tests based on short expansion of conditional mutual information. *Journal of Machine Learning Research*, 22(62):1–57, 2021.

Steffen L. Lauritzen. *Graphical Models*. Oxford University Press, Oxford, 1996.

Thuc Duy Le, Tao Hoang, Jiuyong Li, Lin Liu, Huawen Liu, and Shu Hu. A fast PC algorithm for high dimensional causal discovery with multi-core PCs. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, 16(5):1483–1494, 2019. doi: 10.1109/TCBB.2016.2591526.

Pierre Legendre. Comparison of permutation methods for the partial correlation and partial mantel tests. *Journal of statistical computation and simulation*, 67(1):37–73, 2000.

Judea Pearl. *Causality: Models, Reasoning, and Inference*. Cambridge University Press, New York, 2 edition, 2009.

Mauro Scanagatta, Antonio Salmerón, and Fabio Stella. A survey on bayesian network structure learning from data. *Progress in Artificial Intelligence*, 8:425–439, 2019. doi: 10.1007/s13748-019-00194-y.

Marco Scutari. Learning Bayesian networks with the bnlearn R package. *Journal of Statistical Software*, 35(3):1–22, 2010. doi: 10.18637/jss.v035.i03.

Rajen D. Shah and Jonas Peters. The hardness of conditional independence testing and the generalised covariance measure. *The Annals of Statistics*, 48(3):1514–1538, 2020. ISSN 2168-8966. doi: 10.1214/19-aos1857. URL `http://dx.doi.org/10.1214/19-AOS1857`.

Peter Spirtes, Clark Glymour, and Richard Scheines. *Causation, Prediction, and Search*. MIT Press, Cambridge, MA, 2000.

Teunis J Terpstra. The asymptotic normality and consistency of kendall's test against trend, when ties are present in one ranking. *Indagationes Mathematicae*, 14(3):327–333, 1952.

Ioannis Tsamardinos and Giorgos Borboudakis. Permutation testing improves bayesian network learning. In *Joint European conference on machine learning and knowledge discovery in databases*, pages 322–337. Springer, 2010.

Carlos Villa-Blanco, Alessandro Bregoli, Concha Bielza, Pedro Larrañaga, and Fabio Stella. Constraint-based and hybrid structure learning of multidimensional continuous-time bayesian network classifiers. *International Journal of Approximate Reasoning*, 159:108945, 2023. ISSN 0888-613X. doi: 10.1016/j.ijar.2023.108945. URL `https://www.sciencedirect.com/science/article/pii/S0888613X23000762`.