# Constraint-based learning: Variants of the PC algorithm, hypothesis tests for testing conditional independence, causality, hybrid (constraint based and score+search

Damián Benasco Sánchez
Thales Camargo
Juan David Cárdenas
Universidad Politécnica de Madrid, Spain

**Abstract**

resumen resumen resumen

## 1 Introducción

El descubrimiento de la estructura causal a partir de datos observacionales representa un pilar fundamental en la inteligencia artificial, la estadística y el aprendizaje automático moderno

El aprendizaje de estructuras de redes bayesianas es una tarea central en la inferencia probabilística y en la modelización causal, ya que permite representar relaciones entre variables mediante grafos dirigidos acíclicos y, a partir de ellos, estimar distribuciones condicionales que sustentan la toma de decisiones bajo incertidumbre. En los últimos años, este campo ha experimentado un crecimiento notable por la combinación de técnicas estadísticas, aprendizaje automático y teoría causal. En particular, una de las líneas más relevantes es el aprendizaje basado en restricciones, también conocido como *constraint-based learning*, donde la identificación de la estructura se realiza a partir de pruebas de independencia condicional entre variables. Este enfoque se fundamenta en la idea de que las relaciones de independencia observadas en los datos restringen el conjunto de grafos compatibles con la distribución y, por tanto, permiten recuperar una representación estructural relevante sin asumir necesariamente un modelo causal completo a priori (Spirtes et al., 2000; Pearl, 2009; Kalisch and B"uhlmann, 2007).

Dentro de este marco, el algoritmo PC constituye uno de los métodos más representativos y mejor estudiados. Su esencia consiste en comenzar con un grafo completo y eliminar progresivamente aristas entre variables cuando se detecta que son condicionalmente independientes dadas otras variables. El procedimiento no solo produce una estimación del esqueleto del grafo, sino que también puede orientar parcialmente las aristas en función de la información de independencias y de las restricciones impuestas por la equivalencia de Markov. Sin embargo, la versión clásica del algoritmo es sensible a decisiones locales, al orden de eliminación de aristas y a la calidad de las pruebas estadísticas empleadas. Por este motivo, la literatura ha propuesto numerosas variantes del PC, como versiones estables, orientadas a la eficiencia computacional, o diseñadas para manejar variables latentes, para disminuir estas limitaciones y ampliar su aplicabilidad a escenarios más complejos (Colombo and Maathuis, 2014; Spirtes et al., 2000).

La robustez del algoritmo depende, en gran medida, del tipo de prueba de independencia condicional utilizada. En variables Gaussianas, la dependencia condicional suele evaluarse mediante correlaciones parciales; en variables discretas, se recurren habitualmente a pruebas basadas en tablas de contingencia y criterios de chi-cuadrado; y en escenarios más generales, se adoptan enfoques no

paramétricos o basados en distancia para detectar dependencias complejas. Estos tests permiten decidir si dos variables siguen relacionadas una vez controlado el efecto de un conjunto de variables de confusión. Desde una perspectiva teórica, la conexión entre estas pruebas y la inferencia causal es sólida: bajo supuestos de suficiencia causal, se puede interpretar que las independencias condicionales observadas son manifestaciones de la estructura generadora del proceso, y no solo de una asociación superficial entre variables (Spirtes et al., 2000; Pearl, 2009).

No obstante, la inferencia causal a partir de datos observacionales tiene una limitación esencial: varios DAG equivalentes pueden explicar exactamente las mismas independencias condicionadas. Esto implica que, sin intervenciones o conocimiento previo, ciertos aspectos de la orientación causal permanecen no identificables. La teoría de equivalencia de Markov y la noción de DAG esencial muestran que el problema no es simplemente encontrar un grafo que ajuste los datos, sino identificar la clase de grafos que son indistinguibles desde la observación. Esta idea ha motivado la investigación de procedimientos de orientación parcial y de modelos que incorporen información externa para distinguir entre hipótesis causales equivalentes (Spirtes et al., 2000; Pearl, 2009).

Además, los enfoques puramente basados en restricciones no constituyen la única alternativa dentro del aprendizaje estructural. Existe una línea complementaria de métodos score+search, que evalúan distintas estructuras mediante criterios de ajuste y complejidad, como BIC, BDeu o funciones de verosimilitud penalizada. La combinación de estas estrategias con el enfoque basado en restricciones ha dado lugar a métodos híbridos, cuya lógica consiste en utilizar la fase de independencia condicional para reducir el espacio de soluciones y posteriormente refinar la red mediante una optimización de puntuación. Este tipo de procedimientos suele ofrecer un equilibrio favorable entre interpretabilidad, eficiencia computacional y capacidad predictiva, especialmente cuando el número de variables es elevado (Kalisch and B"uhlmann, 2007; Colombo and Maathuis, 2014).

En este contexto, el presente trabajo se centra en el estado del arte de los métodos constraint-based para el aprendizaje de redes bayesianas, con especial atención a las variantes del algoritmo PC, a las pruebas de independencia condicional, a la relación entre independencia y causalidad, y a la evolución hacia paradigmas híbridos. El objetivo es revisar la literatura más relevante para situar el problema de inferencia estructural dentro del marco teórico del descubrimiento causal y justificar el interés de combinar estrategias estadísticas y causales en la construcción de modelos probabilísticos a partir de datos observacionales.

## 2 Estado del arte

El aprendizaje de redes bayesianas a partir de datos observacionales ha evolucionado a lo largo de las últimas décadas desde dos enfoques principales: métodos basados en restricciones y métodos basados en puntuación. Dentro del primer grupo, el algoritmo PC es uno de los referentes más influyentes. Su idea central es recuperar la estructura causal de un grafo acíclico dirigido (DAG) mediante pruebas sucesivas de independencia condicional entre variables, y eliminar aristas que no son necesarias según la información estadística disponible. Este enfoque parte de la hipótesis de que, bajo condiciones de suficiencia causal y de ciertos supuestos de Markov y de estabilidad, la estructura de independencia de la distribución puede revelar el esqueleto del grafo y, en algunos casos, su orientación parcial. La popularización del algoritmo PC por parte de Spirtes, Glymour y Scheines sentó las bases del descubrimiento causal moderno, y su influencia sigue siendo clara en la literatura actual sobre redes bayesianas y causalidad.

En la práctica, la versión clásica del algoritmo PC presenta varias limitaciones. En primer lugar, depende de un orden de eliminación que puede afectar a la estabilidad de la estimación y a la sensibilidad del procedimiento ante decisiones localmente ambiguas. Para mitigar estos problemas aparecieron varias variantes del algoritmo. Una de las más relevantes es la versión PC-estable o PC-stable, diseñada para reducir la dependencia del orden de las variables al aplicar pruebas de independencia condicional en diferentes etapas del proceso. Esta variante trata de consolidar la estructura de vecindad antes de

eliminar aristas, lo que produce un comportamiento más robusto y más reproducible en conjuntos de datos con tamaños moderados. También se han propuesto versiones orientadas a la eficiencia computacional, como variantes basadas en conjuntos de vecinos máximos, que limitan las comprobaciones locales a subconjuntos relevantes, y variantes que reducen el número de pruebas necesarias mediante estrategias de acotación y preordenamiento. En la literatura especializada se distinguen además formulaciones que intentan recuperar no solo el esqueleto de la red sinó la clase de equivalencia de Markov, es decir, el conjunto de grafos que representan las mismas independencias condicionadas. Esta perspectiva es especialmente importante porque, sin intervenciones o información extra, varios DAG equivalentes son indistinguibles desde los datos observacionales, y por ello muchas metodologías se centran en la identificación de un grafo esencial o de una estructura parcialmente orientada.

Una línea muy relacionada es la del algoritmo FCI (Fast Causal Inference), que extiende el marco PC para modelos con variables latentes y variables de confusión, así como con relaciones de selección. Mientras que el algoritmo PC asume condiciones de suficiencia causal, FCI intenta manejar escenarios más realistas en los que no todas las variables relevantes se observan. Esta consideración es crucial en muchos dominios del mundo real, donde pueden existir factores ocultos no medidos que influyen tanto en las variables observadas como en su relación. En este sentido, la evolución de los métodos basados en restricciones no consiste solo en mejorar la eficiencia del algoritmo original, sino también en ampliar su alcance a contextos causales más generales. Además, variantes como RFCI, PC-Max o métodos de orientación parcial han mostrado que es posible combinar la lógica de independencia condicional con procedimientos de selección de vecinos y orientación de aristas para lograr estimaciones más estables y más interpretables.

La confianza del algoritmo PC y de sus variantes depende directamente de la calidad de la prueba de independencia condicional utilizada. Para variables Gaussianas, la prueba clásica se basa en la correlación parcial, en la que la dependencia entre dos variables condicionadas a un conjunto S se evalúa a partir del coeficiente de correlación parcial. En este caso, la estadística de prueba suele estar asociada a la distribución normal de Fisher z o a una transformación basada en el estadístico t, que permite decidir si una correlación parcial es significativamente distinta de cero. Cuando las variables son discretas, se utilizan habitualmente pruebas basadas en tablas de contingencia, como la prueba de chi-cuadrado o el estadístico G de likelihood-ratio, que comparan la independencia condicional con modelos alternativos que capturan la dependencia. Para escenarios no lineales o no Gaussianos, el campo ha avanzado hacia pruebas más flexibles, incluyendo enfoques basados en distancia, kernels, permutaciones y medidas de dependencia generalizadas. La idea común es evaluar si la distribución conjunta de dos variables condicionadas a un conjunto S coincide con el producto de las distribuciones marginales condicionadas. En otras palabras, se busca detectar si la información que una variable aporta sobre otra persiste una vez controlado el efecto del conjunto de variables condicionantes. La elección entre estas pruebas no es trivial: mientras las pruebas paramétricas son más eficientes cuando se cumplen sus supuestos, las pruebas no paramétricas suelen ser más robustas ante desviaciones de normalidad y modelos más complejos.

El papel de la causalidad es esencial para entender por qué estos métodos tienen sentido. El objetivo no es solo modelar asociaciones observadas, sino inferir, en la medida de lo posible, relaciones causales entre variables. En la tradición causal de Spirtes, Glymour y Pearl, el conocimiento causal se representa mediante grafos dirigidos y la noción de estructura de independencias. La causalidad no se define solo como correlación entre variables, sino como la capacidad de intervenir sobre una variable y observar cambios en otras. En este marco, un DAG puede representar una hipótesis de generación de datos en la que cada arista indica un efecto causal directo, y las independencias condicionales observadas restringen qué grafos son compatibles con esos datos. La distinción entre equivalencia de Markov y causalidad verdadera resulta fundamental: dos redes pueden ser indistinguibles a partir de observaciones pasivas, por lo que la orientación causal completa puede requerir suposiciones adicionales, intervenciones o conocimiento previo. Esta interpretación causal explica la popularidad del enfoque basado en restricciones, ya que conecta las pruebas estadísticas con la inferencia gráfica y con

la construcción de modelos explicativos más allá del mero ajuste predictivo.

A pesar del atractivo del enfoque basado en restricciones, también presenta desafíos importantes. La calidad de la inferencia depende en gran medida del número de muestras, de la potencia de las pruebas de independencia, del tipo de variables implicadas y de la posibilidad de que existan variables ocultas o relaciones no lineales complejas. Por este motivo, la literatura reciente ha incorporado estrategias de regularización, pruebas de independencia robustas y algoritmos híbridos. El enfoque híbrido combina la fase de exploración basada en restricciones con un procedimiento de optimización basado en puntuación. En otras palabras, primero se usa la independencia condicional para reducir el espacio de estructuras posibles y obtener una estimación inicial del grafo; después se refina la estructura mediante un criterio de puntuación, como BIC, BDeu o una verosimilitud penalizada, que selecciona entre las redes candidatas la que mejor equilibra ajuste y complejidad. Este esquema tiene ventajas claras: la fase basada en restricciones aporta una reducción significativa del espacio de búsqueda y la fase de puntuación mejora la calidad de la solución localmente. Métodos híbridos, como MMHC (Max-Min Hill Climbing) o variantes que combinan el PC con búsqueda local, han demostrado ser competitivos frente a enfoques puramente score-based o puramente constraint-based, especialmente en escenarios con muchas variables y alta dimensionalidad.

Dentro de este panorama, el estado del arte sugiere que la inferencia causal de redes bayesianas no se centra en un único algoritmo universal, sino en una familia de metodologías con distintos compromisos entre precisión, eficiencia computacional y supuestos causales. El algoritmo PC y sus variantes siguen siendo una pieza central por su interpretabilidad y su capacidad para conectar datos con estructuras causales. La selección de pruebas de independencia condicional condiciona la sensibilidad y la robustez del método, mientras que la consideración de variables latentes y la combinación con optimización basada en puntuación abren nuevas posibilidades para modelar problemas reales. En consecuencia, la investigación actual se orienta hacia métodos que integran mecanismos de causalidad, estimación estadística y aprendizaje estructural, en busca de modelos cada vez más fiables, explicables y útiles para la toma de decisiones.

En resumen, el avance del aprendizaje basado en restricciones ha permitido pasar de una visión puramente descriptiva de las dependencias entre variables a un marco de inferencia causal más formal, donde el papel del algoritmo PC, las pruebas de independencia condicional y los enfoques híbridos resulta esencial para comprender cómo aprender estructuras probabilísticas a partir de datos observacionales.

## 3 Conclusiones y líneas futuras

Propias.

## References


Diego Colombo and Marloes H. Maathuis. Order-independent constraint-based causal structure learning. *Journal of Machine Learning Research*, 15:3921–3962, 2014.

Markus Kalisch and Peter B"uhlmann. Estimating high-dimensional directed acyclic graphs with the pc-algorithm. *Journal of Machine Learning Research*, 8:613–636, 2007.

Judea Pearl. *Causality: Models, Reasoning, and Inference*. Cambridge University Press, New York, 2 edition, 2009.

Peter Spirtes, Clark Glymour, and Richard Scheines. *Causation, Prediction, and Search*. MIT Press, Cambridge, MA, 2000.