Constraint-based learning: Variants of the PC algorithm, hypothesis tests for testing conditional independence, causality, hybrid (constraint based and score+search

Damián Benasco Sánchez
Thales Camargo
Juan David Cárdenas
Universidad Politécnica de Madrid, Spain

Abstract

resumen resumen resumen

1 Introducción

Las redes bayesianas son modelos gráficos probabilísticos que representan un conjunto de variables aleatorias y sus dependencias condicionales mediante un Grafo Acíclico Dirigido (DAG) y un conjunto de parámetros de distribución condicional (Spirtes et al., 2000). En los desarrollos iniciales de este campo, la estructura y los parámetros de una red bayesiana se construían principalmente a través del conocimiento directo de expertos del dominio(cite??). Sin embargo, la especificación manual por expertos presenta severas limitaciones en sistemas complejos, de alta dimensión o emergentes, donde las relaciones subyacentes son desconocidas, subjetivas o demasiado extensas para ser modeladas manualmente (Spirtes et al., 2000; Averin et al., 2026).

Como alternativa, las redes bayesianas descubiertas a partir de datos (data-driven Bayesian network learning) automatizan la reconstrucción de la topología gráfica y la estimación de parámetros mediante el análisis de bases de datos observacionales o experimentales[1][2]. En este paradigma de descubrimiento automático, todas las variables reciben un tratamiento simétrico —sin necesidad de predefinir variables objetivo supervisadas o clases latentes— para extraer directamente del conjunto de datos las asociaciones probabilísticas y los mecanismos causales subyacentes[2][3].

Dentro del aprendizaje de estructuras guiado por datos, la literatura divide tradicionalmente los métodos en tres familias: métodos basados en puntuación y búsqueda (score+search), métodos basados en restricciones y métodos híbridos [4].El aprendizaje basado en restricciones (constraint-based learning) infiere la estructura gráfica de una red bayesiana evaluando sistemáticamente pruebas estadísticas de hipótesis de independencia condicional (CI) sobre los datos [6]. Su fundamento teórico reposa en la Condición de Markov Causal y la Condición de Lealtad (Faithfulness), las cuales establecen una correspondencia biunívoca entre las independencias condicionales presentes en la distribución de datos y el criterio gráfico de d-separación en el DAG [10].Los algoritmos canónicos de esta familia, como el algoritmo PC (Peter-Clark) o FCI (Fast Causal Inference), operan en fases secuenciales transparentes[8]:

1. **Estimación del Esqueleto:** Parten de un grafo no dirigido completamente conectado y evalúan iterativamente pruebas $X \perp\!\!\!\perp Y \mid S$ incrementando paulatinamente el tamaño del conjunto de condicionamiento S ($|S| = 0, 1, 2, \dots$)[10, 13]. Si una prueba estadística no logra rechazar la hipótesis nula de independencia condicional, la arista $X - Y$ es eliminada y el conjunto S se registra como conjunto de separación (sepset)[8].

2. **Orientación de Aristas:** Evalúan las tripletas no protegidas $X - Z - Y$; si el nodo intermedio Z no pertenece al conjunto de separación de X e Y, la tripleta se orienta como un colisionador o estructura en v $(X \rightarrow Z \leftarrow Y)$[10]. Posteriormente, se aplican reglas deterministas de propagación para orientar aristas adicionales sin crear nuevos colisionadores ni ciclos dirigidos[10, 16].

La ventaja fundamental del aprendizaje basado en restricciones es su interpretabilidad y transparencia, ya que cada decisión de mantener, eliminar u orientar una arista puede rastrearse directamente hasta un resultado estadístico concreto[8, 17].

A pesar de sus sólidas garantías teóricas en el límite de muestras infinitas, el aprendizaje basado en restricciones enfrenta limitaciones críticas en escenarios del mundo real con muestras finitas. En primer lugar, se produce una propagación de errores e inestabilidad debido a que el algoritmo toma decisiones categóricas e irreversibles, ya sea conservar o eliminar una arista, en las primeras fases del proceso[18, 19]. Si una prueba estadística comete un error de Tipo I o Tipo II por causa de ruido estadístico o un tamaño muestral reducido, dicha decisión errónea altera los conjuntos de adyacencia de las pruebas subsecuentes, desencadenando una propagación de errores en cascada que corrompe la orientación de estructuras en v y la topología final del grafo[17]. En segundo lugar, ocurre una pérdida de potencia en test de alto orden; a medida que aumenta la cardinalidad del conjunto de condicionamiento S, las pruebas estadísticas pierden potencia drásticamente o exigen volúmenes de datos impracticables, lo que genera falsas independencias y bloqueos en el algoritmo[23]. Por último, existe una fuerte dependencia del orden de entrada, donde la secuencia en la que se procesan los pares de variables en el algoritmo original puede alterar el esqueleto final recuperado[10, 28].

Para solventar estas debilidades surgen los métodos híbridos (*hybrid methods*), los cuales combinan las fortalezas complementarias del aprendizaje basado en restricciones y de los métodos basados en puntuación y búsqueda (*score+search*)[4]. Un algoritmo híbrido opera típicamente en dos fases integradas[29]. Durante la fase de restricción o poda del espacio, se utilizan pruebas de independencia condicional o algoritmos de búsqueda local de mantos de Markov (*Markov blankets*) para eliminar aristas inverosímiles y definir un esqueleto o espacio de búsqueda fuertemente acotado[4]. A continuación, en la fase de maximización u optimización de puntuación, se aplica una búsqueda heurística, tales como *Hill-Climbing* o *Greedy Equivalence Search*, guiada por una función de puntuación global (como BIC, BDe o métricas Bayesianas) sobre el espacio restringido para hallar la estructura óptima que maximice el ajuste a los datos[5]. Al podar drásticamente el espacio combinatorio mediante restricciones locales y evaluar la estructura final por medio de un criterio de bondad de ajuste global, los métodos híbridos logran un equilibrio idóneo, ya que conservan la velocidad computacional del enfoque basado en restricciones y la robustez estadística frente a errores locales propia del enfoque basado en puntuación.

En este contexto, el presente trabajo se centra en el estado del arte de los métodos *constraint-based* para el aprendizaje de redes bayesianas, con especial atención a las variantes del algoritmo PC (como PC-Stable, CPC, cuPC, PCstar o CTPC)[20], a las pruebas de independencia condicional[4], a la relación entre independencia y causalidad[1], y a la evolución hacia paradigmas híbridos y enfoques diferenciables o de optimización lógica (como BCCD, COmbINE, ASP y DAGPA)[31]. El objetivo es revisar la literatura más relevante para situar el problema de inferencia estructural dentro del marco teórico del descubrimiento causal y justificar el interés de combinar estrategias estadísticas y causales en la construcción de modelos probabilísticos a partir de datos observacionales[1]

citation examplecompleto a priori (Spirtes et al., 2000; Pearl, 2009; Kalisch and B"uhlmann, 2007).

2 Estado del arte

El aprendizaje de redes bayesianas a partir de datos observacionales ha evolucionado a lo largo de las últimas décadas desde dos enfoques principales: métodos basados en restricciones y métodos basados en puntuación. Dentro del primer grupo, el algoritmo PC es uno de los referentes más influyentes. Su

idea central es recuperar la estructura causal de un grafo acíclico dirigido (DAG) mediante pruebas sucesivas de independencia condicional entre variables, y eliminar aristas que no son necesarias según la información estadística disponible. Este enfoque parte de la hipótesis de que, bajo condiciones de suficiencia causal y de ciertos supuestos de Markov y de estabilidad, la estructura de independencia de la distribución puede revelar el esqueleto del grafo y, en algunos casos, su orientación parcial. La popularización del algoritmo PC por parte de Spirtes, Glymour y Scheines sentó las bases del descubrimiento causal moderno, y su influencia sigue siendo clara en la literatura actual sobre redes bayesianas y causalidad.

En la práctica, la versión clásica del algoritmo PC presenta varias limitaciones. En primer lugar, depende de un orden de eliminación que puede afectar a la estabilidad de la estimación y a la sensibilidad del procedimiento ante decisiones localmente ambiguas. Para mitigar estos problemas aparecieron varias variantes del algoritmo. Una de las más relevantes es la versión PC-estable o PC-stable, diseñada para reducir la dependencia del orden de las variables al aplicar pruebas de independencia condicional en diferentes etapas del proceso. Esta variante trata de consolidar la estructura de vecindad antes de eliminar aristas, lo que produce un comportamiento más robusto y más reproducible en conjuntos de datos con tamaños moderados. También se han propuesto versiones orientadas a la eficiencia computacional, como variantes basadas en conjuntos de vecinos máximos, que limitan las comprobaciones locales a subconjuntos relevantes, y variantes que reducen el número de pruebas necesarias mediante estrategias de acotación y preordenamiento. En la literatura especializada se distinguen además formulaciones que intentan recuperar no solo el esqueleto de la red sinó la clase de equivalencia de Markov, es decir, el conjunto de grafos que representan las mismas independencias condicionadas. Esta perspectiva es especialmente importante porque, sin intervenciones o información extra, varios DAG equivalentes son indistinguibles desde los datos observacionales, y por ello muchas metodologías se centran en la identificación de un grafo esencial o de una estructura parcialmente orientada.

Una línea muy relacionada es la del algoritmo FCI (Fast Causal Inference), que extiende el marco PC para modelos con variables latentes y variables de confusión, así como con relaciones de selección. Mientras que el algoritmo PC asume condiciones de suficiencia causal, FCI intenta manejar escenarios más realistas en los que no todas las variables relevantes se observan. Esta consideración es crucial en muchos dominios del mundo real, donde pueden existir factores ocultos no medidos que influyen tanto en las variables observadas como en su relación. En este sentido, la evolución de los métodos basados en restricciones no consiste solo en mejorar la eficiencia del algoritmo original, sino también en ampliar su alcance a contextos causales más generales. Además, variantes como RFCI, PC-Max o métodos de orientación parcial han mostrado que es posible combinar la lógica de independencia condicional con procedimientos de selección de vecinos y orientación de aristas para lograr estimaciones más estables y más interpretables.

La confianza del algoritmo PC y de sus variantes depende directamente de la calidad de la prueba de independencia condicional utilizada. Para variables Gaussianas, la prueba clásica se basa en la correlación parcial, en la que la dependencia entre dos variables condicionadas a un conjunto S se evalúa a partir del coeficiente de correlación parcial. En este caso, la estadística de prueba suele estar asociada a la distribución normal de Fisher z o a una transformación basada en el estadístico t, que permite decidir si una correlación parcial es significativamente distinta de cero. Cuando las variables son discretas, se utilizan habitualmente pruebas basadas en tablas de contingencia, como la prueba de chi-cuadrado o el estadístico G de likelihood-ratio, que comparan la independencia condicional con modelos alternativos que capturan la dependencia. Para escenarios no lineales o no Gaussianos, el campo ha avanzado hacia pruebas más flexibles, incluyendo enfoques basados en distancia, kernels, permutaciones y medidas de dependencia generalizadas. La idea común es evaluar si la distribución conjunta de dos variables condicionadas a un conjunto S coincide con el producto de las distribuciones marginales condicionadas. En otras palabras, se busca detectar si la información que una variable aporta sobre otra persiste una vez controlado el efecto del conjunto de variables condicionantes. La elección entre estas pruebas no es trivial: mientras las pruebas paramétricas son más eficientes cuando

se cumplen sus supuestos, las pruebas no paramétricas suelen ser más robustas ante desviaciones de normalidad y modelos más complejos.

El papel de la causalidad es esencial para entender por qué estos métodos tienen sentido. El objetivo no es solo modelar asociaciones observadas, sino inferir, en la medida de lo posible, relaciones causales entre variables. En la tradición causal de Spirtes, Glymour y Pearl, el conocimiento causal se representa mediante grafos dirigidos y la noción de estructura de independencias. La causalidad no se define solo como correlación entre variables, sino como la capacidad de intervenir sobre una variable y observar cambios en otras. En este marco, un DAG puede representar una hipótesis de generación de datos en la que cada arista indica un efecto causal directo, y las independencias condicionales observadas restringen qué grafos son compatibles con esos datos. La distinción entre equivalencia de Markov y causalidad verdadera resulta fundamental: dos redes pueden ser indistinguibles a partir de observaciones pasivas, por lo que la orientación causal completa puede requerir suposiciones adicionales, intervenciones o conocimiento previo. Esta interpretación causal explica la popularidad del enfoque basado en restricciones, ya que conecta las pruebas estadísticas con la inferencia gráfica y con la construcción de modelos explicativos más allá del mero ajuste predictivo.

A pesar del atractivo del enfoque basado en restricciones, también presenta desafíos importantes. La calidad de la inferencia depende en gran medida del número de muestras, de la potencia de las pruebas de independencia, del tipo de variables implicadas y de la posibilidad de que existan variables ocultas o relaciones no lineales complejas. Por este motivo, la literatura reciente ha incorporado estrategias de regularización, pruebas de independencia robustas y algoritmos híbridos. El enfoque híbrido combina la fase de exploración basada en restricciones con un procedimiento de optimización basado en puntuación. En otras palabras, primero se usa la independencia condicional para reducir el espacio de estructuras posibles y obtener una estimación inicial del grafo; después se refina la estructura mediante un criterio de puntuación, como BIC, BDeu o una verosimilitud penalizada, que selecciona entre las redes candidatas la que mejor equilibra ajuste y complejidad. Este esquema tiene ventajas claras: la fase basada en restricciones aporta una reducción significativa del espacio de búsqueda y la fase de puntuación mejora la calidad de la solución localmente. Métodos híbridos, como MMHC (Max-Min Hill Climbing) o variantes que combinan el PC con búsqueda local, han demostrado ser competitivos frente a enfoques puramente score-based o puramente constraint-based, especialmente en escenarios con muchas variables y alta dimensionalidad.

Dentro de este panorama, el estado del arte sugiere que la inferencia causal de redes bayesianas no se centra en un único algoritmo universal, sino en una familia de metodologías con distintos compromisos entre precisión, eficiencia computacional y supuestos causales. El algoritmo PC y sus variantes siguen siendo una pieza central por su interpretabilidad y su capacidad para conectar datos con estructuras causales. La selección de pruebas de independencia condicional condiciona la sensibilidad y la robustez del método, mientras que la consideración de variables latentes y la combinación con optimización basada en puntuación abren nuevas posibilidades para modelar problemas reales. En consecuencia, la investigación actual se orienta hacia métodos que integran mecanismos de causalidad, estimación estadística y aprendizaje estructural, en busca de modelos cada vez más fiables, explicables y útiles para la toma de decisiones.

En resumen, el avance del aprendizaje basado en restricciones ha permitido pasar de una visión puramente descriptiva de las dependencias entre variables a un marco de inferencia causal más formal, donde el papel del algoritmo PC, las pruebas de independencia condicional y los enfoques híbridos resulta esencial para comprender cómo aprender estructuras probabilísticas a partir de datos observacionales.

3 Conclusiones y líneas futuras

Propias.

References

Pavel Averin, Theodoros Moysiadis, and Ioannis Katakis. Conditional independence tests for constraint-based causal discovery: A survey. *arXiv preprint arXiv:2608.11156*, 2026.

Markus Kalisch and Peter B"uhlmann. Estimating high-dimensional directed acyclic graphs with the pc-algorithm. *Journal of Machine Learning Research*, 8:613–636, 2007.

Judea Pearl. *Causality: Models, Reasoning, and Inference*. Cambridge University Press, New York, 2 edition, 2009.

Peter Spirtes, Clark Glymour, and Richard Scheines. *Causation, Prediction, and Search*. MIT Press, Cambridge, MA, 2000.