# Constraint-based learning: Variants of the PC algorithm, hypothesis tests for testing conditional independence, causality, hybrid (constraint based and score+search)

Damián Benasco Sánchez
Thales Camargo
Juan David Cárdenas
Universidad Politécnica de Madrid, Spain

**Resumen**

Las redes bayesianas son modelos gráficos probabilísticos que permiten representar de forma compacta e interpretable las dependencias condicionales entre un conjunto de variables aleatorias. Cuando la estructura de estos modelos no puede especificarse a partir del conocimiento experto, el aprendizaje estructural a partir de datos permite reconstruirla, y la literatura distingue tres familias de métodos: basados en puntuación y búsqueda, basados en restricciones e híbridos. Este trabajo revisa el estado del arte del aprendizaje basado en restricciones, con el algoritmo PC como eje central. Se examinan sus fundamentos teóricos (condición de Markov causal, fidelidad y d-separación) y las cinco limitaciones que surgen en muestras finitas: ausencia de garantías en alta dimensión, dependencia del orden de las variables, pérdida de potencia al crecer el conjunto de condicionamiento, coste computacional y rigidez de los supuestos. Para cada una se analizan las variantes propuestas, desde CPC, PC-stable y k-PC hasta las versiones paralelas, las extensiones para series temporales, eventos extremos y variables latentes, y las formulaciones diferenciables. A continuación se comparan las pruebas de independencia condicional (correlación parcial, tablas de contingencia, métodos de regresión y contrastes no paramétricos basados en kernel) junto con sus extensiones causales, subrayando que ninguna es universal. Por último, se estudian los enfoques híbridos, que combinan restricciones y optimización por puntuación para mitigar la propagación de errores, y se discuten sus limitaciones. La revisión concluye que el rendimiento depende de la interacción entre potencia estadística, coste y supuestos causales, y que no existe una estrategia dominante. Todo ello sitúa el problema de la inferencia estructural dentro del marco del descubrimiento causal a partir de datos observacionales.

**Palabras clave:** redes bayesianas, aprendizaje estructural, algoritmo PC, independencia condicional, descubrimiento causal, métodos híbridos.

## 1. Introducción

Las redes bayesianas son modelos gráficos probabilísticos que representan un conjunto de variables aleatorias y sus dependencias condicionales mediante un grafo acíclico dirigido (DAG) y un conjunto de distribuciones condicionales (Pearl, 2009; Lauritzen, 1996). Inicialmente, su estructura se especificaba a partir del conocimiento experto, una estrategia limitada en sistemas complejos, de alta dimensión o con relaciones poco conocidas (Scanagatta et al., 2019; Kitson et al., 2023).

El aprendizaje estructural automatiza la construcción del grafo a partir de datos observacionales o experimentales y, cuando el grafo se interpreta causalmente, permite inferir mecanismos causales y no solo asociaciones (Spirtes et al., 2000; Glymour et al., 2019). La literatura distingue tres familias de métodos: basados en puntuación y búsqueda, basados en restricciones e híbridos (Scanagatta et al., 2019; Kitson et al., 2023).

El aprendizaje basado en restricciones (*constraint-based*) infiere la estructura mediante pruebas de independencia condicional (Spirtes et al., 2000; Averin et al., 2026). Se apoya en la condición de Markov causal y en la fidelidad (*faithfulness*), que hacen corresponder las independencias de los datos con la $d$-separación en el DAG (Spirtes et al., 2000; Pearl, 2009). Su algoritmo canónico, el PC (Peter-Clark), elimina primero las aristas entre variables condicionalmente independientes y orienta después las restantes (Spirtes and Glymour, 1991). Cada decisión puede rastrearse hasta una prueba estadística concreta, lo que le confiere una interpretabilidad característica (Glymour et al., 2019; Averin et al., 2026).

En muestras finitas, sin embargo, los errores estadísticos se propagan a decisiones posteriores (Spirtes et al., 2000; Uhler et al., 2013), la potencia de las pruebas cae al crecer el conjunto de condicionamiento (Abellán et al., 2006; Kocaoglu, 2023) y el resultado puede depender del orden de las variables (Colombo and Maathuis, 2014). Los métodos híbridos responden a estas debilidades: una fase de restricción reduce el espacio de soluciones y una búsqueda local optimiza después una puntuación global (Tsamardinos et al., 2006; Kitson et al., 2023).

Este trabajo revisa el estado del arte de los métodos *constraint-based* para redes bayesianas, con atención a las variantes del PC, las pruebas de independencia condicional, la relación entre independencia y causalidad y los enfoques híbridos, situando la inferencia estructural en el marco del descubrimiento causal a partir de datos observacionales.

# 2. Estado del arte

Esta sección se organiza en tres ejes. Primero se examinan el algoritmo PC, sus limitaciones y sus variantes, desde la independencia del orden y la paralelización hasta las extensiones para datos temporales, eventos extremos y optimización diferenciable. Después se analizan las pruebas de independencia condicional, el motor estadístico de las decisiones de poda y orientación. Por último, se estudian los enfoques híbridos, que combinan restricciones y puntuación para mitigar la acumulación de errores en muestras finitas.

## 2.1. El algoritmo PC: fundamentos, limitaciones y variantes

### 2.1.1. Fundamentos y limitaciones

El **algoritmo PC**, llamado así por Peter Spirtes y Clark Glymour (Spirtes and Glymour, 1991), es el método fundacional del aprendizaje basado en restricciones. Mejora al algoritmo SGS, que condiciona sobre todos los subconjuntos posibles del resto de variables, limitando los conjuntos de condicionamiento a los vecinos actuales de cada variable en un grafo que se va podando (Spirtes et al., 2000).

Sea $\mathbf{X} = (X_1, \ldots, X_n)$ un conjunto de variables con distribución conjunta $P$, y sea $I(X, Y \mid \mathbf{S})$ la independencia condicional de $X$ e $Y$ dado el conjunto $\mathbf{S}$. El PC supone que $P$ es *fiel* a un DAG $G$, es decir, que las independencias de $P$ son exactamente las $d$-separaciones de $G$, y que no existen causas comunes latentes (*suficiencia causal*). Bajo estos supuestos, $X$ e $Y$ no son adyacentes en $G$ si y solo si existe un conjunto $\mathbf{S}$, contenido en los vecinos de $X$ o en los de $Y$, tal que $I(X, Y \mid \mathbf{S})$ (Spirtes et al., 2000; Abellán et al., 2006). El algoritmo explota esta propiedad en dos fases. En la primera (Algoritmo 1) parte del grafo completo no dirigido y elimina aristas mediante contrastes de orden creciente $\ell = |\mathbf{S}|$, guardando el conjunto separador $\mathbf{S}_{XY}$ de cada arista eliminada.

**Algoritmo 1** Algoritmo PC: fase de búsqueda del esqueleto

Inicializar $G'$ como un grafo completo no dirigido sobre $\mathbf{X}$
$\ell \leftarrow 0$
**repeat**
  **for** cada par adyacente $(X, Y)$ en $G'$ **do**
    **if** existe $\mathbf{S} \subseteq \mathrm{Adj}_{G'}(X) \setminus \{Y\}$ con $|\mathbf{S}| = \ell$ e $I(X, Y \mid \mathbf{S})$ **then**
      Guardar $\mathbf{S}_{XY} \leftarrow \mathbf{S}$ y eliminar la arista $X - Y$ de $G'$
    **end if**
  **end for**
  $\ell \leftarrow \ell + 1$
**until** $|\mathrm{Adj}_{G'}(X)| \leq \ell$ para todo $X \in \mathbf{X}$

En la segunda fase, cada triple no protegido $X - Z - Y$ (con $X$ e $Y$ no adyacentes) se orienta como $X \to Z \leftarrow Y$ si $Z \notin \mathbf{S}_{XY}$, y las reglas de Meek (1995) propagan orientaciones sin crear ciclos ni nuevas estructuras en $v$. El resultado es un grafo parcialmente dirigido (CPDAG) que representa la *clase de equivalencia de Markov* de $G$; sus aristas no dirigidas no son identificables con datos observacionales. Con un oráculo de independencia perfecto, el PC es correcto y completo, y su coste, exponencial en el peor caso, es polinómico si el grado del grafo está acotado (Spirtes et al., 2000; Scanagatta et al., 2019).

En la versión muestral, sin embargo, cada decisión es un contraste sujeto a error, y la naturaleza secuencial del algoritmo da lugar a cinco limitaciones: (i) falta de garantías cuando el número de variables es comparable o superior al tamaño muestral; (ii) dependencia del orden de las variables, pues un error temprano altera los conjuntos de adyacencia de los contrastes posteriores; (iii) pérdida de potencia al crecer $|\mathbf{S}|$; (iv) coste de los contrastes en alta dimensión; y (v) rigidez de los supuestos (datos i.i.d., fidelidad y suficiencia causal) (Colombo and Maathuis, 2014; Kalisch and Bühlmann, 2007).

### 2.1.2. Consistencia en alta dimensión

Kalisch and Bühlmann (2007) respondieron a (i) para datos gaussianos con contrastes de correlación parcial: el PC muestral estima de forma consistente el esqueleto y el CPDAG aunque $p = O(n^a)$ para cualquier $a > 0$, siempre que el grado máximo sea $q_n = O(n^{1-b})$, con $0 < b \leq 1$, y que $\alpha_n$ decrezca con $n$. En simulaciones alcanzó tasas de descubrimiento verdadero superiores a las de búsquedas basadas en BIC, con poca sensibilidad a $\alpha$. El resultado exige, no obstante, que las correlaciones parciales no nulas estén acotadas inferiormente, una forma de *fidelidad fuerte*, y Uhler et al. (2013) mostraron que, a diferencia de la fidelidad ordinaria, su violación tiene medida positiva y crece con el tamaño y la densidad del grafo. Esto explica la fragilidad del PC en muestras finitas.

### 2.1.3. Dependencia del orden

Para preservar la corrección del PC bajo la *fidelidad de adyacencia*, más débil que la fidelidad, Ramsey et al. (2006) propusieron el **PC conservador (CPC)**, que solo orienta un triple no protegido si el nodo central aparece en todos sus conjuntos separadores o en ninguno, y lo marca como ambiguo en caso contrario; así atenúa también la dependencia del orden en la orientación. Colombo and Maathuis (2014) mostraron que, en alta dimensión, permutar las variables altera también el esqueleto. Su **PC-stable** congela los conjuntos de adyacencia al inicio de cada nivel $\ell$, de modo que el esqueleto deja de depender del orden. Combinado con CPC o con una regla de mayoría (**CPC-** y **MPC-stable**), y con listas de conflictos representados por aristas bidireccionales (LCPC/LMPC-stable), toda la salida pasa a ser independiente del orden sin perder la consistencia en alta dimensión. El precio es realizar más contrastes que el PC original, lo que agrava la limitación (iv).

### 2.1.4. Errores en conjuntos de condicionamiento grandes

Cuando $|\mathbf{S}|$ crece, los contrastes pierden potencia. Para datos discretos, Abellán et al. (2006) redujeron los conjuntos de condicionamiento a conjuntos de corte mínimos entre $X$ e $Y$, sustituyeron el contraste $\chi^2$ por una puntuación bayesiana de Dirichlet (BD), que equilibra mejor los errores de tipo I y II, y añadieron un refinamiento voraz final guiado por esa puntuación, que anticipa los enfoques híbridos. Kocaoglu (2023) renunció directamente a los contrastes de orden alto: definió la **$k$-equivalencia de Markov**, según la cual dos DAG son equivalentes si implican las mismas independencias con $|\mathbf{S}| \leq k$, y diseñó **$k$-PC** para aprender esta clase. A cambio de una clase menos informativa, $k$-PC obtuvo en muestras pequeñas mejores F1 que el PC y NOTEARS, y en la red *Asia* evitó el grafo excesivamente disperso que producen los contrastes de orden 2 poco fiables.

### 2.1.5. Escalabilidad computacional

Una vez congeladas las adyacencias como en PC-stable, los contrastes de un mismo nivel son independientes entre sí y pueden paralelizarse. Madsen et al. (2017) lo hicieron con hilos en memoria compartida, agrupando variables mediante diseños de bloques incompletos balanceados (BIB), y con procesos MPI que reparten los casos. Scutari (2017) mostró en `bnlearn` que el *backtracking* degrada la estabilidad a cambio de poca ganancia en velocidad, y propuso un marco paralelo preferible en hardware multinúcleo. Le et al. (2019) desarrollaron **Parallel-PC**, que reparte entre núcleos los contrastes de cada nivel de PC-stable: en DREAM5, con más de 1600 variables, la versión secuencial no terminó en 24 horas y Parallel-PC lo hizo en menos de seis con ocho núcleos.

### 2.1.6. Relajación de supuestos

Para datos no i.i.d., Biswas and Mukherjee (2024) demostraron que el PC sigue siendo consistente en series temporales estacionarias con dependencia de tipo *$\rho$-mixing* o de mezcla fuerte, incluidos los procesos VARMA, y probaron también la consistencia del **Time-Aware PC (TPC)** (Biswas and Shlizerman, 2022), que aprende relaciones retardadas y supera al PC y a la causalidad de Granger en datos simulados y reales. PCMCI (Runge et al., 2019) añade a una fase de tipo PC un contraste que controla los falsos positivos inducidos por la autocorrelación. Para eventos extremos, Améndola et al. (2026) estudiaron las redes bayesianas max-lineales, propias de distribuciones de cola pesada y no fieles a la $d$-separación: probaron que el PC sigue siendo consistente con un oráculo de $*$-separación y propusieron **PCstar**, que asume fidelidad a la $C^*$-separación y orienta aristas adicionales. La relajación de la suficiencia causal se trata en la Sección 2.2.

### 2.1.7. De decisiones discretas a restricciones diferenciables

Todas estas variantes conservan decisiones binarias e irrevocables. **DAGPA** (Zhou et al., 2025) relaja la $d$-separación a una función diferenciable sobre una matriz de probabilidades de arista, mediante percolación y lógica difusa, y optimiza por gradiente su concordancia con los p-valores de los datos, usados como etiquetas suaves. Resultó robusto en muestras pequeñas y superó a referencias basadas en restricciones y en puntuación sobre el conjunto de Sachs, en la frontera con los enfoques híbridos (Sección 2.3).

La Tabla 1, en el Apéndice A, resume estas variantes según la limitación que abordan.

## 2.2. Pruebas de Independencia Condicional y Extensiones para Causalidad

Las pruebas de independencia condicional (IC) constituyen el motor estadístico del aprendizaje estructural basado en restricciones, pues cada decisión de poda y de orientación del esqueleto del grafo se reduce a determinar si dos variables son dependientes o independientes dado un conjunto de condicionamiento (Spirtes et al., 2000; Averin et al., 2026). A diferencia de las funciones de puntuación (score), que evalúan estructuras completas, el contraste IC es una decisión local y contrastable individualmente, lo que explica la interpretabilidad característica de los métodos *constraint-based*, en los que cada arista eliminada o conservada puede rastrearse hasta un conjunto de contrastes estadísticos concreto y sus p-valores (Averin et al., 2026; Spirtes et al., 2000). La Figura 1 resume el criterio de elección entre las familias de contrastes que se describen a continuación.

Formalmente, dada una distribución de probabilidad $P$ sobre un conjunto de variables $\mathbf{X} = (X_1, \ldots, X_n)$, la notación $I(\mathbf{X}, \mathbf{Y} \mid \mathbf{Z})$ denota que los conjuntos $\mathbf{X}$ e $\mathbf{Y}$ son condicionalmente independientes dado $\mathbf{Z}$, esto es, $P(\mathbf{X}, \mathbf{Y} \mid \mathbf{Z}) = P(\mathbf{X} \mid \mathbf{Z})\, P(\mathbf{Y} \mid \mathbf{Z})$. Un contraste de IC procede sobre una muestra finita y confronta la hipótesis nula de independencia condicional $I(\mathbf{X}, \mathbf{Y} \mid \mathbf{Z})$ con la alternativa de dependencia condicional, controlando al nivel $\alpha$ la probabilidad de falso rechazo. La relevancia de estas decisiones radica en su correspondencia con la estructura del grafo, ya que, bajo las condiciones de Markov causal y fidelidad, una distribución es fiel a un DAG $G$ si y solo si, para todo par de conjuntos disjuntos de vértices $\mathbf{X}$, $\mathbf{Y}$ y todo conjunto $\mathbf{Z}$ disjunto de ambos, $I(\mathbf{X}, \mathbf{Y} \mid \mathbf{Z})$ si y solo si $\mathbf{X}$ e $\mathbf{Y}$ están $d$-separados por $\mathbf{Z}$ (Spirtes et al., 2000). Expresado matemáticamente:

$$P(X_1, \ldots, X_n) = \prod_{i=1}^{n} P(X_i \mid \mathrm{Pa}(X_i)) \iff \forall\, X, Y, \mathbf{Z} \text{ disjuntos}: \quad I(X, Y \mid \mathbf{Z}) \iff \mathbf{X} \perp_G \mathbf{Y} \mid \mathbf{Z}$$

Los algoritmos explotan esta equivalencia tratando cada resultado de un contraste como un hecho de $d$-separación, las independencias detectadas eliminan aristas y las dependencias restantes guían la orientación, de modo que la calidad del grafo aprendido queda acotada por la calidad de las decisiones estadísticas (Spirtes et al., 2000; Pearl, 2009). Los contrastes disponibles se pueden ordenar según la

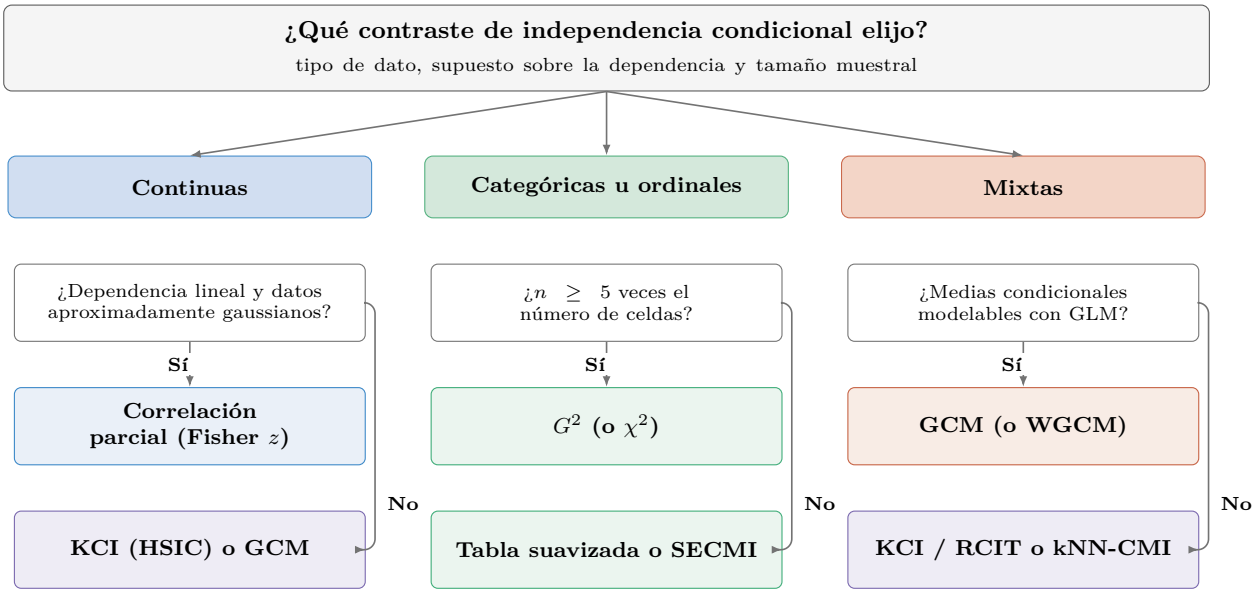



Figura 1: Guía para elegir el contraste de independencia condicional según el tipo de dato, el supuesto sobre la dependencia y el tamaño muestral. La rama *Sí* conduce al contraste recomendado y la rama *No* a su alternativa.

estructura que asumen sobre la dependencia, desde los paramétricos clásicos hasta los no paramétricos, y ninguno es universal, ya que todo contraste restringe implícitamente el tipo de dependencia que puede detectar y paga esa restricción con pérdida de potencia frente al resto de alternativas (Shah and Peters, 2020).

### 2.2.1. Correlación parcial

Para datos continuos, el contraste clásico es la **correlación parcial**. Bajo normalidad conjunta, $I(X, Y \mid \mathbf{Z})$ equivale a la anulación de la correlación parcial (Lauritzen, 1996). Para cada contraste se toman las observaciones de $X$, $Y$ y las variables de $\mathbf{Z}$, es decir, $\mathbf{w}_i = (x_i, y_i, \mathbf{z}_i)$ con $\mathbf{z}_i \in \mathbb{R}^{|\mathbf{Z}|}$, y se calcula su matriz de covarianzas muestral

$$S = \frac{1}{n-1} \sum_{i=1}^{n} (\mathbf{w}_i - \bar{\mathbf{w}})(\mathbf{w}_i - \bar{\mathbf{w}})^\top \in \mathbb{R}^{(|\mathbf{Z}|+2)\times(|\mathbf{Z}|+2)},$$

cuya inversa, $\hat{K} = S^{-1}$, proporciona la correlación parcial muestral entre $X$ e $Y$ dado $\mathbf{Z}$,

$$\hat{\rho}_{XY\cdot\mathbf{Z}} = \frac{-\hat{K}_{XY}}{\sqrt{\hat{K}_{XX}\,\hat{K}_{YY}}}.$$

El contraste aplica la transformada $z$ de Fisher (Hotelling, 1953) a ese valor muestral,

$$z(r) = \tfrac{1}{2} \ln \frac{1+r}{1-r}, \qquad T = \sqrt{n - |\mathbf{Z}| - 3}\, z(\hat{\rho}_{XY\cdot\mathbf{Z}}),$$

de modo que se rechaza la hipótesis de independencia cuando $|T|$ supera el cuantil $z_{1-\alpha/2}$ de una normal estándar. Su ventaja principal es el coste, ya que, con la matriz de covarianzas muestral previamente calculada, cada contraste se reduce a invertir el bloque correspondiente, con $O(|\mathbf{Z}|^3)$ operaciones, y sus p-valores son analíticos, sin remuestreo, lo que lo convierte en el contraste habitual para datos continuos en las implementaciones de referencia (Kalisch et al., 2012; Scutari, 2010), y el que sostiene la consistencia del PC en alta dimensión bajo estructuras poco densas (Kalisch and Bühlmann, 2007). Su limitación es simétrica, pues la equivalencia entre correlación parcial nula e independencia condicional vale solo bajo normalidad y linealidad.

Recientes líneas de investigación tratan de dotar de robustez a estos contrastes frente a violaciones parciales del modelo. Cuando la varianza del error no es constante, las versiones ponderadas (WLS) conservan la estructura del contraste y recuperan su calibración (Günther et al., 2022). Cuando la distribución se aleja de la normalidad, los contrastes basados en correlaciones de rango mantienen la consistencia del PC bajo modelos no gaussianos o de cópula gaussiana, con un coste computacional apenas mayor (Harris and Drton, 2012). En muestras pequeñas, los esquemas de permutación corrigen la aproximación asintótica del p-valor (Tsamardinos and Borboudakis, 2010).

### 2.2.2. Tablas de contingencia

Para datos discretos, el contraste clásico es el de **tablas de contingencia**, empleado en los algoritmos de aprendizaje de estructura cuando las variables son categóricas (Kitson et al., 2023). Cada celda de la tabla conjunta recoge cuántas observaciones caen en una combinación de valores de $X$, $Y$ y las variables de $\mathbf{Z}$, y la hipótesis de independencia impone un valor esperado para cada frecuencia. El contraste mide la discrepancia entre los conteos observados y los esperados.

Denotamos por $n_{ijk}$ el número de observaciones de la muestra en las que $X$ toma su valor $i$, $Y$ su valor $j$ y $\mathbf{Z}$ su $k$-ésima combinación de valores, y escribimos $n_{i\cdot k}$, $n_{\cdot jk}$ y $n_{\cdot\cdot k}$ para las sumas de $n_{ijk}$ sobre el índice sustituido por el punto. Los esperados bajo independencia se calculan precisamente a partir de esas sumas,

$$E_{ijk} = \frac{n_{i\cdot k}\, n_{\cdot jk}}{n_{\cdot\cdot k}},$$

y los dos estadísticos clásicos son

$$\chi^2 = \sum_{i,j,k} \frac{(n_{ijk} - E_{ijk})^2}{E_{ijk}}, \qquad G^2 = 2 \sum_{i,j,k} n_{ijk} \ln \frac{n_{ijk}}{E_{ijk}}.$$

Ambos se distribuyen asintóticamente como una $\chi^2_\nu$ con $\nu = (I-1)(J-1)\prod_l K_l$ grados de libertad (Spirtes et al., 2000; Kitson et al., 2023), donde $K_l$ es el número de valores de la $l$-ésima variable de $\mathbf{Z}$, de modo que se rechaza la independencia cuando el estadístico supera el cuantil $\chi^2_{\nu,1-\alpha}$. El estadístico $G^2$ es la versión discreta del contraste de razón de verosimilitud y es proporcional a la información mutua condicional, $G^2 = 2n\,\hat{\mathrm{I}}(X, Y \mid \mathbf{Z})$, por lo que los contrastes de información mutua (MI) que usan por defecto las implementaciones de referencia pertenecen a esta misma familia (Scutari, 2010).

Su ventaja es ser el contraste canónico para datos categóricos, con p-valores analíticos y una lectura directa como divergencia entre la tabla observada y la que se esperaría bajo independencia. Cabe destacar que en las simulaciones originales del PC, $G^2$ condujo al grafo correcto con más frecuencia que $\chi^2$ (Spirtes et al., 2000). Una de las principales limitaciones es el crecimiento exponencial del número de celdas con respecto a $|\mathbf{Z}|$ y a la cardinalidad de las variables, $I \cdot J \cdot \prod_l K_l$ celdas. Esto hace que los conteos esperados se estimen con pocas observaciones por celda y la aproximación $\chi^2$ deje de ser fiable. Las reglas prácticas exigen un tamaño muestral de al menos cinco veces el número de celdas para estimar con garantías, o asumir dependencia cuando $n < 10\times$ el número de celdas (Spirtes et al., 2000). El coste de calcular el estadístico es lineal en el número de celdas, pero ese número es justamente el cuello de botella.

Las líneas recientes atacan precisamente esta escasez de datos. Dash (2003) propuso una tabla de contingencia suavizada, compatible con cualquier estadístico de tabla, que incorpora *priors* y puede calcularse incluso con bases de datos incompletas, y mostró que mejora la recuperación estructural y reduce la divergencia de KL frente al contraste estándar, incluso con *priors* no informativos y sobre todo con muestras pequeñas o muchas variables. Y en la práctica, la calibración asintótica puede sustituirse por permutaciones o por esquemas semiparamétricos que corrigen el comportamiento en muestra pequeña, tal y como ofrecen las implementaciones de referencia (Scutari, 2010; Tsamardinos and Borboudakis, 2010).

### 2.2.3. Regresión y métodos de residuos

Otra vía, natural cuando los datos son mixtos, consiste en no modelar la dependencia directamente sino eliminar el efecto de $\mathbf{Z}$ mediante regresión y contrastar la asociación de lo que queda. Se ajustan las regresiones de $X$ y de $Y$, dadas por las funciones $\hat{m}_X(\mathbf{z}) = \widehat{\mathbb{E}}[X \mid \mathbf{Z} = \mathbf{z}]$ y $\hat{m}_Y(\mathbf{z}) = \widehat{\mathbb{E}}[Y \mid \mathbf{Z} = \mathbf{z}]$, y se toman los residuos $r_i = x_i - \hat{m}_X(\mathbf{z}_i)$ y $s_i = y_i - \hat{m}_Y(\mathbf{z}_i)$. La independencia condicional implica que sus productos $R_i = r_i s_i$ tienen media cero (Shah and Peters, 2020). La versión general, conocida como medida de covarianza generalizada (GCM), se construye sobre la media muestral $\bar{R}$ de esos productos,

$$T_n = \frac{\sqrt{n}\,\bar{R}}{\hat{\sigma}_R}, \qquad \hat{\sigma}^2_R = \frac{1}{n}\sum_{i=1}^{n}(R_i - \bar{R})^2,$$

que bajo la hipótesis nula converge a una normal estándar siempre que las regresiones estimen las medias condicionales con el producto de sus errores cuadráticos medios de orden $o(n^{-1})$ (Shah and Peters, 2020). En el caso lineal y gaussiano este contraste coincide, salvo detalles de normalización, con el de la correlación parcial ya presentado (Shah and Peters, 2020).

Su ventaja es la flexibilidad, ya que la familia no fija la forma de la dependencia sino la de las medias condicionales, y admite cualquier técnica de regresión, de la lineal y los modelos lineales generalizados para respuestas mixtas a los bosques o los métodos de kernel. Sin embargo, las regresiones no son un elemento neutral en este contraste, ya que el contraste solo puede tener potencia frente a las alternativas que dejan covarianza no nula entre los residuos de las regresiones elegidas, de modo

que elegirlas exige conocer el problema que se estudia (Shah and Peters, 2020). Además, existe un límite teórico más severo. Shah and Peters (2020) demuestran que, sin restringir la clase nula, ningún contraste que controle uniformemente el nivel de significación alcanza potencia, ni siquiera frente a una única alternativa, y que la potencia solo se recupera restringiendo el problema, como hace la propia GCM al exigir que el producto de los errores cuadráticos medios de sus dos regresiones sea de orden $o(n^{-1})$ (Shah and Peters, 2020).

Scheidegger et al. (2022) introdujo la medida de covarianza generalizada ponderada (WGCM) que pesa los residuos por la varianza condicional y amplía la clase de alternativas detectables. Esto obliga a ceder algo de potencia en las alternativas que GCM ya cubría bien, y cuando $X$ e $Y$ son categóricos una de sus variantes alcanza potencia frente a todas las alternativas, fuera ya del marco continuo de ese resultado de imposibilidad.

### 2.2.4. Métodos no paramétricos

Los contrastes no paramétricos no fijan ni la forma de la dependencia ni la de las medias condicionales. Los basados en kernel parten de una caracterización de la independencia según la cual dos variables son independientes si y solo si ninguna función de una covaría con ninguna función de la otra, y resume esa condición en una única medida, el criterio HSIC (Gretton et al., 2005). Su extensión al caso condicional es el contraste KCI, que elimina el efecto de $\mathbf{Z}$ mediante regresiones no paramétricas y aplica una medida del mismo tipo a lo que queda. Su distribución nula se genera por simulación de Monte Carlo o se aproxima por una gamma de dos parámetros (Zhang et al., 2011). De forma alternativa, la información mutua condicional se estima directamente con un estimador de vecinos más cercanos y el contraste se calibra con permutaciones locales (Runge, 2018).

Su ventaja es no asumir forma funcional alguna, lo que les permite captar dependencias no lineales, y con densidades no suaves el estimador por vecinos supera en potencia a los métodos de kernel (Runge, 2018). Además, los de kernel se propusieron para domar la maldición de la dimensionalidad que vacía las tablas de contingencia cuando $|\mathbf{Z}|$ crece. Por otro lado, el coste de KCI está dominado por la inversión y la descomposición de matrices de kernel grandes y crece al menos cuadráticamente con el tamaño muestral, lo que lo hace inviable en muestras grandes (Strobl et al., 2019), y las aproximaciones analíticas de su distribución nula no están bien calibradas por debajo del millar de muestras, aunque las permutaciones mejoran la calibración a costa de potencia (Runge, 2018). Las relajaciones RCIT y RCoT aproximan KCI sustituyendo los kernels por características de Fourier aleatorias, pasan a coste lineal en $n$ y devuelven p-valores precisos mucho más rápido que el contraste original, con grafos al menos tan precisos en los algoritmos de descubrimiento (Strobl et al., 2019).

La familia sigue creciendo en la calibración. El contraste de Doran et al. (2014) conserva la estadística de kernel y calibra con una permutación aprendida, que transforma el problema en un contraste de dos muestras de kernel entre la muestra permutada y la original, gana una potencia competitiva y estima mejor la distribución nula a medida que crece $|\mathbf{Z}|$.

### 2.2.5. Extensiones para causalidad

Las garantías recogidas hasta aquí valen para un contraste aislado, pero el producto de un método basado en restricciones es el de una cadena de ellos. Estos métodos eliminan y orientan aristas a partir de una serie de contrastes de independencia (Kitson et al., 2023; Glymour et al., 2019), y en esa cadena ni el nivel de significación ni la potencia miden el error de la búsqueda salvo en muestras muy grandes, pues la probabilidad de rechazar alguna hipótesis verdadera no viene dada por el nivel del contraste, puede superarlo con creces y depende del número de contrastes y de la estructura que el algoritmo recorre (Spirtes et al., 2000). El efecto se deja ver también degradando la propia propagación, una eliminación errónea de una arista altera los conjuntos de adyacencia que atraviesan los contrastes siguientes, inhibe contrastes que hubieran salvado la arista y arrastra tanto el esqueleto como las estructuras en $v$ (Colombo and Maathuis, 2014). La única garantía disponible es asintótica,

la consistencia del esqueleto exige un nivel $\alpha_n$ que decaiga con el tamaño muestral, y con él el error de la versión muestral se acota exponencialmente (Kalisch and Bühlmann, 2007). El resto del apartado desarrolla las dos direcciones en que la independencia condicional se ha hecho causal, la generalización de los criterios de separación y la relajación de los escenarios en los que se aplican.

La primera dirección de avance generaliza los criterios topológicos que vinculan la independencia estadística con el modelo causal subyacente. Cuando el sistema presenta mecanismos no lineales y ciclos, la $d$-separación clásica resulta teóricamente insuficiente. Para abordarlo, Forré and Mooij (2018) introdujeron los modelos causales estructurales modulares y el criterio de *$\sigma$-separación*, justificando el descubrimiento causal bajo retroalimentación. Paralelamente, frente a variables latentes y sesgo de selección, el criterio de *m-separación* sobre grafos ancestrales (MAGs y PAGs) formaliza la inferencia causal relajando el supuesto de suficiencia (Richardson and Spirtes, 2002). Unificando ambos retos, Mooij and Claassen (2020) demostraron recientemente que las reglas lógicas de orientación topológica (como las del FCI) mantienen su corrección e integridad asintótica incluso en sistemas cíclicos.

La segunda dirección flexibiliza los supuestos sobre el origen de las observaciones. Para resolver la integración de conjuntos de datos heterogéneos, marcos como COmbINE (Triantafillou and Tsamardinos, 2015) extienden los contrastes de independencia condicionando sobre variables indicadoras de contexto. Esto permite unificar experimentos observacionales e intervencionales parcialmente solapados para inferir estructuras globales inidentificables de forma aislada.

En síntesis, estas extensiones dotan a las pruebas de independencia de semántica causal plena frente a ciclos y latentes. Sin embargo, la vulnerabilidad inherente al encadenamiento de contrastes locales en muestras finitas, donde un solo error estadístico altera irremediablemente los conjuntos de condicionamiento posteriores, permanece intacta. Esta fragilidad estructural para propagar errores constituye la motivación central de los enfoques híbridos explorados a continuación, que buscan reconciliar la alta expresividad causal de las restricciones topológicas con la robustez de la optimización global basada en puntuación.

## 2.3. Enfoques híbridos de aprendizaje estructural y líneas futuras

Los métodos basados en restricciones (*constraint-based*) presentan limitaciones debido a su dependencia de las pruebas estadísticas de independencia condicional, cuyo número puede crecer considerablemente con la cantidad de variables y la densidad de la red. Asimismo, los errores estadísticos cometidos durante las primeras etapas del aprendizaje pueden propagarse a decisiones posteriores y comprometer la precisión de la estructura resultante. Por otra parte, los métodos basados en puntuaciones (*score-based*) se enfrentan a la elevada complejidad del espacio de búsqueda, lo que suele requerir estrategias heurísticas que no garantizan alcanzar el óptimo global y cuyos resultados pueden depender de la solución inicial. Ante estas limitaciones, los métodos híbridos combinan técnicas de ambos enfoques para aprovechar sus respectivas fortalezas y mejorar potencialmente tanto la eficiencia del aprendizaje estructural como la calidad de las estructuras obtenidas (Kitson et al., 2023). Esta integración puede adoptar distintas formas, desde restringir el espacio de búsqueda antes de la optimización hasta combinar información estadística y puntuaciones en diferentes fases del aprendizaje.

### 2.3.1. Evolución de los métodos híbridos

Una de las principales estrategias híbridas es el enfoque *Restrict/Maximise* (Kitson et al., 2023). En este esquema, primero se emplean procedimientos basados en restricciones para obtener información sobre las relaciones entre variables y acotar el espacio de búsqueda. Posteriormente, se aplica un algoritmo *score-based* para buscar una estructura de elevada puntuación dentro del espacio delimitado. Esta combinación puede reducir el número de estructuras que deben evaluarse y, con ello, mejorar la eficiencia computacional del aprendizaje.

Una de las primeras propuestas de este tipo fue el algoritmo *Constraint-Bayesian* (CB), presentado por Singh and Valtorta (1993), que combina PC y K2 (Cooper and Herskovits, 1992). CB emplea

pruebas de independencia condicional para obtener un grafo parcialmente dirigido, a partir del cual determina una ordenación de las variables que posteriormente utiliza K2 para construir la red bayesiana. El método alterna iterativamente ambas fases e incrementa progresivamente el tamaño máximo de los conjuntos condicionantes hasta que la puntuación de la estructura deja de mejorar. Sin embargo, el coste de las pruebas de independencia, la sensibilidad a la ordenación obtenida y la naturaleza voraz de K2 introducen limitaciones tanto en la eficiencia como en la calidad de las estructuras aprendidas.

Posteriormente, Friedman et al. (1999) propusieron *Sparse Candidate*, orientado a mejorar la escalabilidad mediante la restricción de los posibles padres de cada variable. A diferencia de CB, que limita la búsqueda de K2 a través de una ordenación, *Sparse Candidate* selecciona directamente un conjunto reducido de padres candidatos mediante criterios estadísticos de relevancia y dependencia. A continuación, realiza una búsqueda basada en puntuaciones restringida a esos candidatos, implementada mediante *Hill-Climbing* con lista tabú en el trabajo original. El procedimiento es iterativo: utiliza la estructura aprendida para actualizar los conjuntos de candidatos y refinar la búsqueda. En sus experimentos, los autores observaron reducciones del coste computacional frente a búsquedas no restringidas, con puntuaciones comparables. No obstante, una selección inadecuada puede excluir relaciones relevantes y limitar la calidad de la estructura final.

Tsamardinos et al. (2006) propusieron el algoritmo *Max-Min Hill-Climbing* (MMHC), que desarrolla la estrategia de selección de relaciones candidatas mediante pruebas de independencia condicional. En su primera etapa utiliza *Max-Min Parents and Children* (MMPC), un procedimiento que identifica posibles padres e hijos de cada variable para estimar el esqueleto de la red. Posteriormente, una búsqueda *Hill-Climbing* basada en puntuaciones construye un DAG y restringe la incorporación de aristas a las relaciones identificadas previamente. A diferencia de *Sparse Candidate*, MMHC no exige fijar un número máximo común de candidatos ni alternar iterativamente las fases de restricción y optimización, lo que permite adaptar los conjuntos de candidatos a la conectividad local. Los experimentos originales mostraron ventajas en distintas medidas de eficiencia y recuperación estructural frente a *Sparse Candidate*. No obstante, el resultado sigue dependiendo de la calidad de la primera etapa, mientras que la búsqueda heurística no garantiza alcanzar una estructura óptima.

### 2.3.2. Mejoras en la selección y aplicación de restricciones

Con el objetivo de reducir el impacto de los errores cometidos durante la fase de restricción, Gasse et al. (2014) propusieron el algoritmo *Hybrid HPC* (H2PC), que sustituye MMPC por *Hybrid Parents and Children* (HPC). Este procedimiento combina técnicas de aprendizaje local para mejorar la identificación de relaciones candidatas, prestando especial atención a la reducción de falsos negativos, que impedirían recuperar determinadas aristas durante la optimización posterior. En los experimentos originales, H2PC mejoró la calidad estructural respecto a MMHC, aunque a costa de un mayor tiempo de ejecución. Estos resultados ponen de manifiesto un compromiso central de los métodos *Restrict/Maximise*: una restricción excesiva puede descartar relaciones verdaderas, mientras que una selección más permisiva amplía las posibilidades de recuperación, pero también el coste de la búsqueda.

Otra línea de investigación ha estudiado los problemas derivados de mantener restricciones rígidas durante la optimización. En este sentido, Nandy et al. (2018) demostraron que restringir una búsqueda basada en puntuaciones a un esqueleto previamente estimado puede comprometer la consistencia del aprendizaje, incluso cuando se dispone del esqueleto correcto. Para abordar este problema, propusieron *Adaptively Restricted Greedy Equivalence Search* (ARGES), una modificación de GES (Chickering, 2002) que busca sobre clases de equivalencia de Markov y permite incorporar determinadas aristas inicialmente excluidas según la configuración del grafo durante la búsqueda. Bajo los supuestos establecidos en el artículo, los autores demostraron garantías de consistencia tanto en el escenario clásico como en determinados escenarios de alta dimensionalidad. Así, ARGES muestra que no solo importa la calidad de las restricciones iniciales, sino también la flexibilidad con la que se aplican durante la optimización.

### 2.3.3. Estrategias alternativas

Además de los métodos *Restrict/Maximise*, existen otras estrategias que combinan procedimientos *constraint-based* y *score-based* sin reducir necesariamente el espacio de búsqueda antes de optimizarlo (Kitson et al., 2023). Una posibilidad consiste en utilizar una búsqueda basada en puntuaciones para obtener una estructura inicial y refinarla después mediante pruebas de independencia condicional. Este planteamiento aparece en *Greedy Fast Causal Inference* (GFCI), propuesto por Ogarrio et al. (2016) para el descubrimiento causal cuando pueden existir variables latentes. Los procedimientos basados en puntuaciones como GES suelen trabajar bajo el supuesto de suficiencia causal, mientras que algoritmos basados en restricciones como FCI (Spirtes et al., 1995) o RFCI (Colombo et al., 2012) admiten causas comunes no observadas, aunque pueden presentar dificultades de precisión con muestras reducidas. GFCI ejecuta primero *Fast Greedy Search* (FGS), una implementación eficiente de GES, para obtener una estructura inicial representada mediante un CPDAG; después aplica pruebas de independencia condicional y reglas de orientación relacionadas con FCI para refinar las adyacencias y obtener un *Partial Ancestral Graph* (PAG). En los experimentos originales se observaron mejoras en distintas medidas de recuperación y precisión frente a FCI, RFCI y FCI+, aunque con un coste computacional superior al de RFCI. La aportación de GFCI va más allá de reducir la búsqueda: combina ambos paradigmas para aprender representaciones causales que contemplan posibles variables no observadas.

Durante el aprendizaje estructural, especialmente con un número reducido de observaciones, algunos procedimientos pueden producir redes con componentes desconectadas, entre las que la evidencia no puede propagarse. Esto puede resultar problemático en dominios donde se espera que las variables formen parte de una misma estructura conectada. Para abordar esta situación, Constantinou (2020) propuso *SaiyanH*, que incorpora explícitamente ese supuesto de conectividad. El algoritmo comienza construyendo un grafo no dirigido y conectado mediante medidas estadísticas de asociación entre variables. Posteriormente, orienta sus aristas combinando pruebas de independencia condicional, funciones de puntuación y criterios basados en efectos de intervención. Finalmente, aplica una búsqueda *Hill-Climbing* con memoria tabú, restringida por las independencias identificadas y por la necesidad de conservar la conectividad. Los experimentos mostraron resultados competitivos en diversas medidas de calidad estructural; sin embargo, imponer una estructura conectada puede introducir relaciones espurias cuando ese supuesto no se ajusta al dominio.

### 2.3.4. Avances recientes

Pese a los avances anteriores, el aprendizaje estructural híbrido sigue afrontando dificultades relacionadas con el coste de identificar relaciones estructurales y con la complejidad de optimizar sobre el espacio de grafos. Investigaciones recientes han explorado mejoras tanto en la eficiencia del aprendizaje del esqueleto como en los procedimientos utilizados para buscar estructuras de alta puntuación.

En esta línea, Wang et al. (2024) propusieron el algoritmo ESLH, orientado a reducir el coste de las pruebas de independencia condicional durante el aprendizaje estructural. Para ello, incorpora una estrategia de umbrales dinámicos (DTH) que permite descartar relaciones poco prometedoras y un procedimiento de aprendizaje del esqueleto basado en la eliminación de triángulos (SLTB), diseñado para reducir el número de pruebas necesarias. Posteriormente, emplea una búsqueda *Hill-Climbing* dividida en tres etapas, que aprovecha el esqueleto aprendido sin depender exclusivamente de él para limitar el efecto de posibles errores. En los experimentos originales, ESLH obtuvo mejoras de eficiencia frente a los métodos comparados y mantuvo una precisión estructural competitiva. Esta propuesta ilustra cómo los desarrollos recientes intentan combinar un aprendizaje de restricciones menos costoso con una optimización menos vulnerable a sus errores.

Mientras que ESLH se centra principalmente en mejorar el aprendizaje del esqueleto, otras propuestas han estudiado alternativas a las búsquedas voraces, que pueden quedar atrapadas en óptimos locales. En esta dirección, Liu et al. (2023) propusieron *Self-Awakened Particle Swarm Optimization* (SAPSO), que combina restricciones estadísticas basadas en información mutua con una adaptación

al aprendizaje estructural de *Particle Swarm Optimization* (PSO) (Kennedy and Eberhart, 1995). El método utiliza un árbol de expansión de peso máximo y medidas de dependencia para orientar la inicialización y restringir el espacio de búsqueda. Después, representa las partículas mediante DAGs y adapta sus actualizaciones al carácter discreto de las modificaciones de aristas, utilizando el criterio BIC (Schwarz, 1978) para evaluar las estructuras. Incorpora, además, un mecanismo *self-awakened* que introduce nuevas soluciones cuando la población se estanca, con el objetivo de mitigar la convergencia prematura. Los experimentos mostraron mejoras en algunas medidas de calidad y eficiencia frente a varios métodos de referencia, aunque su evaluación se limitó a dos redes, lo que dificulta generalizar los resultados.

#### 2.3.5. Limitaciones y desafíos abiertos

La combinación de procedimientos *constraint-based* y *score-based* no garantiza, por sí sola, un rendimiento superior al de los enfoques tradicionales. En este sentido, Karadag (2026) realizó un estudio comparativo de catorce algoritmos de las tres familias, evaluados sobre cinco estructuras simuladas y distintos tamaños muestrales mediante métricas como MCC, F1 y SHD. En las condiciones estudiadas, ninguna familia dominó sistemáticamente al resto, y métodos híbridos como MMHC y H2PC obtuvieron resultados inferiores a los de algunos procedimientos basados exclusivamente en restricciones. El rendimiento también varió según la topología, el número de observaciones y la métrica utilizada. Aunque estas conclusiones se limitan al diseño experimental considerado, subrayan la importancia de realizar comparaciones bajo escenarios variados antes de atribuir ventajas generales a una estrategia de aprendizaje.

En conjunto, la literatura revisada identifica varios desafíos aún relevantes. El primero es equilibrar la reducción del espacio de búsqueda con la conservación de relaciones verdaderas, especialmente cuando las pruebas de independencia condicional son poco fiables por la escasez de datos (Gasse et al., 2014; Nandy et al., 2018). También sigue siendo necesario mejorar la escalabilidad y la exploración del espacio de estructuras sin incrementar excesivamente el coste computacional (Wang et al., 2024; Liu et al., 2023). A ello se añade la dificultad de mantener garantías de aprendizaje bajo supuestos causales menos restrictivos, por ejemplo, cuando existen variables latentes (Ogarrio et al., 2016; Nandy et al., 2018). En definitiva, el reto no consiste únicamente en combinar técnicas basadas en restricciones y puntuaciones, sino en determinar cómo integrarlas de manera eficiente y robusta según las características de los datos y los supuestos del problema.

## 3. Conclusiones y líneas futuras

### 3.1. Conclusiones

El presente trabajo ha revisado el aprendizaje estructural de redes bayesianas basado en restricciones, tomando el algoritmo PC como hilo conductor y articulando el análisis en tres ejes: variantes del algoritmo, pruebas de independencia condicional y enfoques híbridos. La conclusión principal es que el rendimiento depende de la interacción entre potencia estadística, coste computacional y supuestos causales, y que no existe una estrategia universalmente superior.

El PC es el método de referencia de la familia *constraint-based*: cada decisión de poda u orientación se apoya en una serie de contrastes de independencia condicional. Esa trazabilidad es también su principal vulnerabilidad, pues en muestras finitas los errores se propagan al esqueleto y a la orientación (Spirtes et al., 2000; Colombo and Maathuis, 2014). Las cinco limitaciones revisadas (consistencia en alta dimensión, dependencia del orden, pérdida de potencia con $|\mathbf{S}|$, coste computacional y rigidez de supuestos) no se eliminan con las variantes que tratamos, sino que se desplazan.

Las pruebas de independencia condicional determinan qué dependencias pueden detectarse y, por tanto, qué grafos son alcanzables. La correlación parcial es eficiente bajo normalidad; las tablas de

contingencia son el contraste canónico para datos discretos, pero sufren escasez de celdas; los métodos de regresión, incluida la medida de covarianza generalizada, cubren parte de la no linealidad y admiten extensiones a datos mixtos, aunque dependen de la especificación de los modelos; y los contrastes de kernel detectan dependencias no lineales a costa de un mayor coste y de una calibración delicada (Shah and Peters, 2020; Zhang et al., 2011; Runge, 2018; Strobl et al., 2019). Shah and Peters (2020) muestran que ningún contraste puede tener potencia uniforme frente a todas las alternativas sin restringir la clase nula, lo que confirma que no existe una prueba universal.

La independencia condicional tampoco identifica la dirección causal: bajo Markov, fidelidad y suficiencia causal, el PC devuelve como máximo un CPDAG, por lo que parte de las orientaciones queda indeterminada con datos observacionales (Spirtes et al., 2000). Las extensiones causales amplían el ámbito tratable, pero la orientación adicional exige supuestos de separación, intervenciones o conocimiento de dominio (Richardson and Spirtes, 2002; Triantafillou and Tsamardinos, 2015; Mooij and Claassen, 2020); la inferencia causal es, por tanto, una inferencia bajo supuestos explícitos.

Los métodos híbridos combinan ambos paradigmas, pero no garantizan por sí solos un mejor resultado. Las estrategias *Restrict/Maximise*, desde CB y Sparse Candidate hasta MMHC y H2PC, reducen el espacio de búsqueda, aunque un falso negativo en la fase de restricción puede eliminar aristas irrecuperables (Singh and Valtorta, 1993; Friedman et al., 1999; Tsamardinos et al., 2006; Gasse et al., 2014). ARGES muestra que restringir la búsqueda con un esqueleto fijo puede romper la consistencia, y que restricciones adaptativas la recuperan bajo ciertos supuestos de esparsidad (Nandy et al., 2018), mientras que GFCI incorpora variables latentes al combinar la búsqueda voraz con las reglas de FCI (Ogarrio et al., 2016). El estudio comparativo de Karadag (2026) sugiere que ninguna familia domina sistemáticamente y que el rendimiento depende de la topología, el tamaño muestral y la métrica. La clave no es sustituir un paradigma por otro, sino diseñar la interfaz entre restricciones y puntuaciones para que los errores de la primera fase sean recuperables por la segunda.

En definitiva, la pregunta relevante no es qué algoritmo es mejor en abstracto, sino qué supuestos son defendibles en cada dominio y qué errores pueden tolerarse. La elección debe guiarse por el tipo de dato, el tamaño muestral, la dimensionalidad, la densidad, la presencia de variables latentes, el objetivo (predicción o estimación causal) y el presupuesto computacional. El enfoque basado en restricciones mantiene una ventaja característica: su fase de poda es auditable contraste a contraste y sus supuestos son explícitos. Esa interpretabilidad, junto con su papel en los métodos híbridos, explica por qué el PC y sus variantes siguen siendo una referencia en el descubrimiento causal.

### 3.2. Limitaciones del estudio

Esta revisión es narrativa y no sistemática, por lo que la selección de trabajos puede estar sesgada y las afirmaciones sobre rendimiento proceden de los estudios originales, no de una reproducción independiente.

### 3.3. Líneas futuras

1. **Garantías en muestra finita.** Desarrollar cotas, conjuntos de confianza sobre el CPDAG y procedimientos de calibración adaptativa del nivel de significación.

2. **Pruebas adaptativas.** Seleccionar o combinar contrastes según el dato, el tamaño muestral y $|\mathbf{S}|$, con extensión a datos mixtos y de alta dimensión.

3. **Supuestos relajados.** Integrar variables latentes, ciclos, no estacionariedad y eventos extremos con garantías formales, aprovechando datos intervencionales cuando estén disponibles.

4. **Escalabilidad y enfoques diferenciables.** Combinar paralelización, algoritmos *anytime* y relajaciones diferenciables que conserven garantías discretas e integren restricciones corregibles durante la optimización.

5. **Evaluación reproducible.** Bancos de prueba comunes que varíen topología, muestra, dimensionalidad y confusión latente, informando de calidad estructural, calibración y coste computacional.

Estas líneas son complementarias: las garantías condicionan el diseño de las pruebas, la relajación de supuestos exige nuevas formas de evaluar la identificabilidad y la escalabilidad determina qué métodos son aplicables. Su avance permitiría abordar el descubrimiento causal como un problema de ingeniería de supuestos, datos y coste, en el que el PC y sus variantes seguirían ocupando un lugar central.

# A. Resumen de variantes del algoritmo PC

Tabla 1: Principales variantes y extensiones del algoritmo PC, agrupadas según la limitación que abordan (numeración de la Sección 2.1).

| Variante | Aportación principal | Garantías / coste |
|---|---|---|
| *Algoritmo de partida* | | |
| **PC**<br>Spirtes and Glymour (1991) | Poda del grafo completo con contrastes de orden creciente; orientación de estructuras en $v$ y reglas de Meek (1995); devuelve un CPDAG. | Correcto y completo con oráculo; polinómico si el grado está acotado. |
| *(i) Garantías en alta dimensión* | | |
| **PC muestral gaussiano**<br>Kalisch and Bühlmann (2007) | Correlación parcial con $z$ de Fisher y nivel $\alpha_n \to 0$. | Consistente con $p = O(n^a)$ y grafos dispersos; exige fidelidad fuerte (Uhler et al., 2013). |
| *(ii) Dependencia del orden* | | |
| **CPC**<br>Ramsey et al. (2006) | Orienta un triple solo si el nodo central está en todos sus conjuntos separadores o en ninguno; si no, lo marca como ambiguo. | Menos errores de orientación, salida menos informativa. |
| **PC-stable**<br>Colombo and Maathuis (2014) | Congela las adyacencias al inicio de cada nivel $\ell$. | Esqueleto independiente del orden; más contrastes. |
| **CPC-, MPC-, LCPC-, LMPC-stable**<br>Colombo and Maathuis (2014) | Orientación conservadora, por mayoría o con listas de conflictos y aristas bidireccionales; extensión a FCI y RFCI. | Salida completa independiente del orden; consistencia en alta dimensión. |
| *(iii) Errores con conjuntos de condicionamiento grandes* | | |
| **PC con cortes mínimos y BD**<br>Abellán et al. (2006) | Conjuntos de corte mínimos ($CUT_{X,Y}$), contraste bayesiano BD, resolución de triángulos y refinamiento voraz. | Datos discretos; mejora empírica en muestras finitas. |
| **$k$-PC**<br>Kocaoglu (2023) | Solo contrastes con $\lvert\mathbf{S}\rvert \leq k$; aprende la clase de $k$-equivalencia mediante grafos de $k$-clausura. | Clase menos fina; más robusto en muestras pequeñas. |
| *(iv) Coste computacional* | | |
| **PC paralelo (BIB / MPI)**<br>Madsen et al. (2017) | Hilos con diseños de bloques incompletos balanceados y procesos MPI sobre subconjuntos de casos. | Aceleración significativa en datos grandes. |
| **`bnlearn` paralelo**<br>Scutari (2017) | Marco paralelo para algoritmos basados en restricciones como alternativa al *backtracking*. | Más estable y rápido en hardware multinúcleo. |
| **Parallel-PC**<br>Le et al. (2019) | Reparte entre núcleos los contrastes de cada nivel de PC-stable. | Independiente del orden; DREAM5 de $> 24$ h a $< 6$ h. |
| *(v) Relajación de supuestos* | | |
| **TPC**<br>Biswas and Shlizerman (2022) | PC para series temporales con relaciones retardadas y contemporáneas; contrastes de Pearson y HSIC. | Consistente bajo $\rho$-*mixing* y mezcla fuerte (Biswas and Mukherjee, 2024). |
| **PCMCI**<br>Runge et al. (2019) | Selección de condicionantes de tipo PC seguida de un contraste MCI. | Controla falsos positivos por autocorrelación. |
| **PCstar**<br>Améndola et al. (2026) | Redes max-lineales (eventos extremos); fidelidad a la $C$-separación. | Orienta aristas adicionales; polinómico con grado de entrada acotado. |
| *Decisiones suaves* | | |
| **DAGPA**<br>Zhou et al. (2025) | $d$-separación diferenciable por percolación; optimización por gradiente con p-valores como etiquetas suaves. | Robusto en muestras pequeñas; puente hacia los híbridos. |

## Referencias


Joaquín Abellán, Manuel Gómez-Olmedo, and Serafín Moral. Some variations on the PC algorithm. In *Proceedings of the Third European Workshop on Probabilistic Graphical Models (PGM 2006)*, pages 1–8, Granada, Spain, 2006.

Carlos Améndola, Benjamin Hollering, and Francesco Nowell. A PC algorithm for max-linear Bayesian networks. *Journal of Computational and Graphical Statistics*, pages 1–12, 2026. doi: 10.1080/10618600.2026.2673046.

Pavel Averin, Theodoros Moysiadis, and Ioannis Katakis. Conditional independence tests for constraint-based causal discovery: A survey. *Transactions on Machine Learning Research*, 2026. arXiv:2608.11156.

Rahul Biswas and Somabha Mukherjee. Consistent causal inference from time series with PC algorithm and its time-aware extension. *Statistics and Computing*, 34(1):14, 2024. doi: 10.1007/s11222-023-10330-3.

Rahul Biswas and Eli Shlizerman. Statistical perspective on functional and causal neural connectomics: The time-aware PC algorithm. *PLoS Computational Biology*, 18(11):e1010653, 2022. doi: 10.1371/journal.pcbi.1010653.

David Maxwell Chickering. Optimal structure identification with greedy search. 2002. URL `https://www.jmlr.org/papers/v3/chickering02b.html`.

Diego Colombo and Marloes H. Maathuis. Order-independent constraint-based causal structure learning. *Journal of Machine Learning Research*, 15:3921–3962, 2014.

Diego Colombo, Marloes H. Maathuis, Markus Kalisch, and Thomas S. Richardson. Learning high-dimensional directed acyclic graphs with latent and selection variables. 2012. doi: 10.1214/11-AOS940.

Anthony C. Constantinou. Learning Bayesian networks that enable full propagation of evidence. *IEEE Access*, 8:124845–124856, 2020. doi: 10.1109/ACCESS.2020.3006472.

Gregory F. Cooper and Edward Herskovits. A bayesian method for the induction of probabilistic networks from data. 1992. doi: 10.1007/BF00994110.

Denver Dash. Robust independence testing for constraint-based learning of causal structure. In *Proceedings of the 19th Conference on Uncertainty in Artificial Intelligence (UAI)*, pages 167–174. Morgan Kaufmann, 2003.

Gary Doran, Krikamol Muandet, Kun Zhang, and Bernhard Schölkopf. A permutation-based kernel conditional independence test. In *UAI*, pages 132–141, 2014.

Patrick Forré and Joris M. Mooij. Constraint-based causal discovery for non-linear structural causal models with cycles and latent confounders. arXiv preprint, 2018.

Nir Friedman, Iftach Nachman, and Dana Pe'er. Learning Bayesian network structure from massive datasets: The sparse candidate algorithm. In *Proceedings of the Fifteenth Conference on Uncertainty in Artificial Intelligence (UAI)*, pages 206–215. Morgan Kaufmann, 1999.

Maxime Gasse, Alex Aussem, and Haytham Elghazel. A hybrid algorithm for Bayesian network structure learning with application to multi-label learning. *Expert Systems with Applications*, 41 (15):6755–6772, 2014. doi: 10.1016/j.eswa.2014.04.032.

Clark Glymour, Kun Zhang, and Peter Spirtes. Review of causal discovery methods based on graphical models. *Frontiers in Genetics*, 10:524, 2019. doi: 10.3389/fgene.2019.00524.

Arthur Gretton, Olivier Bousquet, Alex Smola, and Bernhard Schölkopf. Measuring statistical dependence with hilbert-schmidt norms. In *International conference on algorithmic learning theory*, pages 63–77. Springer, 2005.

Wiebke Günther, Urmi Ninad, Jonas Wahl, and Jakob Runge. Conditional independence testing with heteroskedastic data and applications to causal discovery. volume 35, pages 16191–16202, 2022.

Naftali Harris and Mathias Drton. Pc algorithm for gaussian copula graphical models, 2012. URL `https://arxiv.org/abs/1207.0242`.

Harold Hotelling. New light on the correlation coefficient and its transforms. *Journal of the Royal Statistical Society. Series B (Methodological)*, 15(2):193–232, 1953.

Markus Kalisch and Peter Bühlmann. Estimating high-dimensional directed acyclic graphs with the pc-algorithm. *Journal of Machine Learning Research*, 8:613–636, 2007.

Markus Kalisch, Martin Mächler, Diego Colombo, Marloes H. Maathuis, and Peter Bühlmann. Causal inference using graphical models with the R package pcalg. *Journal of Statistical Software*, 47(11): 1–26, 2012. doi: 10.18637/jss.v047.i11.

Tugay Karadag. Performance evaluation of Bayesian network learning algorithms in structural equation modeling: A simulation study. *Entropy*, 28(9):955, 2026. doi: 10.3390/e28090955.

James Kennedy and Russell Eberhart. Particle swarm optimization. In *Proceedings of the IEEE International Conference on Neural Networks*, 1995. doi: 10.1109/ICNN.1995.488968.

Neville Kenneth Kitson, Anthony C Constantinou, Zhigao Guo, Yang Liu, and Kiattikun Chobtham. A survey of bayesian network structure learning. *Artificial Intelligence Review*, 56(8):8721–8814, 2023.

Murat Kocaoglu. Characterization and learning of causal graphs with small conditioning sets. In *Advances in Neural Information Processing Systems*, volume 36, pages 74140–74179, 2023. doi: 10.52202/075280-3244.

Steffen L. Lauritzen. *Graphical Models*. Oxford University Press, Oxford, 1996.

Thuc Duy Le, Tao Hoang, Jiuyong Li, Lin Liu, Huawen Liu, and Shu Hu. A fast PC algorithm for high dimensional causal discovery with multi-core PCs. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, 16(5):1483–1495, 2019. doi: 10.1109/TCBB.2016.2591526. Publicado en línea en 2016.

Kun Liu, Peiran Li, Yu Zhang, Jia Ren, Xianyu Wang, and Uzair Aslam Bhatti. Self-awakened particle swarm optimization BN structure learning algorithm based on search space constraint. *Computers, Materials & Continua*, 76(3):3257–3274, 2023. doi: 10.32604/cmc.2023.039430.

Anders L. Madsen, Frank Jensen, Antonio Salmerón, Helge Langseth, and Thomas D. Nielsen. A parallel algorithm for Bayesian network structure learning from large data sets. *Knowledge-Based Systems*, 117:46–55, 2017.

Christopher Meek. Causal inference and causal explanation with background knowledge. In *Proceedings of the Eleventh Conference on Uncertainty in Artificial Intelligence (UAI)*, pages 403–410, 1995.

Joris M Mooij and Tom Claassen. Constraint-based causal discovery using partial ancestral graphs in the presence of cycles. In *Conference on Uncertainty in Artificial Intelligence*, pages 1159–1168. Pmlr, 2020.

Preetam Nandy, Alain Hauser, and Marloes H. Maathuis. High-dimensional consistency in score-based and hybrid structure learning. *The Annals of Statistics*, 46(6A):3151–3183, 2018. doi: 10.1214/17-AOS1654.

Juan Miguel Ogarrio, Peter Spirtes, and Joe Ramsey. A hybrid causal search algorithm for latent variable models. In *Proceedings of the Eighth International Conference on Probabilistic Graphical Models*, pages 368–379. PMLR, 2016. URL `https://proceedings.mlr.press/v52/ogarrio16.html`.

Judea Pearl. *Causality: Models, Reasoning, and Inference*. Cambridge University Press, New York, 2 edition, 2009.

Joseph Ramsey, Jiji Zhang, and Peter Spirtes. Adjacency-faithfulness and conservative causal inference. In *Proceedings of the Twenty-Second Conference on Uncertainty in Artificial Intelligence (UAI)*, pages 401–408, 2006.

Thomas Richardson and Peter Spirtes. Ancestral graph markov models. *The Annals of Statistics*, 30 (4):962–1030, 2002.

Jakob Runge. Conditional independence testing based on a nearest-neighbor estimator of conditional mutual information. In *International conference on artificial intelligence and statistics*, pages 938–947. Pmlr, 2018.

Jakob Runge, Peer Nowack, Marlene Kretschmer, Seth Flaxman, and Dino Sejdinovic. Detecting and quantifying causal associations in large nonlinear time series datasets. *Science Advances*, 5(11): eaau4996, 2019.

Mauro Scanagatta, Antonio Salmerón, and Fabio Stella. A survey on bayesian network structure learning from data. *Progress in Artificial Intelligence*, 8:425–439, 2019. doi: 10.1007/s13748-019-00194-y.

Cyrill Scheidegger, Julia Hörrmann, and Peter Bühlmann. The weighted generalised covariance measure. *Journal of Machine Learning Research*, 23(273):1–68, 2022.

Gideon Schwarz. Estimating the dimension of a model. 1978. doi: 10.1214/aos/1176344136.

Marco Scutari. Learning Bayesian networks with the bnlearn R package. *Journal of Statistical Software*, 35(3):1–22, 2010. doi: 10.18637/jss.v035.i03.

Marco Scutari. Bayesian network constraint-based structure learning algorithms: Parallel and optimized implementations in the bnlearn R package. *Journal of Statistical Software*, 77(2):1–20, 2017. doi: 10.18637/jss.v077.i02.

Rajen D. Shah and Jonas Peters. The hardness of conditional independence testing and the generalised covariance measure. *The Annals of Statistics*, 48(3):1514–1538, 2020. ISSN 2168-8966. doi: 10.1214/19-aos1857. URL `http://dx.doi.org/10.1214/19-AOS1857`.

Moninder Singh and Marco Valtorta. An algorithm for the construction of Bayesian network structures from data. In *Proceedings of the Ninth Conference on Uncertainty in Artificial Intelligence (UAI)*, pages 259–265. Morgan Kaufmann, 1993. doi: 10.1016/B978-1-4832-1451-1.50036-6.

Peter Spirtes and Clark Glymour. An algorithm for fast recovery of sparse causal graphs. *Social Science Computer Review*, 9(1):62–72, 1991.

Peter Spirtes, Christopher Meek, and Thomas S. Richardson. Causal inference in the presence of latent variables and selection bias. In *Proceedings of the Eleventh Conference on Uncertainty in Artificial Intelligence*, 1995. URL `https://mlanthology.org/uai/1995/spirtes1995uai-causal/`.

Peter Spirtes, Clark Glymour, and Richard Scheines. *Causation, Prediction, and Search*. MIT Press, Cambridge, MA, 2000.

Eric V Strobl, Kun Zhang, and Shyam Visweswaran. Approximate kernel-based conditional independence tests for fast non-parametric causal discovery. *Journal of Causal Inference*, 7(1):20180017, 2019.

Sofia Triantafillou and Ioannis Tsamardinos. Constraint-based causal discovery from multiple interventions over overlapping variable sets. *The Journal of Machine Learning Research*, 16(1):2147–2205, 2015.

Ioannis Tsamardinos and Giorgos Borboudakis. Permutation testing improves bayesian network learning. In *Joint European conference on machine learning and knowledge discovery in databases*, pages 322–337. Springer, 2010.

Ioannis Tsamardinos, Laura E. Brown, and Constantin F. Aliferis. The max-min hill-climbing Bayesian network structure learning algorithm. *Machine Learning*, 65(1):31–78, 2006.

Caroline Uhler, Garvesh Raskutti, Peter Bühlmann, and Bin Yu. Geometry of the faithfulness assumption in causal inference. *The Annals of Statistics*, 41(2):436–463, 2013.

Niantai Wang, Haoran Liu, Liyue Zhang, Yanbin Cai, and Qianrui Shi. An efficient skeleton learning approach-based hybrid algorithm for identifying Bayesian network structure. *Engineering Applications of Artificial Intelligence*, 133:108105, 2024. doi: 10.1016/j.engappai.2024.108105.

Kun Zhang, Jonas Peters, Dominik Janzing, and Bernhard Schölkopf. Kernel-based conditional independence test and application in causal discovery. In *Proceedings of the 27th Conference on Uncertainty in Artificial Intelligence (UAI)*, pages 804–813. AUAI Press, 2011.

Jincheng Zhou, Mengbo Wang, Anqi He, Yumeng Zhou, Hessam Olya, Murat Kocaoglu, and Bruno Ribeiro. Differentiable constraint-based causal discovery. In *Advances in Neural Information Processing Systems*, 2025.