Constraint-based learning: Variants of the PC algorithm, hypothesis tests for testing conditional independence, causality, hybrid (constraint based and score+search)

Damián Benasco Sánchez
Thales Camargo
Juan David Cárdenas
Universidad Politécnica de Madrid, Spain

Abstract

resumen resumen resumen

1 Introducción

Las redes bayesianas son modelos gráficos probabilísticos que representan un conjunto de variables aleatorias y sus dependencias condicionales mediante un grafo acíclico dirigido (DAG) y un conjunto de parámetros de distribución condicional (Spirtes et al., 2000; Pearl, 2009). En los desarrollos iniciales de este campo, la estructura de la red y sus parámetros se especificaban principalmente a partir del conocimiento experto; sin embargo, esta estrategia presenta limitaciones importantes en sistemas complejos, de alta dimensión o en dominios donde las relaciones subyacentes no se conocen de forma directa (Spirtes et al., 2000; Averin et al., 2026).

Como alternativa, el aprendizaje estructural a partir de datos automatiza la construcción de la topología gráfica y la estimación de parámetros mediante el análisis de bases de datos observacionales o experimentales (Kalisch and Bühlmann, 2007; Colombo and Maathuis, 2014; Averin et al., 2026). En este paradigma de descubrimiento automático, todas las variables se tratan de forma simétrica para inferir directamente las asociaciones probabilísticas y los mecanismos causales subyacentes sin necesidad de imponer una estructura previa por expertos (Spirtes et al., 2000; Pearl, 2009).

Dentro del aprendizaje de estructuras guiado por datos, la literatura distingue tradicionalmente tres familias de métodos: enfoques basados en puntuación y búsqueda, enfoques basados en restricciones y métodos híbridos (Spirtes et al., 2000; Kalisch and Bühlmann, 2007). El aprendizaje basado en restricciones, también conocido como *constraint-based learning*, infiere la estructura de la red mediante pruebas estadísticas de hipótesis de independencia condicional entre variables (Averin et al., 2026; Spirtes et al., 2000). Su fundamento teórico se apoya en la condición de Markov causal y la propiedad de fidelidad (faithfulness), que establecen una correspondencia entre las independencias condicionadas observadas en los datos y la d-separación en el DAG (Spirtes et al., 2000; Pearl, 2009).

Los algoritmos canónicos de esta familia, como el algoritmo PC (Peter-Clark), operan en fases secuenciales y transparentes: primero eliminan aristas entre variables que son condicionalmente independientes dado un conjunto de condicionamiento y, posteriormente, orientan las relaciones que permanecen relevantes según la estructura de independencias observada (Spirtes et al., 2000; Kalisch and Bühlmann, 2007). Este enfoque ofrece una mayor interpretabilidad que otras estrategias de aprendizaje estructural, ya que cada decisión de mantener, eliminar u orientar una relación puede rastrearse hasta una prueba estadística concreta (Averin et al., 2026; Spirtes et al., 2000).

No obstante, el aprendizaje basado en restricciones también presenta limitaciones importantes en muestras finitas. La propagación de errores estadísticos puede alterar decisiones tempranas sobre

eliminación de aristas, la potencia de las pruebas de independencia condicional disminuye cuando aumenta el tamaño del conjunto de condicionamiento y la calidad de la inferencia puede depender del orden de procesamiento de las variables (Kalisch and Bühlmann, 2007; Colombo and Maathuis, 2014). Estos problemas motivan la aparición de métodos híbridos, que combinan la fase de restricción con una etapa de optimización por puntuación y búsqueda local (Kalisch and Bühlmann, 2007; Colombo and Maathuis, 2014).

Para solventar estas debilidades, surgen los métodos híbridos, los cuales combinan las fortalezas complementarias del aprendizaje basado en restricciones y de los métodos basados en puntuación y búsqueda (Kalisch and Bühlmann, 2007; Colombo and Maathuis, 2014). En este esquema, la fase de restricción reduce el espacio de soluciones mediante pruebas de independencia condicional y, a continuación, la búsqueda local optimiza una función de puntuación global para refinar la estructura final (Kalisch and Bühlmann, 2007; Colombo and Maathuis, 2014).

En este contexto, el presente trabajo se centra en el estado del arte de los métodos *constraint-based* para el aprendizaje de redes bayesianas, con especial atención a las variantes del algoritmo PC, a las pruebas de independencia condicional, a la relación entre independencia y causalidad, y a la evolución hacia enfoques híbridos que integran restricciones y optimización basada en puntuación. El objetivo es revisar la literatura más relevante para situar el problema de inferencia estructural dentro del marco teórico del descubrimiento causal y justificar el interés de combinar estrategias estadísticas y causales en la construcción de modelos probabilísticos a partir de datos observacionales (Spirtes et al., 2000; Pearl, 2009; Averin et al., 2026).

2 Estado del arte

El panorama actual del descubrimiento de estructuras en redes bayesianas y modelos gráficos causales ha experimentado una notable evolución, transitando desde la formulación clásica de algoritmos basados en restricciones hacia métodos altamente escalables, flexibles e híbridos. Para comprender de manera sistemática este estado del arte, la presente sección se organiza en tres ejes analíticos interconectados. En primer lugar, se examina la evolución del algoritmo PC y sus variantes, abordando desde sus fundamentos teóricos y modificaciones para garantizar la independencia del orden de entrada y la paralelización, hasta sus extensiones modernas para datos temporales, valores extremos y optimización diferenciable. En segundo lugar, se analizan las pruebas de hipótesis de independencia condicional, comprendidas como el motor estadístico crítico que sustenta las decisiones de poda de aristas y orientación en presencia de variados tipos de datos. Por último, se exploran los paradigmas híbridos, los cuales integran el filtrado local por restricciones con la optimización por puntuación o la resolución lógica de conflictos para mitigar la acumulación de errores en muestras finitas y mejorar la precisión estructural.

2.1 Evolución del Algoritmo PC: Fundamentos, Inestabilidad y Variantes Algorítmicas

El **algoritmo PC** (denominado así por sus creadores Peter Spirtes y Clark Glymour) constituye el método clásico y fundacional dentro del paradigma de aprendizaje de estructuras causales basado en restricciones. Desarrollado como una alternativa computacionalmente eficiente al algoritmo SGS (*Spirtes, Glymour y Scheines*), el algoritmo PC parte de un grafo completo no dirigido y elimina aristas de forma recursiva basándose en decisiones de independencia condicional. Esto produce un grafo no dirigido que luego puede ser parcialmente orientado y extendido para representar el DAG subyacente. El algoritmo PC se ejecuta en el peor de los casos en tiempo exponencial (en función del número de nodos), pero si el DAG subyacente real es disperso, esta complejidad se reduce a un tiempo de ejecución polinomial. (Spirtes et al., 2000; Scanagatta et al., 2019)

En el algoritmo PC, asumimos un conjunto de variables $\mathbf{X} = (X_1, \ldots, X_n)$ con una distribución de probabilidad global P sobre ellas. Los subconjuntos de variables de $\mathbf{X}$ se representan mediante letras mayúsculas en negrita (por ejemplo, $\mathbf{A}, \mathbf{B}, \mathbf{C}$). La notación $I(\mathbf{A}, \mathbf{B} \mid \mathbf{C})$ denota que los conjuntos de variables $\mathbf{A}$ y $\mathbf{B}$ son condicionalmente independientes dado el conjunto $\mathbf{C}$. El algoritmo PC asume la hipótesis de fidelidad (*faithfulness*). Esto significa que existe un grafo acíclico dirigido (DAG), G, tal que las relaciones de independencia entre las variables de $\mathbf{X}$ son exactamente aquellas representadas por G mediante el criterio de d-separación. En consecuencia, el algoritmo PC se apoya en la posibilidad de comprobar cuándo se verifica $I(\mathbf{A}, \mathbf{B} \mid \mathbf{C})$ en el grafo G y, a partir de esa información, recuperar la estructura subyacente. (Spirtes et al., 2000; Abellán et al., 2006)

La idea central del método consiste en recuperar primero el esqueleto del grafo y, posteriormente, orientar las aristas que permanecen. La etapa de poda se realiza eliminando enlaces entre parejas de nodos cuando existe un subconjunto de sus vecinos que hace que ambas variables sean condicionalmente independientes dados esos vecinos. Este criterio permite reducir progresivamente el grafo completo inicial hasta un grafo no dirigido compatible con las independencias observadas. (Spirtes et al., 2000; Abellán et al., 2006)

Algorithm 1 Algoritmo PC: fase de búsqueda del esqueleto

```
Inicializar G' como un grafo completo no dirigido sobre X
i ← 0
repeat
    for cada par adyacente (X, Y) en G' do
        if existe S ⊆ Adj_{G'}(X) \ {Y} con |S| = i y I(X, Y | S) then
            Guardar S_XY ← S
            Eliminar la arista X − Y de G'
        end if
    end for
    i ← i + 1
until ∀X ∈ X, |Adj_{G'}(X)| ≤ i
```

En que el conjunto completo de variables del problema se denota por $\mathbf{X}$, mientras que $\mathrm{Adj}_{G'}(X)$ representa el conjunto de vecinos de X en el grafo actual G'. La expresión $I(X, Y \mid S)$ indica que X e Y son condicionalmente independientes dado el conjunto S. Así, si las independencias observadas son fieles a un DAG, no existe un enlace entre X e Y si y solo si existe un subconjunto S de los vecinos de X tal que se cumple $I(X, Y \mid S)$. Para cada par de variables, S_{XY} contendrá dicho conjunto, si se encuentra. Este conjunto se utilizará en la etapa posterior de orientación.(Spirtes et al., 2000; Abellán et al., 2006)

La etapa de orientación procederá buscando conjuntos de tres variables $\{X, Y, Z\}$ tales que los enlaces $X - Z$ y $Y - Z$ estén en el grafo pero no el enlace $X - Y$. Entonces, si $Z \notin S_{XY}$, orienta los enlaces de X a Z y de Y a Z creando una estructura en v: $X \rightarrow Z \leftarrow Y$. Una vez realizadas estas orientaciones, se intenta orientar el resto de las aristas siguiendo dos principios básicos: no crear ciclos y no crear nuevas estructuras en v. Es posible que la orientación de algunas aristas deba elegirse arbitrariamente. Si el conjunto de independencias es fiel a un grafo y disponemos de un procedimiento perfecto para determinar si $I(X, Y \mid S)$, entonces el algoritmo garantiza producir un grafo equivalente (que representa el mismo conjunto de independencias) al original. (Abellán et al., 2006)

A pesar de su solidez teórica y su completitud asintótica bajo supuestos de fidelidad y suficiencia causal, el algoritmo PC clásico presenta varias limitaciones críticas cuando se aplica a datos reales de tamaño muestral finito (Colombo and Maathuis, 2014). En primer lugar, la versión muestral del algoritmo sufre una fuerte dependencia del orden, donde la secuencia en la que se disponen las variables en el conjunto de datos determina qué pruebas de independencia condicional se ejecutan primero; como resultado, los errores estadísticos tempranos alteran dinámicamente los conjuntos de condicionamiento

disponibles para pares de variables posteriores, lo que conduce a esqueletos estimados, estructuras en v y orientaciones de aristas altamente variables. En segundo lugar, las pruebas estadísticas frecuentistas estándar (como χ^2 o las pruebas z de correlación parcial) toman decisiones categóricas e irrevocables desde el principio, y se vuelven cada vez más propensas a errores de tipo I y tipo II a medida que disminuyen los tamaños de muestra o crece la cardinalidad del conjunto de condicionamiento (Abellán et al., 2006). En tercer lugar, aunque el algoritmo es computacionalmente polinómico para grafos dispersos, el cálculo de numerosas pruebas de independencia condicional en conjuntos de datos de alta dimensión o con muestras masivas crea un cuello de botella computacional dominante. Estos desafíos combinados —inestabilidad del orden, vulnerabilidad estadística en muestras finitas y limitaciones de escalabilidad computacional— motivaron el desarrollo de las variantes algorítmicas especializadas que se discuten a continuación.

Abellán, Gómez-Olmedo y Moral (2006) propusieron cuatro modificaciones clave al algoritmo PC estándar para abordar las limitaciones causadas por errores estadísticos en contextos de muestras finitas. Para minimizar los errores de decisión asociados a conjuntos de condicionamiento grandes, introdujeron la evaluación de la independencia condicional mediante conjuntos de corte de tamaño mínimo ($CUT_{X,Y}$), calculados con un algoritmo de Ford-Fulkerson modificado. Además, sustituyeron las pruebas clásicas de χ^2 por una métrica de puntuación bayesiana de Dirichlet (BD), que ofrece un equilibrio más razonable entre los errores de tipo I y tipo II en distintos tamaños de muestra. Asimismo, incorporaron un paso de refinamiento greedy posterior para optimizar el grafo aprendido según una puntuación BD con el fin de aproximar mejor la distribución conjunta de probabilidad, y un método de resolución de triángulos que evalúa la fuerza de los enlaces para podar el arco más débil en subgrafos totalmente conectados de tres variables.

Kalisch y Bühlmann (2007) establecieron la validez teórica de aplicar el algoritmo PC en escenarios de alta dimensión, donde el número de variables p crece rápidamente en función del tamaño muestral n ($p = O(n^a)$ con $0 < a < \infty$). Demostraron que la versión muestral del algoritmo PC, utilizando la transformación z de Fisher para pruebas de correlación parcial, es asintóticamente consistente para estimar el esqueleto de DAG dispersos bajo distribuciones gaussianas multivariantes. Bajo la suposición de que los vecindarios del grafo son dispersos ($q_n = O(n^{1-b})$ con $0 < b \leq 1$), mostraron que la complejidad computacional en el peor caso queda acotada por $O(p^{q_n})$, lo que hace que el aprendizaje de estructuras sea computacionalmente tratable en redes altas y dispersas. Por último, sus simulaciones empíricas demostraron que el algoritmo PC alcanza tasas de descubrimiento verdaderas (TDR) significativamente mayores que las alternativas basadas en puntuación y mantiene una gran robustez en un amplio rango de niveles de significación α.

Colombo y Maathuis (2014) abordaron la cuestión crítica de la dependencia del orden en los algoritmos de aprendizaje de estructuras causales basados en restricciones (incluidos PC, FCI, RFCI y CCD), demostrando que, en escenarios de alta dimensión y muestras finitas, la variación en la secuencia de variables de entrada produce una inestabilidad sustancial en los esqueletos estimados, las estructuras en v y las orientaciones de aristas. Para eliminar la dependencia del orden en la búsqueda del esqueleto, introdujeron el algoritmo extbfPC-stable, que registra y congela los conjuntos de adyacencia $a(X_i)$ al inicio de cada nivel de condicionamiento ℓ, impidiendo que las eliminaciones de aristas dentro del nivel ℓ alteren prematuramente los conjuntos de condicionamiento para otros pares de variables. Para la determinación de estructuras en v independientes del orden, desarrollaron extbfCPC-stable (Conservative PC) y extbfMPC-stable (Majority Rule PC), que evalúan todos los conjuntos separadores para triples no protegidos y clasifican un triple como no ambiguo solo si el nodo intermedio es consistente en su presencia o ausencia en todos los conjuntos separadores (CPC) o en un umbral mayoritario de ellos (MPC). Además, propusieron reglas de orientación basadas en listas (extbfLCPC-stable y extbfLMPC-stable) que utilizan aristas bidireccionales para resolver conflictos de orientación, logrando salidas gráficas completamente independientes del orden. De manera crucial, demostraron que todas las modificaciones propuestas preservan la corrección, la completitud y la consistencia en alta dimensión del algoritmo PC original bajo condiciones teóricas idénticas, mientras extienden con éxito

estos principios de independencia del orden a algoritmos que manejan variables latentes como FCI y RFCI. A través de simulaciones de alta dimensión y análisis de expresión genética, demostraron que las variantes PC-stable producen una varianza significativamente menor de la Distancia de Hamming Estructural (SHD), tasas de descubrimiento verdaderas (TDR) superiores y predicciones de efectos causales mejores cuando se integran con IDA.

2.2 Pruebas de Independencia Condicional y Extensiones para Causalidad

La base del aprendizaje estructural de tipo *constraint-based* reside en las pruebas de independencia condicional, que permiten decidir si dos variables son dependientes o independientes dadas otras variables del sistema...

2.3 Enfoques Híbridos (Constraint-Based y Score-and-Search) y Líneas Futuras

La literatura reciente ha mostrado un creciente interés en enfoques híbridos que combinan la fuerza de los métodos*constraint-based* con las estrategias de*score-and-search*. ...

3 Conclusiones y líneas futuras

Propias.

References

Joaquín Abellán, Manuel Gómez-Olmedo, and Serafín Moral. Some variations on the PC algorithm. In *Proceedings of the Third European Workshop on Probabilistic Graphical Models (PGM 2006)*, pages 1–8, Granada, Spain, 2006.

Pavel Averin, Theodoros Moysiadis, and Ioannis Katakis. Conditional independence tests for constraint-based causal discovery: A survey. arXiv preprint arXiv:2608.11156, 2026.

Diego Colombo and Marloes H. Maathuis. Order-independent constraint-based causal structure learning. *Journal of Machine Learning Research*, 15:3921–3962, 2014.

Markus Kalisch and Peter Bühlmann. Estimating high-dimensional directed acyclic graphs with the pc-algorithm. *Journal of Machine Learning Research*, 8:613–636, 2007.

Judea Pearl. *Causality: Models, Reasoning, and Inference*. Cambridge University Press, New York, 2 edition, 2009.

Mauro Scanagatta, Antonio Salmerón, and Fabio Stella. A survey on bayesian network structure learning from data. *Progress in Artificial Intelligence*, 8:425–439, 2019. doi: 10.1007/s13748-019-00194-y.

Peter Spirtes, Clark Glymour, and Richard Scheines. *Causation, Prediction, and Search*. MIT Press, Cambridge, MA, 2000.