Constraint-based learning

Variantes del algoritmo PC, contrastes de independencia condicional y enfoques híbridos

Damián Benasco Sánchez Thales Camargo Juan David Cárdenas

Universidad Politécnica de Madrid

Máster Universitario en Inteligencia Artificial

Contenido

1. El algoritmo PC: fundamentos, limitaciones y variantes
2. Pruebas de independencia condicional y extensiones para causalidad
3. Enfoques híbridos y líneas futuras

Hilo conductor

Una frase que conecte las tres secciones de la presentación.

1
El algoritmo PC

Motivación y objetivos

Punto de partida

- *Idea 1*
- *Idea 2*
- *Idea 3*

Objetivo de la presentación

- *Qué se revisa*
- *Por qué importa*
- *Qué se concluye*

Algoritmo PC: fundamentos

- *Supuestos: Markov causal, fidelidad, suficiencia causal.*
- *Fase de esqueleto: poda con contrastes de independencia.*
- *Fase de orientación: v-estructuras y reglas de Meek.*
- *Salida: CPDAG.*

Idea clave

La frase que el público debe recordar de esta diapositiva.

Esquema del algoritmo
o figura del informe

Variantes del PC

Variante	Idea clave	Referencia
Variante 1	*Aportación principal*	*Autor, año*
Variante 2	*Aportación principal*	*Autor, año*
Variante 3	*Aportación principal*	*Autor, año*
Variante 4	*Aportación principal*	*Autor, año*

Criterio de agrupación

Ordenar las variantes por la limitación que abordan.

PC-stable y dependencia del orden

El problema

- *Qué se rompe*
- *Por qué*

La solución

- *Cambio en el algoritmo*
- *Trade-off*

Para recordar

Una frase de cierre de la sección.

2
Pruebas de independencia condicional

Pruebas de IC: el motor estadístico

- Cada decisión de poda u orientación del PC se apoya en contrastes $H_0 : I(X, Y \mid \mathbf{Z})$.
- Bajo Markov causal y fidelidad:

$$I(X, Y \mid \mathbf{Z}) \iff X \perp_G Y \mid \mathbf{Z}.$$

- Frente a las funciones de puntuación, que evalúan estructuras completas, la decisión es local y trazable: cada arista se justifica con uno o varios contrastes y sus p-valores.
- No hay contraste universal: van de los paramétricos clásicos a los no paramétricos, y cada uno impone un modelo de dependencia y paga esa restricción con potencia.

Por qué importa

La calidad del grafo aprendido queda acotada por la calidad de las decisiones estadísticas.

Un contraejemplo

Si $X \sim \mathcal{N}(0, 1)$ e $Y = X^2$:

$$\operatorname{corr}(X, Y) = 0 \quad \text{pero} \quad \neg I(X, Y).$$

La correlación parcial no la detecta.

Cuatro bloques de contrastes: parcial, tablas, regresión/GCM y no paramétricos (kernel y kNN).

Correlación parcial: el contraste gaussiano

- Datos continuos con normalidad conjunta.
- $I(X, Y \mid \mathbf{Z})$ equivale a que la correlación parcial $\rho_{XY \cdot \mathbf{Z}}$ se anule.
- Se estima la covarianza muestral S de $(X, Y, \mathbf{Z})$ y se invierte: $\hat{K} = S^{-1}$.

$$\hat{\rho}_{XY \cdot \mathbf{Z}} = \frac{-\hat{K}_{XY}}{\sqrt{\hat{K}_{XX}\hat{K}_{YY}}}.$$

- La transformada z de Fisher convierte la correlación en un estadístico aproximadamente normal.

Contraste

$$z(r) = \tfrac{1}{2} \ln \frac{1+r}{1-r},$$

$$T = \sqrt{n - |\mathbf{Z}| - 3}\; z(\hat{\rho}).$$

Se rechaza H_0 si $|T| > z_{1-\alpha/2}$.

Coste

$\mathcal{O}(|\mathbf{Z}|^3)$ por contraste, con p-valores analíticos.

Correlación parcial: ventajas y limitaciones

Ventajas

- Coste bajo: invertir el bloque de covarianzas.
- p-valores analíticos, sin remuestreo.
- Implementación de referencia en `pcalg` y `bnlearn`.
- Sostiene la consistencia del PC en alta dimensión con grafos dispersos.

Limitaciones

- Solo es válido bajo normalidad y linealidad.
- Fuera de ese modelo, las versiones de rango solo aproximan.
- Correlación nula no implica independencia en general.
- En muestras pequeñas, la aproximación asintótica del p-valor puede ser pobre.

Líneas recientes

WLS para varianza no constante; correlaciones de rango y cópulas para no normalidad; permutaciones para calibrar en muestra pequeña.

Tablas de contingencia: el contraste discreto

- Datos discretos o categóricos: se comparan los conteos observados con los esperados bajo independencia.
- n_{ijk}: observaciones con $X = i$, $Y = j$ y $\mathbf{Z} = k$.

Estadísticos

$$E_{ijk} = \frac{n_{i\cdot k}\, n_{\cdot jk}}{n_{\cdot\cdot k}},$$

$$\chi^2 = \sum_{i,j,k} \frac{(n_{ijk} - E_{ijk})^2}{E_{ijk}},$$

$$G^2 = 2 \sum_{i,j,k} n_{ijk} \ln \frac{n_{ijk}}{E_{ijk}}.$$

Distribución nula

$$\nu = (I-1)(J-1) \prod_l K_l$$

Se rechaza H_0 si el estadístico supera $\chi^2_{\nu,1-\alpha}$.

Lectura

$G^2 = 2n\,\hat{I}(X, Y \mid \mathbf{Z})$: versión discreta del contraste de razón de verosimilitudes, dentro de la familia de información mutua.

Ordinales: tendencia de Jonckheere–Terpstra.

Tablas de contingencia: ventajas y limitaciones

Ventajas

- Contraste canónico para datos categóricos.
- p-valores analíticos.
- Lectura directa como divergencia entre la tabla observada y la esperada.
- En las simulaciones originales del PC, G^2 acertó el grafo más veces que χ^2.

Limitaciones

- Celdas $I \cdot J \cdot \prod_l K_l$: crecimiento exponencial con $|\mathbf{Z}|$ y la cardinalidad.
- Con pocas observaciones por celda, la aproximación χ^2 deja de ser fiable.
- Regla práctica: $n \geq 5\times$ número de celdas.
- El coste es lineal en celdas, pero las celdas son el cuello de botella.

Líneas recientes

Tablas suavizadas (Dash et al., 2003); SECMI (Kubkowski et al., 2021); permutaciones.

Regresión y residuos: el contraste GCM

- Datos mixtos: no se modela directamente la dependencia, sino que se elimina el efecto de $\mathbf{Z}$.
- La versión general es la medida de covarianza generalizada (GCM) de Shah & Peters (2020).
- Se ajustan $\hat{m}_X(\mathbf{z})$ y $\hat{m}_Y(\mathbf{z})$ y se toman los residuos $r_i = x_i - \hat{m}_X(\mathbf{z}_i)$ y $s_i = y_i - \hat{m}_Y(\mathbf{z}_i)$.
- Bajo independencia, los productos $R_i = r_i s_i$ tienen media cero.

$$T_n = \frac{\sqrt{n}\,\bar{R}}{\hat{\sigma}_R}, \qquad \hat{\sigma}_R^2 = \frac{1}{n}\sum_{i=1}^{n}(R_i - \bar{R})^2.$$

Distribución nula

$T_n \longrightarrow \mathcal{N}(0,1)$ si el producto de los errores cuadráticos medios de ambas regresiones es $o(n^{-1})$.

Caso lineal-gaussiano

El contraste coincide, salvo normalización, con la correlación parcial de Fisher.

Idea

No fija la forma de la dependencia, sino la de las medias condicionales.

Regresión y residuos: ventajas y limitaciones

Ventajas

- Flexible: lineal, GLM, bosques y kernels; admite datos mixtos.
- Cubre parte de la no linealidad.
- WGCM pondera por la varianza; el doble ML evita el sobreajuste.

Limitaciones

- Las regresiones no son neutrales: solo detectan alternativas con covarianza residual.
- Sin restringir la clase nula, ningún contraste con nivel uniforme tiene potencia (Shah & Peters, 2020).
- Elegir las regresiones exige conocer el problema; su coste puede ser alto.

Líneas recientes

WGCM amplía las alternativas a costa de potencia; el doble ML permite regresiones flexibles y calibradas.

Kernel y vecinos: contrastes no paramétricos

Kernel: HSIC y KCI

- HSIC: dos variables son independientes si y solo si ninguna función de una covaría con ninguna función de la otra.
- KCI elimina $\mathbf{Z}$ por regresión no paramétrica y aplica una medida tipo HSIC a los residuos.
- Nulo por Monte Carlo o aproximación gamma.

$$\mathrm{HSIC}(X, Y) = 0 \iff X \perp Y.$$

Vecinos más cercanos

- La información mutua condicional se estima con un estimador de k vecinos.
- El contraste se calibra con permutaciones locales.
- RCIT/RCoT sustituyen los kernels por características de Fourier aleatorias y pasan a coste lineal.

Idea común

No se fija la forma de la dependencia ni la de las medias condicionales.

Métodos no paramétricos: ventajas y limitaciones

Ventajas

- No asumen forma funcional.
- Captan dependencias no lineales.
- Con densidades no suaves, los vecinos superan en potencia a los métodos de kernel.
- Los de kernel mitigan la maldición de la dimensionalidad; RCIT/RCoT escalan a muestras grandes.

Limitaciones

- KCI es $\mathcal{O}(n^2)$ o peor: inviable en muestras grandes.
- La distribución nula analítica no está bien calibrada por debajo de ~ 1000 muestras.
- Las permutaciones mejoran la calibración a costa de potencia.

Líneas recientes

Contrastes *distribution-free* cuyo índice se anula si y solo si hay independencia; permutaciones aprendidas para estimar mejor el nulo.

De la independencia a la causalidad

El problema de encadenar contrastes

- Ni α ni la potencia miden el error de la búsqueda, que depende del número de contrastes y de la estructura recorrida.
- Una eliminación errónea inhibe contrastes posteriores y arrastra esqueleto y orientación.
- La consistencia exige $\alpha_n \to 0$ con n.

Nuevos criterios de separación

- σ-**separación**: mecanismos no lineales y ciclos.
- m-**separación** en MAG/PAG: variables latentes y sesgo de selección (FCI).

Nuevos escenarios

- **COmbINE**: unifica datos observacionales e intervencionales parcialmente solapados.
- **CTBN**: contrastes para trayectorias continuas; explotan la asimetría del tiempo.

Forré & Mooij (2018); Richardson & Spirtes (2002); Triantafillou & Tsamardinos (2015); Villa & Stella (2016).

Extensiones causales: alcance y límites

Ventajas

- Dotan a los contrastes de semántica causal plena.
- Cubren ciclos, latentes y sesgo de selección.
- Integran datos heterogéneos y temporales.
- FCI/RFCI y COmbINE amplían el marco sin abandonar las restricciones.

Limitaciones

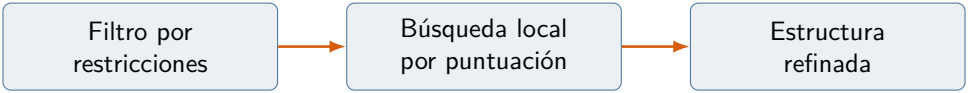
- La vulnerabilidad al encadenamiento en muestra finita permanece intacta.
- Un solo error estadístico altera los conjuntos de condicionamiento posteriores.
- Las garantías son asintóticas.
- Cada extensión añade supuestos y requisitos de datos.

Cierre de la sección

Esta fragilidad estructural es la motivación central de los enfoques híbridos de la sección 3.

3
Enfoques híbridos

Enfoques híbridos



Idea

- *Qué aporta cada fase*
- *Qué se gana*

Ejemplo

Algoritmo híbrido representativo.

Pendiente

Completar con la revisión de la sección de híbridos.

Conclusiones

- *Conclusión 1*
- *Conclusión 2*
- *Conclusión 3*
- *Conclusión 4*

[Esqueleto: completar con las conclusiones del informe.]

Líneas futuras

Línea 1

Descripción breve

Línea 2

Descripción breve

Línea 3

Descripción breve

Línea 4

Descripción breve

Referencias

- *Referencia 1*
- *Referencia 2*
- *Referencia 3*
- *Referencia 4*
- *Referencia 5*

Gracias

Preguntas y discusión

Damián Benasco Thales Camargo Juan David Cárdenas

Anexo: material de respaldo

- *Tabla de variantes del PC*
- *Figura de decisión sobre contrastes*
- *Detalles que no caben en el cuerpo principal*

Anexo: cuándo elegir cada contraste

Modelo	Cuándo usarlo	Coste y límite
Lineal-gaussiano	continuas, normalidad conjunta, linealidad; n grande y $\lvert\mathbf{Z}\rvert$ moderado	$\mathcal{O}(\lvert\mathbf{Z}\rvert^3)$, p analítico; ciego a $Y = X^2$
Medias condicionales	continuas o mixtas; media condicional especificable (GLM, doble ML)	2 regresiones $+\,\mathcal{O}(n)$; WGCM si la varianza del error no es constante
Sin forma funcional	no lineal o error con varianza no constante; n y $\lvert\mathbf{Z}\rvert$ moderados	KCI $\mathcal{O}(n^3)$; RCIT/RCoT $\mathcal{O}(n)$; frágil si $n < 1000$
Tabla de contingencia	categóricas; conteos por celda suficientes; $\lvert\mathbf{Z}\rvert$ bajo	χ^2/G^2 analítico; SECMI si $\lvert\mathbf{Z}\rvert$ grande

GCM frente a KCI

GCM si la dependencia pasa por la media condicional y el regresor es fiable; KCI si no quieres imponer esa forma y asumes su coste.