Constraint-based learning

Variantes del algoritmo PC, contrastes de independencia condicional y enfoques híbridos

Damián Benasco Sánchez Thales Camargo Juan David Cárdenas

Universidad Politécnica de Madrid

Máster Universitario en Inteligencia Artificial

Aprender la estructura: tres familias de métodos

Puntuación y búsqueda

Evalúa grafos completos con una puntuación (p. ej. BIC) y busca el mejor.

Como probarse ropa hasta encontrar la que mejor queda.

Basados en restricciones

Pruebas locales de independencia condicional; cada decisión es rastreable.

Como un detective que descarta sospechosos con pistas.

Híbridos

Las restricciones reducen el espacio y una puntuación refina el grafo (p. ej. MMHC).

El detective hace la lista corta; el jurado decide.

Tema del trabajo

De las restricciones a los híbridos: el PC, sus pruebas de independencia y su evolución hacia los métodos híbridos.

Independencia condicional

¿X e Y son independientes si ya conozco Z?

Cadena



$X \perp Y \mid Z$

Bifurcación



$X \perp Y \mid Z$

Colisor



$X \perp Y$, pero dependientes dado Z

Condición de Markov

El grafo implica independencias en los datos.

Fidelidad

Los datos no tienen independencias extra por coincidencias.

Los colisores dejan una huella distinta en los datos: son la clave para orientar las flechas.

Contenido

1. El algoritmo PC: fundamentos, limitaciones y variantes
2. Pruebas de independencia condicional y extensiones para causalidad
3. Enfoques híbridos y líneas futuras

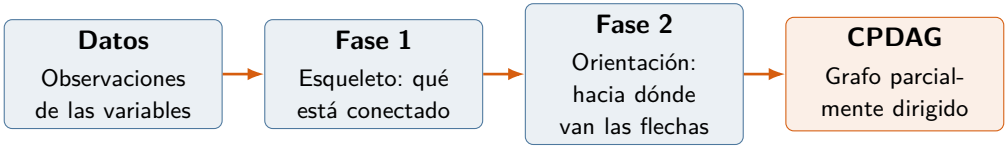
Hilo conductor

Aprender el grafo de una red bayesiana a partir de datos haciendo preguntas del tipo *¿son* X *e* Y *independientes si ya conozco* Z*?*: el algoritmo PC, las pruebas estadísticas que responden a esas preguntas y los híbridos que corrigen su fragilidad.

1
El algoritmo PC

Algoritmo PC: fundamentos

Peter Spirtes y Clark Glymour (1991): dos fases a partir de los datos.



- Supuestos: condición de Markov causal, fidelidad y suficiencia causal (sin variables ocultas).
- Fase 1: parte del grafo completo y poda aristas con contrastes de independencia, guardando el conjunto separador de cada par.
- Fase 2: orienta v-estructuras (colisores) y propaga con las reglas de Meek.

La idea que lo hace eficiente

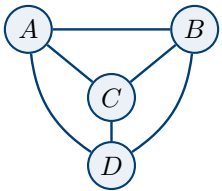
Solo condiciona sobre los vecinos actuales de cada variable, no sobre todos los subconjuntos posibles (como hacía SGS). Coste exponencial en el peor caso, pero polinómico si el grafo es poco denso.

Fase 1: el esqueleto

Todo conectado al inicio; se eliminan aristas con pruebas.

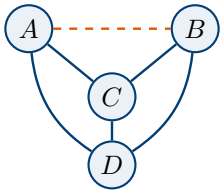
Grafo verdadero (desconocido): $A \to C \leftarrow B$, $C \to D$.

1. Grafo completo



Todo conectado.

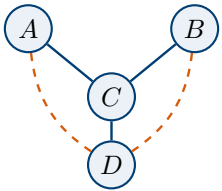
2. Orden $\ell = 0$



$A \perp B \Rightarrow$ se elimina A–B

$S(A, B) = \emptyset$

3. Orden $\ell = 1$



$A \perp D \mid C, \;\; B \perp D \mid C$

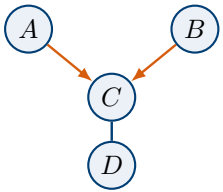
$S(A, D) = S(B, D) = \{C\}$

Líneas discontinuas: aristas eliminadas en cada paso. Se guarda el conjunto separador de cada par, porque la fase 2 lo usa.

Fase 2: orientar las flechas

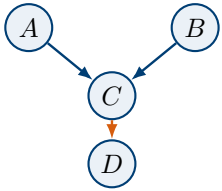
Primero los colisores, después reglas de propagación.

1. Colisor



$$C \notin S(A,B) = \emptyset$$
$$\Rightarrow A \to C \leftarrow B$$

2. Propagación (Meek)



Sin ciclos ni colisores nuevos
$$\Rightarrow C \to D$$

Resultado: un CPDAG

Las aristas que los datos no permiten orientar quedan sin dirección:

$$X \to Y \to Z \quad \text{y} \quad X \leftarrow Y \leftarrow Z$$

implican las mismas independencias.

Intuición: si C fuera intermediario o causa común, habría hecho falta C para separar A y B.

Del oráculo a los datos

Con pruebas perfectas acierta; con datos reales puede fallar.

Oráculo ideal

Pruebas perfectas: el PC es correcto y completo.

Datos reales

Cada prueba puede fallar y el error se propaga a las siguientes.

(i) Alta dimensión
muchas variables, pocos datos

(ii) Orden de las variables
el resultado cambia al reordenar

(iii) Conjuntos grandes
pruebas poco fiables al condicionar mucho

(iv) Coste computacional
miles de pruebas

(v) Supuestos rígidos
i.i.d., fidelidad, sin variables ocultas

Como el algoritmo es secuencial, un error al principio cambia los vecinos y, con ellos, las pruebas posteriores. Estas cinco limitaciones organizan el resto de la sección.

$$p \gg n$$

más variables (p) que observaciones (n)

Kalisch y Bühlmann (2007)

El PC es consistente en alta dimensión si:

- el grafo es poco denso (pocos vecinos);
- los datos son gaussianos;
- el nivel de significación α disminuye con n.

La letra pequeña: fidelidad fuerte · Uhler et al. (2013)

La prueba exige que las dependencias reales no sean demasiado débiles. Las distribuciones que incumplen esta condición no son casos raros: pueden ser una fracción sorprendentemente grande. Por eso el PC es frágil con muestras finitas.

(ii) PC-stable y dependencia del orden

Reordenar las columnas no debería cambiar el resultado.

El problema: PC original

- Elimina una arista y actualiza los vecinos al instante.
- Las pruebas siguientes dependen de lo que ya se eliminó.
- Distinto orden de variables $\Rightarrow$ grafo distinto.

La solución: PC-stable · Colombo y Maathuis (2014)

- Congela la lista de vecinos al inicio de cada nivel.
- Todas las pruebas del nivel usan la misma lista.
- Esqueleto independiente del orden.

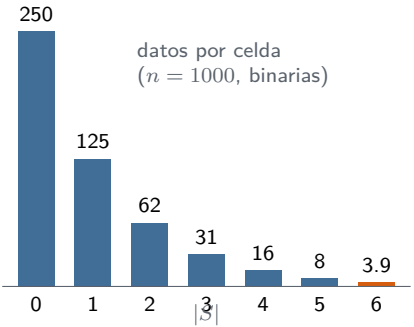
Para las flechas: CPC (Ramsey et al., 2006)

Orienta un colisor solo si todos los separadores coinciden; si no, lo marca como ambiguo.

Precio: más pruebas $\longrightarrow$ (iv)

(iii) Conjuntos de condicionamiento grandes

Condicionar en muchas variables deja pocos datos por celda.



Con $|S| = 6$ ya hay 256 celdas: menos de 4 datos en cada una.

Abellán et al. (2006)

Cortes mínimos para usar conjuntos más pequeños y una prueba bayesiana (BD) en lugar de χ^2.

k-PC · Kocaoglu (2023)

Solo pruebas con $|S| \leq k$: aprende una clase algo menos precisa, pero comete menos errores.

Aprender menos, pero aprenderlo bien.

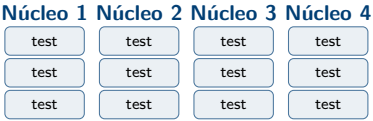
(iv) Coste computacional

Las pruebas de un nivel de PC-stable son independientes: paralelizables.

$$> 24\,\mathbf{h} \rightarrow < 6\,\mathbf{h}$$

Parallel-PC (Le et al., 2019)

DREAM5: más de 1600 variables, 8 núcleos



Madsen et al. (2017)

Hilos con bloques de variables y procesos MPI que se reparten los datos.

Scutari (2017) · `bnlearn`

El *backtracking* empeora la estabilidad; paralelizar es mejor.

Le et al. (2019)

Reparte entre núcleos las pruebas de cada nivel de PC-stable, sin perder la independencia del orden.

(v) Relajar los supuestos

Llevar el PC a datos que no cumplen sus hipótesis.

1. Series temporales

TPC · Biswas y Mukherjee (2024)

PCMCI · Runge et al. (2019)

Datos que dependen del tiempo; relaciones con retardo (la lluvia de ayer afecta al caudal de hoy).

2. Eventos extremos

PCstar · Améndola et al. (2026)

Modelos de colas pesadas (riesgo financiero, crecidas) donde la fidelidad a la d-separación falla.

3. Decisiones suaves

DAGPA · Zhou et al. (2025)

Convierte la d-separación en una función continua y optimiza el grafo con gradientes.

Variables ocultas: FCI y RFCI (se tratan en la sección de pruebas de independencia).

Evolución del algoritmo PC

Año	Variante	Idea clave	Referencia
1991	PC	Esqueleto + orientación	Spirtes y Glymour
1995	Reglas de orientación	Propagación sin ciclos	Meek
2006	CPC, cortes mínimos	Fiabilidad estadística (ii, iii)	Ramsey; Abellán
2007	Alta dimensión	Consistencia con $p \gg n$ (i)	Kalisch y Bühlmann
2014	PC-stable	Independencia del orden (ii)	Colombo y Maathuis
2017–19	Paralelización	Pruebas de un nivel en paralelo (iv)	Madsen; Scutari; Le
2023	k-PC	Conjuntos pequeños (iii)	Kocaoglu
2024–26	Tiempo, extremos, DAGPA	Relajar supuestos (v)	Biswas; Améndola; Zhou

Criterio de agrupación

Cada mejora responde a una limitación concreta: el PC no se ha reemplazado, se ha ido parcheando problema a problema.

Resumen del algoritmo PC

Tres ideas antes de pasar a las pruebas de independencia.

1. Interpretable

El PC deduce el grafo con pruebas de independencia; devuelve un CPDAG, no un único DAG.

2. Frágil

Los errores estadísticos se propagan; cada variante corrige una cara del problema.

3. Depende de sus pruebas

Cada decisión es una prueba estadística: elegirla bien es clave (sección 2).

A menudo resolver un problema genera otro, como PC-stable, que hace más pruebas. Esta fragilidad motiva también los métodos híbridos.

2
Pruebas de independencia condicional

Pruebas de IC: el motor estadístico

- Cada decisión de poda u orientación del PC se apoya en contrastes $H_0 : I(X, Y \mid \mathbf{Z})$.
- Bajo Markov causal y fidelidad:

$$I(X, Y \mid \mathbf{Z}) \iff X \perp_G Y \mid \mathbf{Z}.$$

- Frente a las funciones de puntuación, que evalúan estructuras completas, la decisión es local y trazable: cada arista se justifica con uno o varios contrastes y sus p-valores.
- No hay contraste universal: van de los paramétricos clásicos a los no paramétricos, y cada uno impone un modelo de dependencia y paga esa restricción con potencia.

Por qué importa

La calidad del grafo aprendido queda acotada por la calidad de las decisiones estadísticas.

Un contraejemplo

Si $X \sim \mathcal{N}(0, 1)$ e $Y = X^2$:

$$\operatorname{corr}(X, Y) = 0 \quad \text{pero} \quad \neg I(X, Y).$$

La correlación parcial no la detecta.

Fuentes: Spirtes et al. (2000); Kitson et al. (2023); Shah y Peters (2020).

Correlación parcial: el contraste gaussiano

- Datos continuos con normalidad conjunta (Lauritzen, 1996).
- $I(X, Y \mid \mathbf{Z})$ equivale a que la correlación parcial $\rho_{XY \cdot \mathbf{Z}}$ se anule.
- Se estima la covarianza muestral S de $(X, Y, \mathbf{Z})$ y se invierte: $\hat{K} = S^{-1}$.

$$\hat{\rho}_{XY \cdot \mathbf{Z}} = \frac{-\hat{K}_{XY}}{\sqrt{\hat{K}_{XX}\hat{K}_{YY}}}.$$

- La transformada z de Fisher convierte la correlación en un estadístico aproximadamente normal (Hotelling, 1953; Anderson, 2003).

Contraste

$$z(r) = \tfrac{1}{2} \ln \frac{1+r}{1-r},$$

$$T = \sqrt{n - |\mathbf{Z}| - 3}\; z(\hat{\rho}).$$

Se rechaza H_0 si $|T| > z_{1-\alpha/2}$.

Coste

$\mathcal{O}(|\mathbf{Z}|^3)$ por contraste, con p-valores analíticos.

Correlación parcial: ventajas y limitaciones

Ventajas

- Coste bajo: invertir el bloque de covarianzas.
- p-valores analíticos, sin remuestreo.
- Implementación de referencia en `pcalg` y `bnlearn` (Kalisch et al., 2012; Scutari, 2010).
- Sostiene la consistencia del PC en alta dimensión con grafos dispersos (Kalisch y Bühlmann, 2007).

Limitaciones

- Solo es válido bajo normalidad y linealidad.
- Fuera de ese modelo, las versiones de rango solo aproximan (Baba et al., 2004).
- Correlación nula no implica independencia en general.
- En muestras pequeñas, la aproximación asintótica del p-valor puede ser pobre (Tsamardinos et al., 2010).

Líneas recientes

WLS para varianza no constante (Günther et al., 2022); correlaciones de rango y cópulas para no normalidad (Harris y Drton, 2012; Cui et al., 2016); permutaciones para calibrar en muestra pequeña.

Tablas de contingencia: el contraste discreto

- Datos discretos o categóricos: se comparan los conteos observados con los esperados bajo independencia (Spirtes et al., 2000; Kitson et al., 2023).
- n_{ijk}: observaciones con $X = i$, $Y = j$ y $\mathbf{Z} = k$.

Estadísticos

$$E_{ijk} = \frac{n_{i\cdot k}\, n_{\cdot jk}}{n_{\cdot\cdot k}},$$

$$\chi^2 = \sum_{i,j,k} \frac{(n_{ijk} - E_{ijk})^2}{E_{ijk}},$$

$$G^2 = 2 \sum_{i,j,k} n_{ijk} \ln \frac{n_{ijk}}{E_{ijk}}.$$

Distribución nula

$$\nu = (I-1)(J-1) \prod_{l} K_l$$

Se rechaza H_0 si el estadístico supera $\chi^2_{\nu,1-\alpha}$ (Spirtes et al., 2000).

Lectura

$G^2 = 2n\, \hat{I}(X, Y \mid \mathbf{Z})$: versión discreta del contraste de razón de verosimilitudes, dentro de la familia de información mutua (Scutari, 2010).

Ordinales: tendencia de Jonckheere–Terpstra (Jonckheere, 1954; Terpstra, 1952).

Tablas de contingencia: ventajas y limitaciones

Ventajas

- Contraste canónico para datos categóricos (Kitson et al., 2023).
- p-valores analíticos.
- Lectura directa como divergencia entre la tabla observada y la esperada.
- En las simulaciones originales del PC, G^2 acertó el grafo más veces que χ^2 (Spirtes et al., 2000).

Limitaciones

- Celdas $I \cdot J \cdot \prod_l K_l$: crecimiento exponencial con $|\mathbf{Z}|$ y la cardinalidad.
- Con pocas observaciones por celda, la aproximación χ^2 deja de ser fiable.
- Regla práctica: $n \geq 5\times$ número de celdas (Spirtes et al., 2000).
- El coste es lineal en celdas, pero las celdas son el cuello de botella.

Líneas recientes

Tablas suavizadas (Dash et al., 2003); SECMI (Kubkowski et al., 2021); permutaciones.

Regresión y residuos: el contraste GCM

- Datos mixtos: no se modela directamente la dependencia, sino que se elimina el efecto de $\mathbf{Z}$.
- La versión general es la medida de covarianza generalizada (GCM) de Shah & Peters (2020).
- Se ajustan $\hat{m}_X(\mathbf{z})$ y $\hat{m}_Y(\mathbf{z})$ y se toman los residuos $r_i = x_i - \hat{m}_X(\mathbf{z}_i)$ y $s_i = y_i - \hat{m}_Y(\mathbf{z}_i)$.
- Bajo independencia, los productos $R_i = r_i s_i$ tienen media cero.

$$T_n = \frac{\sqrt{n}\,\bar{R}}{\hat{\sigma}_R}, \qquad \hat{\sigma}_R^2 = \frac{1}{n}\sum_{i=1}^{n}(R_i - \bar{R})^2.$$

Distribución nula

$T_n \longrightarrow \mathcal{N}(0,1)$ si el producto de los errores cuadráticos medios de ambas regresiones es $o(n^{-1})$ (Shah y Peters, 2020).

Caso lineal-gaussiano

El contraste coincide, salvo normalización, con la correlación parcial de Fisher (Shah y Peters, 2020).

Idea

No fija la forma de la dependencia, sino la de las medias condicionales.

Regresión y residuos: ventajas y limitaciones

Ventajas

- Flexible: lineal, GLM, bosques y kernels; admite datos mixtos.
- Cubre parte de la no linealidad.
- WGCM pondera por la varianza (Scheidegger et al., 2022); el doble ML evita el sobreajuste (Chernozhukov et al., 2018).

Limitaciones

- Las regresiones no son neutrales: solo detectan alternativas con covarianza residual.
- Sin restringir la clase nula, ningún contraste con nivel uniforme tiene potencia (Shah & Peters, 2020).
- Elegir las regresiones exige conocer el problema; su coste puede ser alto.

Líneas recientes

WGCM amplía las alternativas a costa de potencia (Scheidegger et al., 2022); el doble ML permite regresiones flexibles y calibradas (Chernozhukov et al., 2018).

Kernel y vecinos: contrastes no paramétricos

Kernel: HSIC y KCI

- HSIC: dos variables son independientes si y solo si ninguna función de una covaría con ninguna función de la otra (Gretton et al., 2005).
- KCI elimina $\mathbf{Z}$ por regresión no paramétrica y aplica una medida tipo HSIC a los residuos (Zhang et al., 2011).
- Nulo por Monte Carlo o aproximación gamma (Zhang et al., 2011).

$$\mathrm{HSIC}(X, Y) = 0 \iff X \perp Y.$$

Vecinos más cercanos

- La información mutua condicional se estima con un estimador de k vecinos (Runge, 2018).
- El contraste se calibra con permutaciones locales (Runge, 2018).
- RCIT/RCoT sustituyen los kernels por características de Fourier aleatorias y pasan a coste lineal (Strobl et al., 2019).

Idea común

No se fija la forma de la dependencia ni la de las medias condicionales.

Métodos no paramétricos: ventajas y limitaciones

Ventajas

- No asumen forma funcional.
- Captan dependencias no lineales.
- Con densidades no suaves, los vecinos superan en potencia a los métodos de kernel (Runge, 2018).
- Los de kernel mitigan la maldición de la dimensionalidad (Zhang et al., 2011); RCIT/RCoT escalan a muestras grandes (Strobl et al., 2019).

Limitaciones

- KCI es $\mathcal{O}(n^2)$ o peor: inviable en muestras grandes (Strobl et al., 2019).
- La distribución nula analítica no está bien calibrada por debajo de ~ 1000 muestras (Runge, 2018).
- Las permutaciones mejoran la calibración a costa de potencia (Runge, 2018).

Líneas recientes

Contrastes *distribution-free* cuyo índice se anula si y solo si hay independencia (Cai et al., 2022); permutaciones aprendidas para estimar mejor el nulo (Doran et al., 2014).

De la independencia a la causalidad

El problema de encadenar contrastes

- Ni α ni la potencia miden el error de la búsqueda, que depende del número de contrastes y de la estructura recorrida (Spirtes et al., 2000).
- Una eliminación errónea inhibe contrastes posteriores y arrastra esqueleto y orientación (Colombo y Maathuis, 2014).
- La consistencia exige $\alpha_n \to 0$ con n (Kalisch y Bühlmann, 2007).

Nuevos criterios de separación

- σ-**separación**: mecanismos no lineales y ciclos (Forré y Mooij, 2018).
- m-**separación** en MAG/PAG: variables latentes y sesgo de selección (FCI) (Richardson y Spirtes, 2002).

Nuevos escenarios

- **COmbINE**: unifica datos observacionales e intervencionales parcialmente solapados (Triantafillou y Tsamardinos, 2015).
- **CTBN**: contrastes para trayectorias continuas; explotan la asimetría del tiempo (Villa y Stella, 2016).

Extensiones causales: alcance y límites

Ventajas

- Dotan a los contrastes de semántica causal plena.
- Cubren ciclos, latentes y sesgo de selección.
- Integran datos heterogéneos y temporales.
- FCI/RFCI y COmbINE amplían el marco sin abandonar las restricciones.

Limitaciones

- La vulnerabilidad al encadenamiento en muestra finita permanece intacta.
- Un solo error estadístico altera los conjuntos de condicionamiento posteriores.
- Las garantías son asintóticas.
- Cada extensión añade supuestos y requisitos de datos.

Cierre de la sección

Esta fragilidad estructural es la motivación central de los enfoques híbridos de la sección 3.

Fuentes: Forré y Mooij (2018); Richardson y Spirtes (2002); Triantafillou y Tsamardinos (2015); Villa y Stella (2016).

3
Enfoques híbridos

Motivación

Constraint-based

- Pruebas de **independencia condicional** (IC).
- El número de pruebas puede crecer mucho.
- Un error temprano puede **propagarse**.

Score-and-search

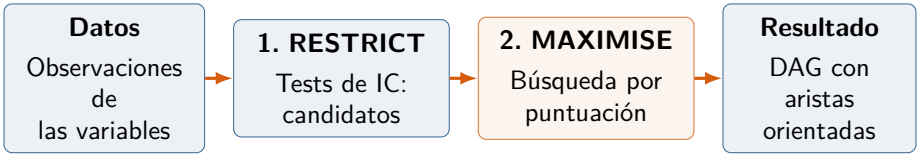
- Asigna una **puntuación** a cada estructura.
- El espacio de DAGs es enorme.
- La búsqueda voraz puede acabar en **óptimos locales**.

La idea híbrida

Usar las dependencias entre variables para orientar la optimización.
Combinar fortalezas *no* garantiza superar a ambos métodos por separado.

Fuente: Kitson et al. (2023)

Restrict/Maximise: ¿cómo funciona un híbrido clásico?



Ventaja esperada

Menos candidatos $\Rightarrow$ búsqueda más manejable.

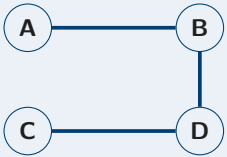
Riesgo central

La búsqueda no recupera una arista **prohibida por el filtro**.

Fuente: Kitson et al. (2023). Esquema conceptual, no algoritmo específico.

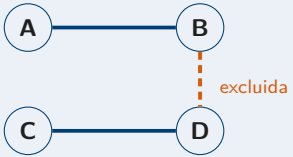
Ejemplo: una restricción demasiado estricta

Esqueleto que querríamos recuperar



Tres conexiones relevantes.

Candidatos tras un test erróneo



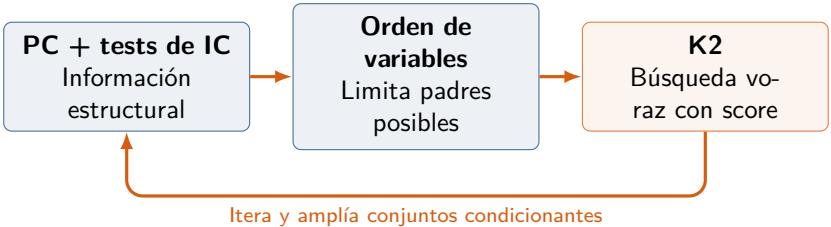
La arista B–D queda fuera de la búsqueda.

Problema de fondo

Optimizar muy bien *dentro* del espacio permitido no corrige un filtro equivocado.

Ejemplo didáctico inventado para explicar el compromiso; no corresponde a un experimento.

CB (1993): restringir mediante una ordenación



Su aportación

Combinar información de PC con K2, alternando ambas etapas.

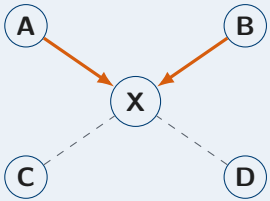
Su límite

K2 depende del orden obtenido y no garantiza un óptimo global.

Fuente: Singh y Valtorta (1993)

Sparse Candidate (1999): restringir posibles padres

Para cada variable objetivo X



Azul = candidatos; gris = excluidos. Ejemplo ilustrativo.

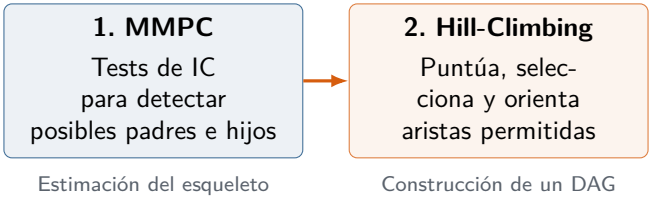
1. **Seleccionar** un pequeño conjunto de padres candidatos mediante dependencias estadísticas.
2. **Optimizar** el DAG mediante Hill-Climbing con lista tabú sobre esos candidatos.
3. **Repetir**: actualizar candidatos con la estructura aprendida.

Salto frente a CB

La restricción deja de ser principalmente un **orden global**: pasa a ser una **lista local de padres posibles**.

Fuente: Friedman et al. (1999)

MMHC (2006): separar detección y optimización



Respecto a Sparse Candidate

Candidatos locales adaptados a cada variable; **dos etapas**, sin alternancia iterativa.

Dependencia que persiste

Si MMPC omite una relación, Hill-Climbing no puede añadirla.

Fuente: Tsamardinos et al. (2006)

Tres hitos: lo que realmente cambia

Método	¿Qué restringe?	Búsqueda	Organización
CB (1993)	Ordenación de variables	K2	Iterativa
Sparse Candidate (1999)	Posibles padres por nodo	HC + tabú	Iterativa
MMHC (2006)	Adyacencias padre–hijo (MMPC)	HC	Dos etapas

Hilo histórico

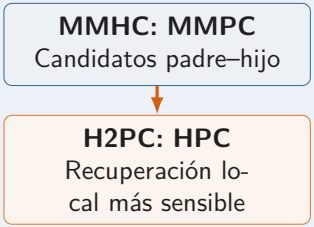
De guiar la búsqueda con un orden a delimitar las relaciones candidatas.

A medida que mejora el filtro, resulta más importante saber *qué ocurre cuando falla*.

Fuentes: Singh y Valtorta (1993); Friedman et al. (1999); Tsamardinos et al. (2006)

H2PC (2014): evitar falsos negativos en el filtro

La modificación



- Falso negativo: **una arista real no pasa el filtro**.
- HPC combina técnicas locales para mejorar la detección.
- La etapa *score-based* sigue buscando con los candidatos.

El nuevo compromiso

Menos aristas reales descartadas puede implicar **más tiempo de ejecución**.

Fuente: Gasse et al. (2014). Mejora observada frente a MMHC en sus experimentos.

ARGES (2018): que las restricciones sean adaptativas

Una búsqueda restringida rígida

Esqueleto inicial

⇓

Solo se permiten movimientos compatibles con ese filtro.

ARGES: restricciones adaptativas

Filtro inicial

⇓

Admite **algunas aristas adicionales** según la configuración actual del grafo.

Diferencia respecto a H2PC

H2PC mejora **qué relaciones detectamos**.
ARGES modifica **cómo aplicamos las restricciones** durante la búsqueda.

Fuente: Nandy et al. (2018). Consistencia demostrada bajo supuestos específicos.

Otras formas de combinar ambos paradigmas

GFCI (2016): invertir el orden

Score (FGS) $\longrightarrow$ IC / FCI

- Empieza con una estructura aprendida por puntuación.
- La refina mediante tests y orientación causal.
- Devuelve un **PAG**, admite posibles variables latentes.

SaiyanH (2020): añadir un supuesto

Grafo conectado $\longrightarrow$ IC + score

- Combina asociaciones, IC y búsqueda HC con tabú.
- Conserva la **conectividad** del grafo.
- Si el supuesto es falso, puede crear aristas espurias.

"Híbrido" no significa siempre "filtrar y después buscar".

Fuentes: Ogarrio et al. (2016); Constantinou (2020)

Avances recientes: acelerar el filtro o mejorar la búsqueda

ESLH (2024)

Coste de las pruebas de IC

- Umbrales dinámicos y eliminación de triángulos.
- Aprendizaje más eficiente del esqueleto.
- **HC en tres etapas** menos sujeto a restricciones rígidas.

SAPSO (2023)

Exploración del espacio de DAGs

- Información mutua para guiar y restringir.
- Búsqueda poblacional **PSO** con score BIC.
- Reinicio adaptativo cuando la población se estanca.

Interpretar bien los resultados

Las mejoras son experimentales y contextuales; **SAPSO se evaluó en dos redes**.

Fuentes: Wang et al. (2024); Liu et al. (2023)

¿Son siempre mejores los híbridos? La evidencia dice que no

14
algoritmos comparados

5
estructuras simuladas

MCC, F1, SHD
varias métricas y tamaños muestrales

Resultado del estudio comparativo de Karadag (2026)

Ninguna familia dominó sistemáticamente en las condiciones estudiadas.

MMHC y H2PC no superaron en todos los casos a enfoques puramente *constraint-based*.

La comparación debe considerar **topología, muestras, supuestos y métrica**.

Fuente: Karadag (2026). La conclusión solo se refiere a los escenarios evaluados.

Conclusiones y líneas futuras del bloque

1. ¿Qué restringir?

Evitar falsos negativos con pocos datos; filtrar sin perder relaciones relevantes.

H2PC, ESLH

2. ¿Cómo buscar?

Explorar mejor DAGs o clases de equivalencia; aplicar restricciones con flexibilidad.

ARGES, SAPSO

3. ¿Bajo qué supuestos?

Tratar variables latentes y evaluar métodos en escenarios variados.

GFCI, evaluación

Idea para cerrar la sección

El reto no es simplemente mezclar técnicas: es decidir cómo integrarlas y cuándo convienen.

Síntesis de la revisión del estado del arte (Kitson et al., 2023, y trabajos citados).

Conclusiones

- **No existe una estrategia universalmente superior.** El rendimiento depende de la interacción entre potencia estadística, coste computacional y supuestos causales.
- **El PC es auditable, pero frágil.** Cada decisión es trazable; en muestra finita, un error se propaga al esqueleto y a la orientación. Las limitaciones se desplazan, no se eliminan.
- **Las pruebas de IC acotan lo que puede aprenderse.** Ningún contraste tiene potencia uniforme frente a todas las alternativas sin restringir la clase nula: no hay una prueba universal.
- **La independencia no basta para orientar.** Bajo Markov, fidelidad y suficiencia, el PC devuelve como máximo un CPDAG; orientar más exige supuestos, intervenciones o conocimiento de dominio.
- **Los híbridos no garantizan una mejora.** Un falso negativo en el filtro deja aristas irrecuperables; la clave está en diseñar la interfaz entre restricciones y puntuaciones.

La pregunta relevante

No qué algoritmo es mejor en abstracto, sino qué supuestos son defendibles y qué errores pueden tolerarse en cada dominio.

Revisión narrativa: las cifras proceden de los estudios originales, no de una reproducción independiente.

Líneas futuras

1. Garantías en muestra finita

Cotas, conjuntos de confianza sobre el CPDAG y calibración adaptativa del nivel de significación.

2. Pruebas adaptativas

Seleccionar o combinar contrastes según el dato, n y $|\mathbf{S}|$; extensión a datos mixtos y de alta dimensión.

3. Supuestos relajados

Variables latentes, ciclos, no estacionariedad y eventos extremos, con garantías formales y datos intervencionales.

4. Escalabilidad y enfoques diferenciables

Paralelización, algoritmos *anytime* y relajaciones diferenciables que conserven garantías discretas.

5. Evaluación reproducible

Bancos de prueba comunes que varíen topología, muestra, dimensionalidad y confusión latente, midiendo calidad estructural, calibración y coste.

Cierre

Las garantías condicionan el diseño de las pruebas; relajar supuestos exige nuevas formas de evaluar la identificabilidad.

Referencias: algoritmo PC y variantes

- Spirtes, P., Glymour, C. (1991). An algorithm for fast recovery of sparse causal graphs. *Social Science Computer Review*.
- Meek, C. (1995). Causal inference and causal explanation with background knowledge. *UAI*.
- Ramsey, J., Zhang, J., Spirtes, P. (2006). Adjacency-faithfulness and conservative causal inference. *UAI*.
- Abellán, J., Gómez-Olmedo, M., Moral, S. (2006). Some variations on the PC algorithm. *PGM*.
- Kalisch, M., Bühlmann, P. (2007). Estimating high-dimensional DAGs with the PC-algorithm. *JMLR*.
- Uhler, C., Raskutti, G., Bühlmann, P., Yu, B. (2013). Geometry of the faithfulness assumption. *Annals of Statistics*.
- Colombo, D., Maathuis, M. (2014). Order-independent constraint-based causal structure learning. *JMLR*.
- Madsen, A. L. et al. (2017). A parallel algorithm for BN structure learning from large data sets. *KBS*.
- Scutari, M. (2017). BN constraint-based structure learning: parallel and optimized implementations in bnlearn. *JSS*.
- Le, T. D. et al. (2019). A fast PC algorithm for high dimensional causal discovery with multi-core PCs. *IEEE/ACM TCBB*.
- Runge, J. et al. (2019). Detecting and quantifying causal associations in large nonlinear time series datasets. *Science Advances*.
- Kocaoglu, M. (2023). Characterization and learning of causal graphs with small conditioning sets. *NeurIPS*.
- Biswas, R., Mukherjee, S. (2024). Consistent causal inference from time series with PC algorithm. *Statistics and Computing*.
- Zhou, J. et al. (2025). Differentiable constraint-based causal discovery. *NeurIPS*.
- Améndola, C., Hollering, B., Nowell, F. (2026). A PC algorithm for max-linear Bayesian networks. *JCGS*.

La bibliografía completa está en el informe.

Gracias

Preguntas y discusión

Damián Benasco Thales Camargo Juan David Cárdenas

Anexo: cuándo elegir cada contraste

Modelo	Cuándo usarlo	Coste y límite
Lineal-gaussiano	continuas, normalidad conjunta, linealidad; n grande y $\lvert\mathbf{Z}\rvert$ moderado	$\mathcal{O}(\lvert\mathbf{Z}\rvert^3)$, p analítico; ciego a $Y = X^2$
Medias condicionales	continuas o mixtas; media condicional especificable (GLM, doble ML)	2 regresiones $+\,\mathcal{O}(n)$; WGCM si la varianza del error no es constante
Sin forma funcional	no lineal o error con varianza no constante; n y $\lvert\mathbf{Z}\rvert$ moderados	KCI $\mathcal{O}(n^3)$; RCIT/RCoT $\mathcal{O}(n)$; frágil si $n < 1000$
Tabla de contingencia	categóricas; conteos por celda suficientes; $\lvert\mathbf{Z}\rvert$ bajo	χ^2/G^2 analítico; SECMI si $\lvert\mathbf{Z}\rvert$ grande

GCM frente a KCI

GCM si la dependencia pasa por la media condicional y el regresor es fiable; KCI si no quieres imponer esa forma y asumes su coste.