Constraint-based learning

Variantes del algoritmo PC, contrastes de independencia condicional y enfoques híbridos

Damián Benasco Sánchez Thales Camargo Juan David Cárdenas

Universidad Politécnica de Madrid

Máster Universitario en Inteligencia Artificial

Aprender la estructura: tres familias de métodos

Puntuación y búsqueda

Evalúa grafos completos con una puntuación (p. ej. BIC) y busca el mejor.

Como probarse ropa hasta encontrar la que mejor queda.

Basados en restricciones

Pruebas locales de independencia condicional; cada decisión es rastreable.

Como un detective que descarta sospechosos con pistas.

Híbridos

Las restricciones reducen el espacio y una puntuación refina el grafo (p. ej. MMHC).

El detective hace la lista corta; el jurado decide.

Tema del trabajo

De las restricciones a los híbridos: el PC, sus pruebas de independencia y su evolución hacia los métodos híbridos.

Independencia condicional

¿X e Y son independientes si ya conozco Z?

Cadena



$X \perp Y \mid Z$

Bifurcación



$X \perp Y \mid Z$

Colisor



$X \perp Y$, pero dependientes dado Z

Condición de Markov

El grafo implica independencias en los datos.

Fidelidad

Los datos no tienen independencias extra por coincidencias.

Los colisores dejan una huella distinta en los datos: son la clave para orientar las flechas.

Contenido

1. El algoritmo PC: fundamentos, limitaciones y variantes
2. Pruebas de independencia condicional y extensiones para causalidad
3. Enfoques híbridos y líneas futuras

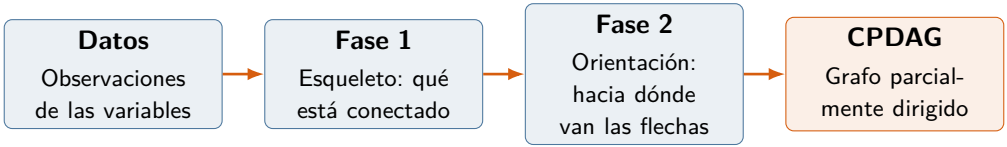
Hilo conductor

Aprender el grafo de una red bayesiana a partir de datos haciendo preguntas del tipo *¿son* X *e* Y *independientes si ya conozco* Z*?*: el algoritmo PC, las pruebas estadísticas que responden a esas preguntas y los híbridos que corrigen su fragilidad.

1
El algoritmo PC

Algoritmo PC: fundamentos

Peter Spirtes y Clark Glymour (1991): dos fases a partir de los datos.



- Supuestos: condición de Markov causal, fidelidad y suficiencia causal (sin variables ocultas).
- Fase 1: parte del grafo completo y poda aristas con contrastes de independencia, guardando el conjunto separador de cada par.
- Fase 2: orienta v-estructuras (colisores) y propaga con las reglas de Meek.

La idea que lo hace eficiente

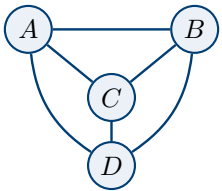
Solo condiciona sobre los vecinos actuales de cada variable, no sobre todos los subconjuntos posibles (como hacía SGS). Coste exponencial en el peor caso, pero polinómico si el grafo es poco denso.

Fase 1: el esqueleto

Todo conectado al inicio; se eliminan aristas con pruebas.

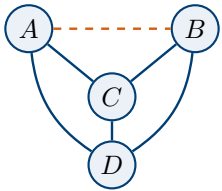
Grafo verdadero (desconocido): $A \to C \leftarrow B$, $C \to D$.

1. Grafo completo



Todo conectado.

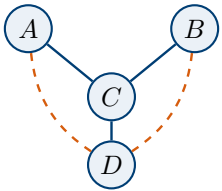
2. Orden $\ell = 0$



$A \perp B \Rightarrow$ se elimina A–B

$S(A, B) = \emptyset$

3. Orden $\ell = 1$



$A \perp D \mid C, \;\; B \perp D \mid C$

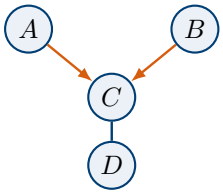
$S(A, D) = S(B, D) = \{C\}$

Líneas discontinuas: aristas eliminadas en cada paso. Se guarda el conjunto separador de cada par, porque la fase 2 lo usa.

Fase 2: orientar las flechas

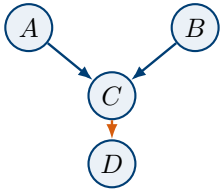
Primero los colisores, después reglas de propagación.

1. Colisor



$$C \notin S(A,B) = \emptyset$$
$$\Rightarrow A \to C \leftarrow B$$

2. Propagación (Meek)



Sin ciclos ni colisores nuevos
$$\Rightarrow C \to D$$

Resultado: un CPDAG

Las aristas que los datos no permiten orientar quedan sin dirección:

$$X \to Y \to Z \quad \text{y} \quad X \leftarrow Y \leftarrow Z$$

implican las mismas independencias.

Intuición: si C fuera intermediario o causa común, habría hecho falta C para separar A y B.

Del oráculo a los datos

Con pruebas perfectas acierta; con datos reales puede fallar.

Oráculo ideal

Pruebas perfectas: el PC es correcto y completo.

Datos reales

Cada prueba puede fallar y el error se propaga a las siguientes.

(i) Alta dimensión
muchas variables, pocos datos

(ii) Orden de las variables
el resultado cambia al reordenar

(iii) Conjuntos grandes
pruebas poco fiables al condicionar mucho

(iv) Coste computacional
miles de pruebas

(v) Supuestos rígidos
i.i.d., fidelidad, sin variables ocultas

Como el algoritmo es secuencial, un error al principio cambia los vecinos y, con ellos, las pruebas posteriores. Estas cinco limitaciones organizan el resto de la sección.

$$p \gg n$$

más variables (p) que observaciones (n)

Kalisch y Bühlmann (2007)

El PC es consistente en alta dimensión si:

- el grafo es poco denso (pocos vecinos);
- los datos son gaussianos;
- el nivel de significación α disminuye con n.

La letra pequeña: fidelidad fuerte · Uhler et al. (2013)

La prueba exige que las dependencias reales no sean demasiado débiles. Las distribuciones que incumplen esta condición no son casos raros: pueden ser una fracción sorprendentemente grande. Por eso el PC es frágil con muestras finitas.

(ii) PC-stable y dependencia del orden

Reordenar las columnas no debería cambiar el resultado.

El problema: PC original

- Elimina una arista y actualiza los vecinos al instante.
- Las pruebas siguientes dependen de lo que ya se eliminó.
- Distinto orden de variables $\Rightarrow$ grafo distinto.

La solución: PC-stable · Colombo y Maathuis (2014)

- Congela la lista de vecinos al inicio de cada nivel.
- Todas las pruebas del nivel usan la misma lista.
- Esqueleto independiente del orden.

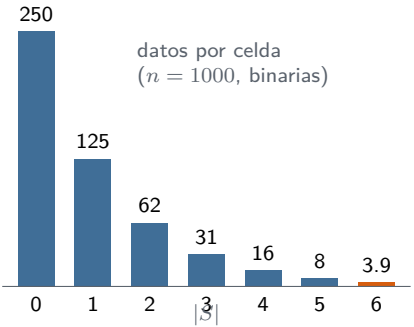
Para las flechas: CPC (Ramsey et al., 2006)

Orienta un colisor solo si el nodo central está en todos los conjuntos separadores o en ninguno; si no, lo marca como ambiguo.

Precio: más pruebas $\longrightarrow$ (iv)

(iii) Conjuntos de condicionamiento grandes

Condicionar en muchas variables deja pocos datos por celda.



Con $|S| = 6$ ya hay 256 celdas: menos de 4 datos en cada una.

Abellán et al. (2006)

Cortes mínimos para usar conjuntos más pequeños y una prueba bayesiana (BD) en lugar de χ^2.

k-PC · Kocaoglu (2023)

Solo pruebas con $|S| \leq k$: aprende una clase algo menos precisa, pero comete menos errores.

Aprender menos, pero aprenderlo bien.

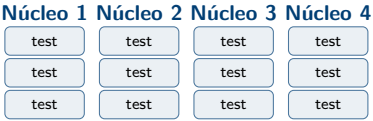
(iv) Coste computacional

Las pruebas de un nivel de PC-stable son independientes: paralelizables.

$$> 24\,\mathbf{h} \rightarrow < 6\,\mathbf{h}$$

Parallel-PC (Le et al., 2019)

DREAM5: más de 1600 variables, 8 núcleos



Madsen et al. (2017)

Hilos con bloques de variables y procesos MPI que se reparten los datos.

Scutari (2017) · `bnlearn`

El *backtracking* empeora la estabilidad; paralelizar es mejor.

Le et al. (2019)

Reparte entre núcleos las pruebas de cada nivel de PC-stable, sin perder la independencia del orden.

(v) Relajar los supuestos

Llevar el PC a datos que no cumplen sus hipótesis.

1. Series temporales

TPC · Biswas y Shlizerman (2022); consistencia: Biswas y Mukherjee (2024)

PCMCI · Runge et al. (2019)

Datos que dependen del tiempo; relaciones con retardo (la lluvia de ayer afecta al caudal de hoy).

2. Eventos extremos

PCstar · Améndola et al. (2026)

Modelos de colas pesadas (riesgo financiero, crecidas) donde la fidelidad a la d-separación falla.

3. Decisiones suaves

DAGPA · Zhou et al. (2025)

Convierte la d-separación en una función continua y optimiza el grafo con gradientes.

Variables ocultas: FCI y RFCI (se tratan en la sección de pruebas de independencia).

Evolución del algoritmo PC

Año	Variante	Idea clave	Referencia
1991	PC	Esqueleto + orientación	Spirtes y Glymour
1995	Reglas de orientación	Propagación sin ciclos	Meek
2006	CPC, cortes mínimos	Fiabilidad estadística (ii, iii)	Ramsey; Abellán
2007	Alta dimensión	Consistencia con $p \gg n$ (i)	Kalisch y Bühlmann
2014	PC-stable	Independencia del orden (ii)	Colombo y Maathuis
2017–19	Paralelización	Pruebas de un nivel en paralelo (iv)	Madsen; Scutari; Le
2023	k-PC	Conjuntos pequeños (iii)	Kocaoglu
2022–26	Tiempo, extremos, DAGPA	Relajar supuestos (v)	Biswas; Améndola; Zhou

Criterio de agrupación

Cada mejora responde a una limitación concreta: el PC no se ha reemplazado, se ha ido parcheando problema a problema.

Resumen del algoritmo PC

Tres ideas antes de pasar a las pruebas de independencia.

1. Interpretable

El PC deduce el grafo con pruebas de independencia; devuelve un CPDAG, no un único DAG.

2. Frágil

Los errores estadísticos se propagan; cada variante corrige una cara del problema.

3. Depende de sus pruebas

Cada decisión es una prueba estadística: elegirla bien es clave (sección 2).

A menudo resolver un problema genera otro, como PC-stable, que hace más pruebas. Esta fragilidad motiva también los métodos híbridos.

2
Pruebas de independencia condicional

Pruebas de IC: el motor estadístico

- Cada decisión de poda u orientación del PC se apoya en contrastes $H_0 : I(X, Y \mid \mathbf{Z})$.
- Bajo Markov causal y fidelidad:

$$I(X, Y \mid \mathbf{Z}) \iff X \perp_G Y \mid \mathbf{Z}.$$

- Frente a las funciones de puntuación, que evalúan estructuras completas, la decisión es local y trazable: cada arista se justifica con uno o varios contrastes y sus p-valores.
- No hay contraste universal: van de los paramétricos clásicos a los no paramétricos, y cada uno impone un modelo de dependencia y paga esa restricción con potencia.

Por qué importa

La calidad del grafo aprendido queda acotada por la calidad de las decisiones estadísticas.

Un contraejemplo

Si $X \sim \mathcal{N}(0, 1)$ e $Y = X^2$:

$$\operatorname{corr}(X, Y) = 0 \quad \text{pero} \quad \neg I(X, Y).$$

La correlación parcial no la detecta.

Fuentes: Spirtes et al. (2000); Kitson et al. (2023); Shah y Peters (2020).

Correlación parcial: el contraste gaussiano

- Datos continuos con normalidad conjunta (Lauritzen, 1996).
- $I(X, Y \mid \mathbf{Z})$ equivale a que la correlación parcial $\rho_{XY \cdot \mathbf{Z}}$ se anule.
- Se estima la covarianza muestral S de $(X, Y, \mathbf{Z})$ y se invierte: $\hat{K} = S^{-1}$.

$$\hat{\rho}_{XY \cdot \mathbf{Z}} = \frac{-\hat{K}_{XY}}{\sqrt{\hat{K}_{XX}\hat{K}_{YY}}}.$$

- La transformada z de Fisher convierte la correlación en un estadístico aproximadamente normal (Hotelling, 1953).

Contraste

$$z(r) = \tfrac{1}{2} \ln \frac{1+r}{1-r},$$

$$T = \sqrt{n - |\mathbf{Z}| - 3}\; z(\hat{\rho}).$$

Se rechaza H_0 si $|T| > z_{1-\alpha/2}$.

Coste

$\mathcal{O}(|\mathbf{Z}|^3)$ por contraste, con p-valores analíticos.

Correlación parcial: ventajas y limitaciones

Ventajas

- Coste bajo: invertir el bloque de covarianzas.
- p-valores analíticos, sin remuestreo.
- Implementación de referencia en `pcalg` y `bnlearn` (Kalisch et al., 2012; Scutari, 2010).
- Sostiene la consistencia del PC en alta dimensión con grafos dispersos (Kalisch y Bühlmann, 2007).

Limitaciones

- Solo es válido bajo normalidad y linealidad.
- Correlación nula no implica independencia en general.
- En muestras pequeñas, la aproximación asintótica del p-valor puede ser pobre (Tsamardinos et al., 2010).

Líneas recientes

WLS para varianza no constante (Günther et al., 2022); correlaciones de rango para no normalidad (Harris y Drton, 2012); permutaciones para calibrar en muestra pequeña.

Tablas de contingencia: el contraste discreto

- Datos discretos o categóricos: se comparan los conteos observados con los esperados bajo independencia (Spirtes et al., 2000; Kitson et al., 2023).
- n_{ijk}: observaciones con $X = i$, $Y = j$ y $\mathbf{Z} = k$.

Estadísticos

$$E_{ijk} = \frac{n_{i\cdot k}\, n_{\cdot jk}}{n_{\cdot\cdot k}},$$

$$\chi^2 = \sum_{i,j,k} \frac{(n_{ijk} - E_{ijk})^2}{E_{ijk}},$$

$$G^2 = 2 \sum_{i,j,k} n_{ijk} \ln \frac{n_{ijk}}{E_{ijk}}.$$

Distribución nula

$$\nu = (I-1)(J-1) \prod_{l} K_l$$

Se rechaza H_0 si el estadístico supera $\chi^2_{\nu,1-\alpha}$ (Spirtes et al., 2000).

Lectura

$G^2 = 2n\, \hat{I}(X, Y \mid \mathbf{Z})$: versión discreta del contraste de razón de verosimilitudes, dentro de la familia de información mutua (Scutari, 2010).

Tablas de contingencia: ventajas y limitaciones

Ventajas

- Contraste canónico para datos categóricos (Kitson et al., 2023).
- p-valores analíticos.
- Lectura directa como divergencia entre la tabla observada y la esperada.
- En las simulaciones originales del PC, G^2 acertó el grafo más veces que χ^2 (Spirtes et al., 2000).

Limitaciones

- Celdas $I \cdot J \cdot \prod_l K_l$: crecimiento exponencial con $|\mathbf{Z}|$ y la cardinalidad.
- Con pocas observaciones por celda, la aproximación χ^2 deja de ser fiable.
- Regla práctica: $n \geq 5\times$ número de celdas (Spirtes et al., 2000).
- El coste es lineal en celdas, pero las celdas son el cuello de botella.

Líneas recientes

Tablas suavizadas (Dash et al., 2003); permutaciones.

Regresión y residuos: el contraste GCM

- Datos mixtos: no se modela directamente la dependencia, sino que se elimina el efecto de $\mathbf{Z}$.
- La versión general es la medida de covarianza generalizada (GCM) de Shah & Peters (2020).
- Se ajustan $\hat{m}_X(\mathbf{z})$ y $\hat{m}_Y(\mathbf{z})$ y se toman los residuos $r_i = x_i - \hat{m}_X(\mathbf{z}_i)$ y $s_i = y_i - \hat{m}_Y(\mathbf{z}_i)$.
- Bajo independencia, los productos $R_i = r_i s_i$ tienen media cero.

$$T_n = \frac{\sqrt{n}\,\bar{R}}{\hat{\sigma}_R}, \qquad \hat{\sigma}_R^2 = \frac{1}{n}\sum_{i=1}^{n}(R_i - \bar{R})^2.$$

Distribución nula

$T_n \longrightarrow \mathcal{N}(0,1)$ si el producto de los errores cuadráticos medios de ambas regresiones es $o(n^{-1})$ (Shah y Peters, 2020).

Caso lineal-gaussiano

El contraste coincide, salvo normalización, con la correlación parcial de Fisher (Shah y Peters, 2020).

Idea

No fija la forma de la dependencia, sino la de las medias condicionales.

Regresión y residuos: ventajas y limitaciones

Ventajas

- Flexible: lineal, GLM, bosques y kernels; admite datos mixtos.
- Cubre parte de la no linealidad.
- WGCM pondera por la varianza (Scheidegger et al., 2022); el doble ML evita el sobreajuste (Chernozhukov et al., 2018).

Limitaciones

- Las regresiones no son neutrales: solo detectan alternativas con covarianza residual.
- Sin restringir la clase nula, ningún contraste con nivel uniforme tiene potencia (Shah & Peters, 2020).
- Elegir las regresiones exige conocer el problema; su coste puede ser alto.

Líneas recientes

WGCM amplía las alternativas a costa de potencia (Scheidegger et al., 2022); el doble ML permite regresiones flexibles y calibradas (Chernozhukov et al., 2018).

Kernel y vecinos: contrastes no paramétricos

Kernel: HSIC y KCI

- HSIC: dos variables son independientes si y solo si ninguna función de una covaría con ninguna función de la otra (Gretton et al., 2005).
- KCI elimina $\mathbf{Z}$ por regresión no paramétrica y aplica una medida tipo HSIC a los residuos (Zhang et al., 2011).
- Nulo por Monte Carlo o aproximación gamma (Zhang et al., 2011).

$$\mathrm{HSIC}(X, Y) = 0 \iff X \perp Y.$$

Vecinos más cercanos

- La información mutua condicional se estima con un estimador de k vecinos (Runge, 2018).
- El contraste se calibra con permutaciones locales (Runge, 2018).
- RCIT/RCoT sustituyen los kernels por características de Fourier aleatorias y pasan a coste lineal (Strobl et al., 2019).

Idea común

No se fija la forma de la dependencia ni la de las medias condicionales.

Métodos no paramétricos: ventajas y limitaciones

Ventajas

- No asumen forma funcional.
- Captan dependencias no lineales.
- Con densidades no suaves, los vecinos superan en potencia a los métodos de kernel (Runge, 2018).
- Los de kernel mitigan la maldición de la dimensionalidad (Zhang et al., 2011); RCIT/RCoT escalan a muestras grandes (Strobl et al., 2019).

Limitaciones

- KCI es $\mathcal{O}(n^2)$ o peor: inviable en muestras grandes (Strobl et al., 2019).
- La distribución nula analítica no está bien calibrada por debajo de ~ 1000 muestras (Runge, 2018).
- Las permutaciones mejoran la calibración a costa de potencia (Runge, 2018).

Líneas recientes

Permutaciones aprendidas para estimar mejor el nulo (Doran et al., 2014).

De la independencia a la causalidad

El problema de encadenar contrastes

- Ni α ni la potencia miden el error de la búsqueda, que depende del número de contrastes y de la estructura recorrida (Spirtes et al., 2000).
- Una eliminación errónea inhibe contrastes posteriores y arrastra esqueleto y orientación (Colombo y Maathuis, 2014).
- La consistencia exige $\alpha_n \to 0$ con n (Kalisch y Bühlmann, 2007).

Nuevos criterios de separación

- σ-**separación**: mecanismos no lineales y ciclos (Forré y Mooij, 2018).
- m-**separación** en MAG/PAG: variables latentes y sesgo de selección (FCI) (Richardson y Spirtes, 2002).

Nuevos escenarios

- **COmbINE**: unifica datos observacionales e intervencionales parcialmente solapados (Triantafillou y Tsamardinos, 2015).

Extensiones causales: alcance y límites

Ventajas

- Dotan a los contrastes de semántica causal plena.
- Cubren ciclos, latentes y sesgo de selección.
- Integran datos heterogéneos.
- FCI/RFCI y COmbINE amplían el marco sin abandonar las restricciones.

Limitaciones

- La vulnerabilidad al encadenamiento en muestra finita permanece intacta.
- Un solo error estadístico altera los conjuntos de condicionamiento posteriores.
- Las garantías son asintóticas.
- Cada extensión añade supuestos y requisitos de datos.

Cierre de la sección

Esta fragilidad estructural es la motivación central de los enfoques híbridos de la sección 3.

Fuentes: Forré y Mooij (2018); Richardson y Spirtes (2002); Triantafillou y Tsamardinos (2015).

3
Enfoques híbridos

Enfoques híbridos: motivación

Métodos *constraint-based*

- Construyen relaciones a partir de contrastes de independencia condicional (IC).
- Coste computacional crece con el tamaño y la densidad del grafo.
- Una decisión estadística errónea puede propagarse durante la búsqueda.

Métodos *score-and-search*

- Evalúan estructuras mediante funciones de puntuación, como BIC.
- El espacio de DAGs crece de forma superexponencial con las variables.
- Las búsquedas heurísticas pueden terminar en óptimos locales.

Motivación de los enfoques híbridos

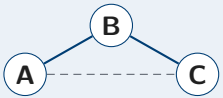
Usar información estadística sobre las relaciones entre variables para orientar o restringir una búsqueda basada en puntuaciones.

Kitson et al. (2023).

Restrict/Maximise: filtrar antes de optimizar

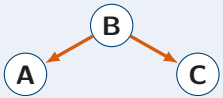
1. *Restrict*

- Los **tests de independencia condicional** identifican relaciones candidatas.
- Se delimitan las aristas posibles, por ejemplo mediante un esqueleto candidato.



2. *Maximise*

- Se exploran **DAGs** que respetan las aristas permitidas.
- Una búsqueda (p. ej., Hill-Climbing) selecciona y orienta aristas.



Compromiso

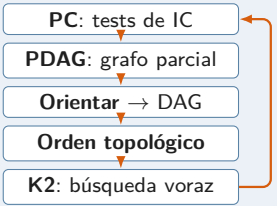
Al reducir el espacio de búsqueda se mejora potencialmente la eficiencia computacional, pero puede perjudicar a la calidad del resultado.

Constraint-Bayesian: PC + K2

- Uno de los primeros algoritmos híbridos de aprendizaje estructural.
- Utiliza PC para obtener información sobre dependencias y una ordenación de las variables.
- K2 busca un DAG mediante puntuaciones, respetando esa ordenación.
- Itera ambas fases: incrementa el tamaño permitido de los conjuntos condicionantes mientras mejora el resultado.

Singh y Valtorta (1993).

Procedimiento



Si no mejora la puntuación, se detiene.

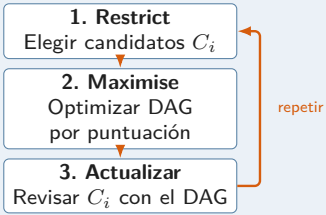
Limitación

Sensible al orden estimado y a la naturaleza voraz de K2.

Sparse Candidate: selección de padres

- Para cada variable X_i, selecciona un conjunto reducido de posibles padres C_i.
- Los candidatos se eligen mediante criterios estadísticos de relevancia y dependencia.
- Realiza una búsqueda por puntuación restringida *Hill-Climbing* con lista tabú.
- Alterna selección de candidatos y búsqueda, actualizando los conjuntos con el DAG obtenido.

Procedimiento iterativo



Aportación frente a CB

SC introduce una selección explícita de padres candidatos, permitiendo restringir y refinar iterativamente el espacio de búsqueda.

Friedman et al. (1999).

MMHC: aprendizaje en dos etapas

- **MMPC:** pruebas de IC para identificar posibles padres e hijos de cada variable.
- Los conjuntos locales estiman las adyacencias del **esqueleto** de la red.
- **Hill-Climbing:** construye un DAG mediante puntuaciones, restringiendo la incorporación de aristas a las relaciones candidatas.

Dos fases diferenciadas

MMPC

Identificación de posibles padres e hijos

⇓

Hill-Climbing

Búsqueda por puntuaciones restringida a las relaciones candidatas

Aportación frente a Sparse Candidate

Mejora la selección de candidatos mediante pruebas MMPC y realiza el aprendizaje en fases no iterativas.

Tsamardinos et al. (2006).

Dependencia del filtro

Si MMPC omite una relación verdadera, Hill-Climbing no puede recuperarla.

CB, Sparse Candidate y MMHC: comparación

Algoritmo	Qué restringe	Optimización	Organización
CB (1993)	Ordenación de variables	K2	Iterativa
Sparse Candidate (1999)	Hasta k padres candidatos por variable	Hill-Climbing con tabú	Iterativa
MMHC (2006)	Aristas candidatas mediante MMPC	Hill-Climbing	Dos etapas

Evolución posterior

Tras estas primeras propuestas, la investigación se centra no solo en reducir el espacio de búsqueda, sino también en mejorar la calidad de las restricciones y flexibilizar su aplicación.

Singh y Valtorta (1993); Friedman et al. (1999); Tsamardinos et al. (2006).

H2PC: mejorar la selección de candidatos

- Sustituye **MMPC** por *Hybrid Parents and Children* (**HPC**), que combina procedimientos de aprendizaje local.
- Busca reducir los falsos negativos durante la selección de candidatos, evitando descartar relaciones verdaderas.
- Los experimentos originales mostraron mejoras en la **calidad estructural** frente a MMHC.

Gasse et al. (2014).

Aportación frente a MMHC

Mejora la identificación de relaciones candidatas sin modificar la arquitectura general de aprendizaje.

Limitación

La selección más exhaustiva de candidatos incrementa el coste computacional, obteniendo mayores tiempos de ejecución que MMHC en los experimentos originales.

ARGES: restricciones adaptativas

- Parte de *Greedy Equivalence Search* (**GES**), que busca sobre clases de equivalencia de Markov.
- Restringe inicialmente la búsqueda utilizando un esqueleto o un grafo de independencias condicionales estimado.
- Permite añadir aristas inicialmente excluidas cuando aparecen determinadas configuraciones en el grafo.
- Bajo ciertos supuestos, presenta **garantías de consistencia**, incluso en escenarios de alta dimensión.

Nandy et al. (2018).

Aportación frente a H2PC

En lugar de mejorar únicamente las restricciones iniciales, ARGES **flexibiliza su aplicación** durante la optimización.

Limitación

La relajación solo permite determinadas aristas adicionales y no garantiza encontrar la estructura óptima con muestras finitas.

Restricciones: ventajas y limitaciones

Mejor selección: H2PC

- Detecta más relaciones candidatas mediante HPC.
- Reduce el riesgo de perder aristas en el primer paso.
- A cambio, incrementa el trabajo estadístico previo.

Mayor flexibilidad: ARGES

- Mantiene una búsqueda inicialmente restringida.
- Admite ciertas incorporaciones adaptativas de aristas.
- Sus garantías dependen de supuestos específicos.

Más allá de Restrict/Maximise

Existen otras estrategias híbridas que combinan restricciones y puntuaciones sin seguir necesariamente este orden de aprendizaje.

Gasse et al. (2014); Nandy et al. (2018).

GFCI: descubrimiento causal con variables latentes

- A diferencia de *Restrict/Maximise*, comienza con una búsqueda por puntuaciones y después aplica restricciones.
- Ejecuta *Fast Greedy Search* (**FGS**), obteniendo un **CPDAG** inicial.
- Utiliza pruebas de IC y reglas de **FCI** para refinar las adyacencias y orientaciones obtenidas.
- Produce un PAG, que representa relaciones causales compatibles con la existencia de posibles variables latentes.

Procedimiento

FGS (Score-based)

CPDAG inicial

⇓

Refinamiento tipo FCI

Tests de IC y orientación

⇓

PAG final

CPDAG vs. PAG

CPDAG: $A - B$

Orientación no determinada.

PAG: $A \leftrightarrow B$

Compatible con confusión latente.

Ogarrio et al. (2016). PAG: Partial Ancestral Graph.

SaiyanH: incorporar conectividad

- Diseñado para dominios donde se espera una red **conectada**.
- Construye inicialmente un grafo no dirigido y conectado utilizando medidas de asociación.
- Orienta relaciones con pruebas de IC, puntuaciones y criterios asociados a intervenciones.
- Refina el resultado mediante *Hill-Climbing* con memoria tabú y restricciones de conectividad.

Aportación

Incorpora conocimiento estructural del dominio que otros enfoques híbridos no exigen.

Riesgo

Si la red verdadera tiene componentes desconectadas, forzar conectividad puede introducir aristas espurias.

Constantinou (2020).

Avances recientes: eficiencia y exploración

ESLH

- Umbrales dinámicos (DTH) para reducir pruebas poco prometedoras.
- Aprendizaje del esqueleto por eliminación de triángulos (SLTB).
- Hill-Climbing en tres etapas, con cierta flexibilidad ante errores del esqueleto.

SAPSO

- Inicialización guiada por dependencias y árbol de expansión máximo.
- Adapta *Particle Swarm Optimization* a cambios discretos de aristas de DAGs.
- Mecanismo *self-awakened* para reducir el estancamiento de la población.

Precaución al comparar

ESLH prioriza acelerar los contrastes; SAPSO explora búsquedas menos voraces, pero su evaluación original usa solo dos redes.

¿Son mejores los métodos híbridos?

- Una evaluación de 2026 comparó **14 algoritmos** *constraint-based*, *score-based* e híbridos.
- Utilizó **cinco DAGs simulados**, diferentes tamaños muestrales y métricas estructurales.
- Consideró **MCC** como métrica principal, junto con **F1** y **SHD** como medidas complementarias.
- Ninguna familia de algoritmos dominó sistemáticamente en todos los escenarios.

Observación

MMHC y H2PC obtuvieron peores resultados que varios métodos basados exclusivamente en restricciones en determinadas condiciones.

Interpretación

El rendimiento depende de la topología, el tamaño muestral y la métrica utilizada.

Karadag (2026). Conclusiones limitadas al diseño experimental estudiado.

Limitaciones y líneas futuras

Calidad de las restricciones

Reducir falsos negativos sin disparar las pruebas de IC, especialmente con muestras escasas.

Búsqueda robusta

Evitar restricciones excesivamente rígidas y mitigar óptimos locales.

Escalabilidad

Aprender candidatos y buscar DAGs de alta puntuación con menos coste computacional.

Supuestos causales

Mantener garantías al incorporar latentes, datos heterogéneos u otros escenarios complejos.

Kitson et al. (2023); Gasse et al. (2014); Nandy et al. (2018); Wang et al. (2024).

Conclusiones

- **No existe una estrategia universalmente superior.** El rendimiento depende de la interacción entre potencia estadística, coste computacional y supuestos causales.
- **El PC es auditable, pero frágil.** Cada decisión es trazable; en muestra finita, un error se propaga al esqueleto y a la orientación. Las limitaciones se desplazan, no se eliminan.
- **Las pruebas de IC acotan lo que puede aprenderse.** Ningún contraste tiene potencia uniforme frente a todas las alternativas sin restringir la clase nula: no hay una prueba universal.
- **La independencia no basta para orientar.** Bajo Markov, fidelidad y suficiencia, el PC devuelve como máximo un CPDAG; orientar más exige supuestos, intervenciones o conocimiento de dominio.
- **Los híbridos no garantizan una mejora.** Un falso negativo en el filtro deja aristas irrecuperables; la clave está en diseñar la interfaz entre restricciones y puntuaciones.

La pregunta relevante

No qué algoritmo es mejor en abstracto, sino qué supuestos son defendibles y qué errores pueden tolerarse en cada dominio.

Revisión narrativa: las cifras proceden de los estudios originales, no de una reproducción independiente.

Líneas futuras

1. Garantías en muestra finita

Cotas, conjuntos de confianza sobre el CPDAG y calibración adaptativa del nivel de significación.

2. Pruebas adaptativas

Seleccionar o combinar contrastes según el dato, n y $|\mathbf{S}|$; extensión a datos mixtos y de alta dimensión.

3. Supuestos relajados

Variables latentes, ciclos, no estacionariedad y eventos extremos, con garantías formales y datos intervencionales.

4. Escalabilidad y enfoques diferenciables

Paralelización, algoritmos *anytime* y relajaciones diferenciables que conserven garantías discretas.

5. Evaluación reproducible

Bancos de prueba comunes que varíen topología, muestra, dimensionalidad y confusión latente, midiendo calidad estructural, calibración y coste.

Cierre

Las garantías condicionan el diseño de las pruebas; relajar supuestos exige nuevas formas de evaluar la identificabilidad.

Referencias: algoritmo PC y variantes

- Spirtes, P., Glymour, C. (1991). An algorithm for fast recovery of sparse causal graphs. *Social Science Computer Review*.
- Meek, C. (1995). Causal inference and causal explanation with background knowledge. *UAI*.
- Ramsey, J., Zhang, J., Spirtes, P. (2006). Adjacency-faithfulness and conservative causal inference. *UAI*.
- Abellán, J., Gómez-Olmedo, M., Moral, S. (2006). Some variations on the PC algorithm. *PGM*.
- Kalisch, M., Bühlmann, P. (2007). Estimating high-dimensional DAGs with the PC-algorithm. *JMLR*.
- Uhler, C., Raskutti, G., Bühlmann, P., Yu, B. (2013). Geometry of the faithfulness assumption. *Annals of Statistics*.
- Colombo, D., Maathuis, M. (2014). Order-independent constraint-based causal structure learning. *JMLR*.
- Madsen, A. L. et al. (2017). A parallel algorithm for BN structure learning from large data sets. *KBS*.
- Scutari, M. (2017). BN constraint-based structure learning: parallel and optimized implementations in bnlearn. *JSS*.
- Le, T. D. et al. (2019). A fast PC algorithm for high dimensional causal discovery with multi-core PCs. *IEEE/ACM TCBB*.
- Runge, J. et al. (2019). Detecting and quantifying causal associations in large nonlinear time series datasets. *Science Advances*.
- Kocaoglu, M. (2023). Characterization and learning of causal graphs with small conditioning sets. *NeurIPS*.
- Biswas, R., Mukherjee, S. (2024). Consistent causal inference from time series with PC algorithm. *Stat. Comput.*
- Biswas, R., Shlizerman, E. (2022). The time-aware PC algorithm. *PLoS Computational Biology*.
- Zhou, J. et al. (2025). Differentiable constraint-based causal discovery. *NeurIPS*.
- Améndola, C., Hollering, B., Nowell, F. (2026). A PC algorithm for max-linear Bayesian networks. *JCGS*.

La bibliografía completa está en el informe.

Gracias

Preguntas y discusión

Damián Benasco Thales Camargo Juan David Cárdenas

Anexo: cuándo elegir cada contraste

Modelo	Cuándo usarlo	Coste y límite
Lineal-gaussiano	continuas, normalidad conjunta, linealidad; n grande y $\lvert\mathbf{Z}\rvert$ moderado	$\mathcal{O}(\lvert\mathbf{Z}\rvert^3)$, p analítico; ciego a $Y = X^2$
Medias condicionales	continuas o mixtas; media condicional especificable (GLM, doble ML)	2 regresiones $+\,\mathcal{O}(n)$; WGCM si la varianza del error no es constante
Sin forma funcional	no lineal o error con varianza no constante; n y $\lvert\mathbf{Z}\rvert$ moderados	KCI $\mathcal{O}(n^3)$; RCIT/RCoT $\mathcal{O}(n)$; frágil si $n < 1000$
Tabla de contingencia	categóricas; conteos por celda suficientes; $\lvert\mathbf{Z}\rvert$ bajo	χ^2/G^2 analítico; tabla suavizada si $\lvert\mathbf{Z}\rvert$ grande

GCM frente a KCI

GCM si la dependencia pasa por la media condicional y el regresor es fiable; KCI si no quieres imponer esa forma y asumes su coste.